단일 관절 모터 출력 저하에 적응하는 Teacher–Student 기반 4족보행 로봇 제어[1) 2)]



Isaac Gym에서 관측 이력 기반 고장 적응 정책의 생존·추종·회복 성능 평가

---

1) Liu et al., Saving the Limping, arXiv:2210.00474v3, 2023. 2) Wu et al., ADAPT, DAI '23, 2023.

1조 변지훈 · 유은빈 · 최서경 · 김준영

02 | 연구 개요 [1]

CONTENTS

주행 중 한 관절의 출력이 줄어도, 고장 정보를 직접 입력하지 않고 보행을 유지하는 정책을 학습

구분	세부 사항
대상·환경	Isaac Gym · Unitree A1 · 12개 관절 중 하나의 출력 저하
방법	물리정보를 받는 Teacher → 최근 1초 관측 이력을 쓰는 Student
검증 목표	고장 후 20초 생존 · 명령 속도 추종 · 1초 연속 안정 회복
완료	Teacher/Student 학습 · 동일 조건 비교 · 관절별 분석 · history 개입 실험
남은 과제	심한 고장의 회복 저하 원인 분석 · 미평가 속도/지형 검증 · 재학습 반복

1) 범위 및 현황: docs/results/p5-tf43000-vs-jt71500.md.

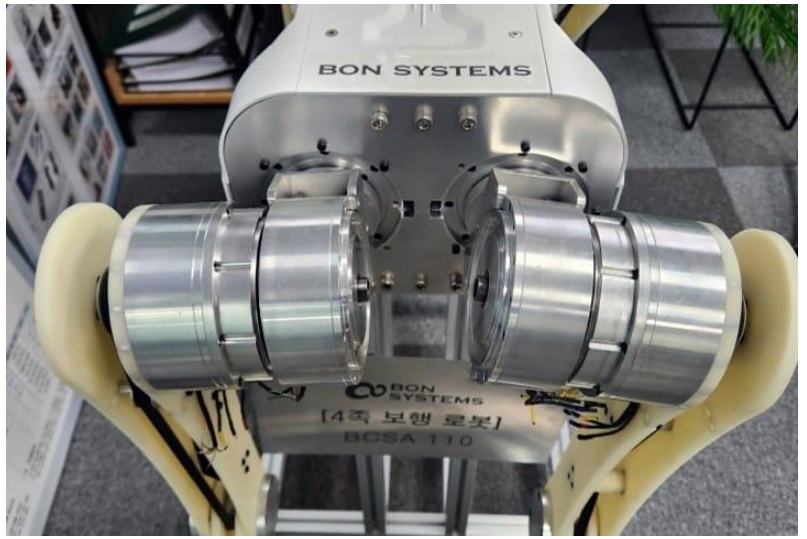
03 | 4족 보행 로봇의 구조 [1) 2)]

RESEARCH BACKGROUND

각 다리의 hip·thigh·calf를 제어하며, 같은 출력 저하라도 발생 관절에 따라 보행 영향이 달라진다.

4개 다리 × 다리당 3개 관절 = 총 12개 구동 관절





Hip 다리를 몸체 안쪽·바깥쪽으로 이동
좌우 균형 · body roll · lateral motion

Thigh 다리를 앞뒤로 이동
보폭 · 추진 · stance/swing 궤적

Calf 무릎을 굽히고 펴며 다리 길이를 조절
몸체 높이 · 수직 지지 · 지면 반력

1) Liu et al., Saving the Limping, arXiv:2210.00474v3, 2023. 2) Wu et al., ADAPT, DAI '23, 2023.

04 | 액추에이터 고장의 분류 [1) 2)]

RESEARCH BACKGROUND

연구 대상은 관절 각도를 고정하는 고장이 아니라, 한 관절의 명령 토크를 일정 비율 줄이는 고장이다.

고장 유형	관절 움직임	능동 torque	본 연구와의 관계
Joint Locking	특정 각도·좁은 범위로 제한	계속 발생 가능	Saving the Limping the Limping의 대상 [1]
Actuator Degradation	가동 범위는 유지	명령보다 작은 torque 출력	본 연구의 직접 대상 · ADAPT 모델 [2]
Torque Loss	외력에 의해 수동 이동	거의 또는 전혀 없음	완전 출력 상실에 포함 · 실제 motor damping은 미모델링

1) Liu et al., Saving the Limping, arXiv:2210.00474v3, 2023. 2) Wu et al., ADAPT, DAI '23, 2023.

05 | 연구 문제와 목표 [1) 2)]

RESEARCH BACKGROUND

목표는 고장 후 넘어지지 않는 것과 명령 속도로 다시 안정적으로 걷는 것을 함께 달성하는 것이다.

정상 상태

12개 관절이 명령 토크를 출력
명령 속도에 맞춰 보행

출력 저하

한 관절의 출력 토크 감소
속도 저하·회전 오차 발생 가능

적응 목표

최근 1초의 움직임을 입력해
12개 관절 명령을 조정

1) Liu et al., Saving the Limping, arXiv:2210.00474v3, 2023. 2) Wu et al., ADAPT, DAI '23, 2023.

06 | 선행연구와 공동학습의 근거 [1) 2)]

RELATED WORK

- RMA는 history 기반 적응 구조, Saving은 공동학습 방식(Joint Training) , ADAPT는 출력 저하 모델 차용.

연구	원 논문의 목적·방법	현재 프로젝트와의 연결
Rapid Motor Adaptation · 2021	변하는 물리조건에 빠르게 적응 ① 물리정보로 보행 정책 학습 ② history로 특징을 추정하는 모듈 학습	관측 이력 → 숨은 조건의 특징 → 행동 이라는 적응 구조의 선행연구 Teacher–Student 구조
Saving the Limping	주행 중 단일 관절 잠금에 대응 Teacher·Student 특징을 점진적으로 혼합 Student와 정책을 공동 최적화	프로젝트의 핵심 학습 아이디어 Student 추정 오차에 Actor도 적응 관절 잠금을 출력 토크 저하로 변경
ADAPT · 2023	관절 출력 저하 조건에서 보행 제어 명령 토크 × 남은 출력 비율 원 논문은 별도의 모방학습 구조 사용	출력 저하 수학 모델을 사용 ADAPT의 학습 파이프라인 전체를 현재 공동학습에 적용한 것은 아님

1) Kumar et al., RMA, RSS 2021; Liu et al., Saving the Limping, 2023. 2) Wu et al., ADAPT, 2023; Lee et al., Science Robotics 2020 (arXiv:2010.11251).

07 | 프로젝트 변형과 연구 기여 [1) 2) 3)]

RESEARCH POSITIONING

논문에서 계승한 모델·학습 구조와 프로젝트에서 정한 수치·평가 조건을 구분한다.

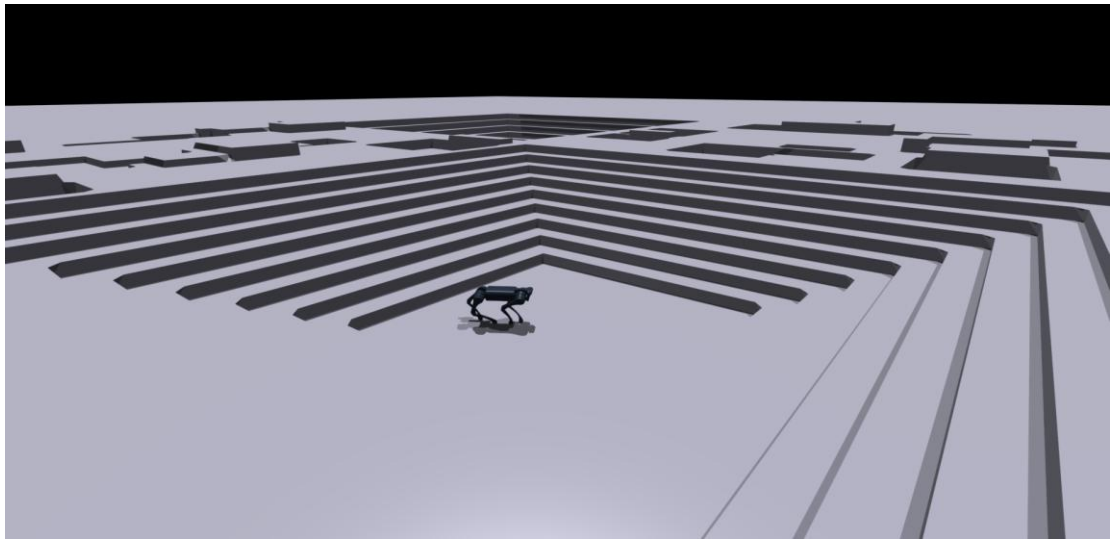
요소	논문·기존 방식	본 프로젝트 반영	구분
문제 정식화	표준 MDP · ADAPT §3.1	고장 상태·관측 이력을 현재 환경에 구체화	정식화 적용
고장 모델	ADAPT: 남은 출력 비율로 토크 축소	동일 토크 감소식 · 단일 관절 · 6단계 열화율	모델 계승
고장 발생	Saving the Limping: 주행 중 단일 관절 잠금	잠금 → 토크 저하 · 발생 시점 2–10초	변형·설정
적응·학습	Saving the Limping: 특징 혼합 + Teacher–Student 공동학습	관측 235D · 이력 50×48 · 특징 8D로 구현	구조 계승
전환 schedule	Saving the Limping: Student 비중 증가 · 모방 가중치 감소	10,000 iteration의 선형 전환	프로젝트 설정
평가 설계	표준 추종 오차 지표 등 활용	0.5 m/s · 고장 후 20초 · 1초 안정 회복	프로젝트 설정

1) Liu et al., Saving the Limping, arXiv:2210.00474v3, 2023. 2) Wu et al., ADAPT, DAI '23, 2023. 3) Local result: docs/results/p5-tf43000-vs-jt71500.md.

08 | Isaac Gym 환경 [1) 2)]

EXPERIMENT ENVIRONMENT

Isaac Gym에서 4,096개 A1 환경을 병렬 실행하고, 정책은 0.02초마다 목표 관절각을 출력한다.



항목	설정
Robot	Unitree A1 · 12 DOF
Simulator	Isaac Gym · GPU PhysX
Parallel envs	4,096
Physics / policy	200 Hz / 50 Hz
Episode	20 s · 1,000 policy steps
PPO rollout	24 steps/env = 98,304 transitions/iteration

1) Makoviychuk et al., Isaac Gym, arXiv:2108.10470, 2021. 2) Rudin et al., Learning to Walk in Minutes, CoRL 2021.

09 | 제어 문제의 정식화 [1]

01 제어 문제 · MDP / 관측·행동 / 고장 전이 / 보상

출력 저하가 발생해도 명령 속도를 추종하도록 누적 보상을 최대화한다. 고장 변수를 직접 모르는 정책의 제어 문제다.

$$M = (S, A, P, R, \gamma, \rho_0), \qquad \gamma = 0.99$$

$$\pi^* = arg\,max_\pi\, E[\sum_{t=0}^{T-1} \gamma^t r_t]$$

요소	역할	구체화
상태 / 관측	환경의 전체 상태와 정책이 받는 정보를 구분	로봇·접촉·지형·물리계수·명령·고장 및 이력 / 부분 관측
행동	현재 관측과 이력에 따라 제어 입력 결정	관측 차원·단위·관절각 보정량
전이	행동 이후 로봇과 접촉 상태가 변화	PD 제어 + 출력 저하 + Isaac Gym 물리
보상	추종·안정성·제어 비용을 하나의 값으로 합산	활성 10개 항·계수·추종 함수
초기화 / 종료	조건을 바꾸어 학습하고 episode를 구분	지형·물리조건 무작위화 / 몸체 접촉·시간 제한

$$s_{t+1} \sim P(\cdot \mid s_t, a_t), \qquad o_t \sim O(\cdot \mid s_t)$$

1) ADAPT §3.1: MDP definition; project environment/schema

10 | 관측 및 행동 공간 [1]

관측은 정책이 받는 정보, 행동은 관절각 보정량이다. 차원·단위를 정의하고 PD 제어로 연결한다.

관측	기호	차원	단위
몸체 선속도	v_b	3	m/s
몸체 각속도	ω_b	3	rad/s
중력·명령	g_b, c_t	6	-, m/s, rad/s
관절 상태	$q - q_0, \dot{q}$	24	rad, rad/s
이전 행동	a_{t-1}	12	-
지형 높이	m_t	187	m

현재 관측
235D
48D + terrain 187D

Student history
50×48
약 1초

$$q_t^{\text{des}} = q^{\text{default}} + 0.25\, a_t, \qquad a_t \in \mathrm{R}^{12}$$

정책 입력

현재 관측 235D + latent 8D = 243D

1) Local code: a1_official_wim_teacher/schema.py; joint_schema.py.

11 | 출력 저하 동역학 [1]

- 고장 모델은 전이 과정의 적용 토크를 변경.
  열화율이 커질수록 해당 관절이 명령 토크를 덜 낸다.

$$\tau_{j,t}^{cmd} = K_{p,j}(q_{j,t}^{des} - q_{j,t}) - K_{d,j}\dot{q}_{j,t}$$

$$\tau_{j,t}^{applied} = (1 - d_{j,t})\tau_{j,t}^{cmd}$$

$$d_{j,t} = d \cdot 1\{j = J_f, t \geq T_f\}, \qquad d \in [0,1]$$

열화율	남은 출력	명령 토크의 감소
0.0	100%	정상 · 감소 없음
0.2	80%	20% 감소
0.4	60%	40% 감소
0.6	40%	60% 감소
0.8	20%	80% 감소
1.0	0%	100% 감소 · 명령 토크 제거

1) ADAPT Eq. (7): output degradation model..

12 | 보상함수의 구성 [1) 2)]

MDP는 매 step에 스칼라 보상 하나를 받지만, 그 값은 아래 10개 항의 가중합이다.

$$r_t = max(0, \Delta t \sum_{i=1}^{10} w_i f_{i,t}), \qquad \Delta t = 0.02\,s$$

항	의도 / 정의 요약	설정 계수
평면 선속도 추종	평면 명령 속도와 실제 속도의 오차를 지수 보상으로 변환	+1.0
yaw 각속도 추종	명령 yaw rate와 실제 yaw rate의 오차를 지수 보상으로 변환	+0.5
수직 속도	몸체 수직 속도의 제곱	−2.0
roll·pitch 각속도	몸체 roll·pitch 각속도 제곱합	−0.05
토크	12개 관절에 적용된 토크의 제곱합	-2×10^{-4}
관절 가속도	관절 속도 차분 / policy dt의 제곱합	-2.5×10^{-7}
행동 변화	현재·직전 행동 차이의 제곱합	−0.01
충돌	thigh·calf의 임계값 초과 접촉 개수	−1.0
관절 위치 한계	soft joint limit를 벗어난 각도량 합	−10.0
발 체공 시간	착지 시 체공 시간 − 0.5초; 이동 명령 조건에서만 적용	+1.0

1) Saved JT resolved_config.json: environment.rewards. 2) legged_robot.py: compute_reward / _prepare_reward_function.

13 | 추종 목표의 보상 표현 [1) 2)]

속도 오차를 지수 보상으로 바꿔 정확한 추종을 유도한다. 아래 예시는 횡속도 오차0·선속도 항 계수1·dt0.02초 조건이다.

$$f_{lin,t} = exp(\frac{-\|v_{xy,t}^{cmd} - v_{xy,t}\|^2}{0.25})$$

$$f_{yaw,t} = exp(\frac{-(\omega_{z,t}^{cmd} - \omega_{z,t})^2}{0.25})$$

전진 속도 예시	추종 항의 값	한 step 선속도 보상 기여
명령 0.5 / 실제 0.5 m/s	1.000	0.0200
명령 0.5 / 실제 0.4 m/s	약 0.961	약 0.0192
명령 0.5 / 실제 0.0 m/s	약 0.368	약 0.0074

1) legged_robot.py: _reward_tracking_lin_vel / _reward_tracking_ang_vel. 2) JT saved config: tracking_sigma=0.25; P5 evaluation protocol.

14 | Teacher–Student의 학습 목적 [1) 2) 3)]

고장 정보 없이 제어할 Student를 학습하기 위해 Teacher의 물리정보를 활용한다. 이제 이 제어 문제를 푸는 학습 방법을 설명한다.

단계	이유	프로젝트에서 하는 일
1 · Teacher 기준	마찰·출력 저하 같은 숨은 조건을 알면 상황에 맞는 행동을 배우기 쉽다.	시뮬레이터 물리정보를 8D 특징으로 압축 해당 특징을 쓰는 보행 정책을 먼저 학습
2 · Student 추정	평가 정책에 정확한 고장 관절과 열화율을 알려 주지 않는다.	최근 1초의 관측·행동으로 8D 특징 추정 현재 관측과 함께 Actor에 입력
3 · 공동학습	Student의 추정 특징은 Teacher의 특징을 완벽하게 복제하지 못한다.	Student를 학습하면서 Actor도 갱신 추정 오차가 있는 입력으로 보행하도록 적응

1) Liu et al., Saving the Limping, arXiv:2210.00474v3, 2023. 2) Kumar et al., RMA: Rapid Motor Adaptation for Legged Robots, RSS 2021. 3) Local code: a1_official_wim_joint.py; joint_teacher_student_actor_critic.py.

15 | Teacher–Student 정보 비대칭 [1) 2)]

- [Saving the Limping/RMA 구조 계승] Teacher는 물리정보로, Student는 관측 이력으로 특징을 만든다.
- [프로젝트 구현] 물리정보 45D · 이력 50×48 → 각각 8D 특징으로 압축한다.

Teacher · privileged 45D	Student · history 50×48
• friction 1 • payload 1 • motor strength 12 • Kp/Kd scale 24 • clean body velocity 6 • failure flag 1	• 최근 50프레임의 몸체·명령·관절·행동 • 고장 관절·열화율은 직접 입력하지 않음

$$z_t^T = \mu(\xi_t) \in \mathrm{R}^8$$

$$z_t^S = \varphi(h_t) \in \mathrm{R}^8$$

현재 관측

235D

48D + terrain 187D

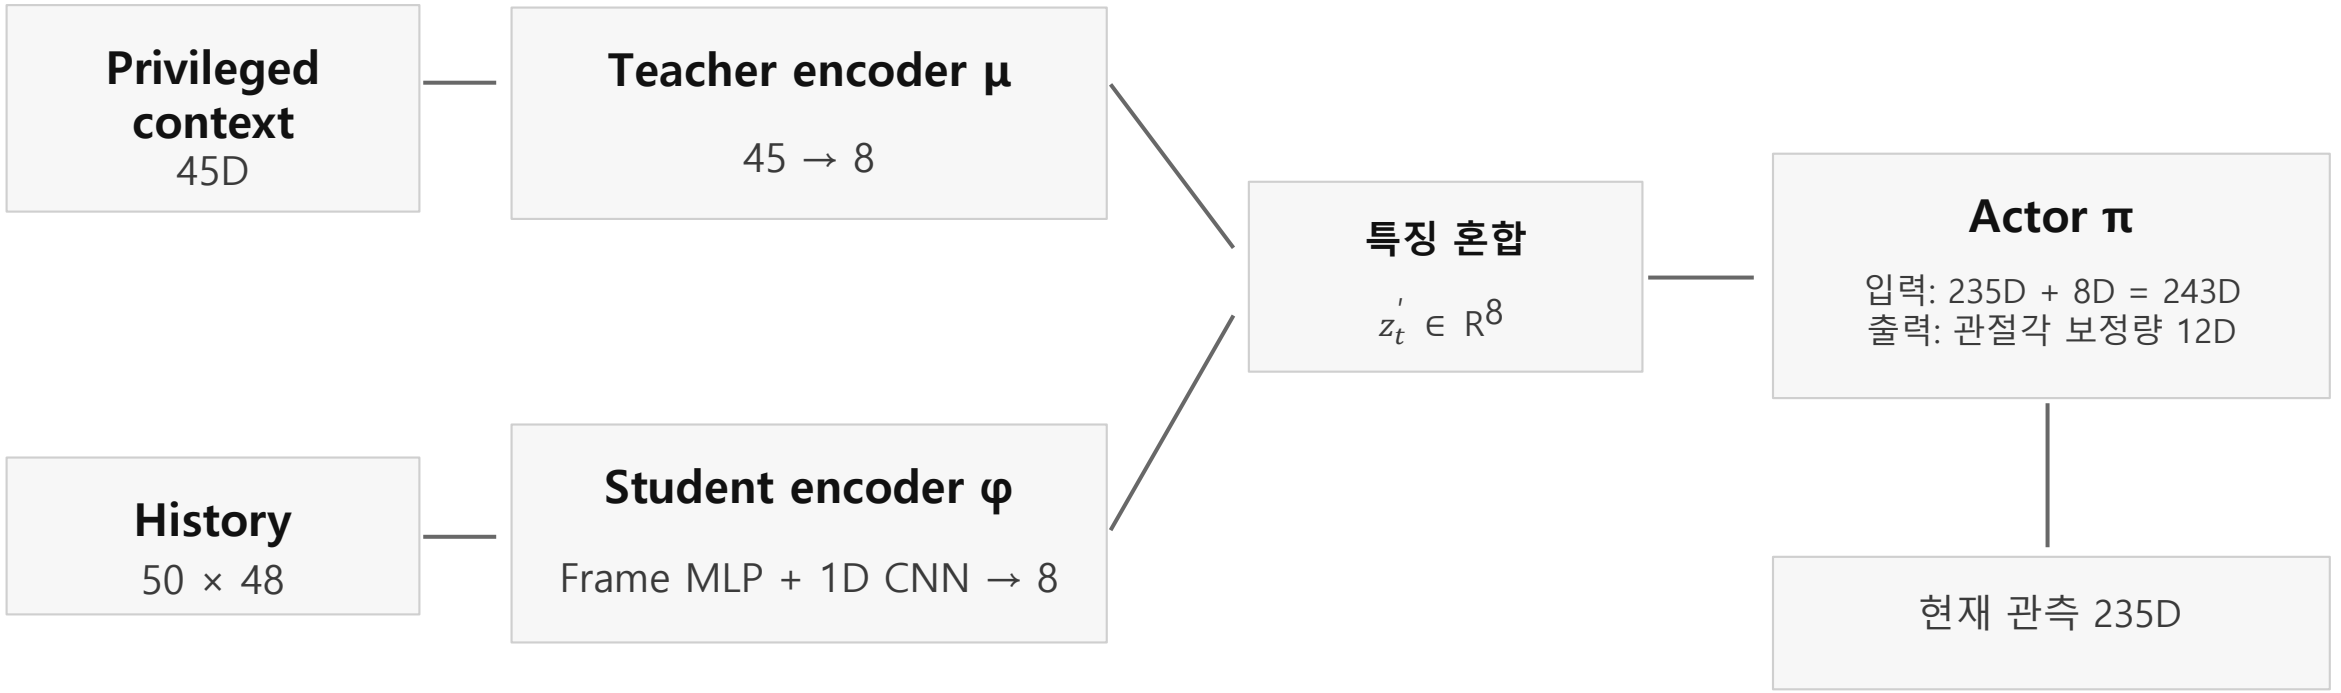
정책 입력

현재 관측 235D + latent 8D = 243D

1) Liu et al., Saving the Limping, arXiv:2210.00474v3, 2023. 2) Local code: a1_official_wim_teacher/schema.py; joint_schema.py.

16 | Teacher–Student 구조 [1) 2) 3)]

- [Saving the Limping 구조 계승] 두 encoder가 만든 8D 특징을 Actor가 사용한다.
- [학습·평가 구분] 학습은 Teacher·Student 특징을 혼합하고, Student 평가에서는 Student 특징만 사용한다.



학습: Teacher + Student → 혼합 8D
평가: Student → 8D (Teacher 경로 제외)

1) Liu et al., Saving the Limping, arXiv:2210.00474v3, 2023. 2) Kumar et al., RMA: Rapid Motor Adaptation for Legged Robots, RSS 2021..

17 | 특징 혼합과 Student 전환 [1) 2)]

- α는 8차원 특징의 혼합 비율
- Student의 추정 오차로 인한 급격한 입력 변화를 줄이면서, Actor도 그 특징으로 보행하도록 함께 학습한다.

$$z_t^{mix} = (1-\alpha)z_t^T + \alpha z_t^S \in R^8$$

학습 단계	Teacher 특징 비중	Student 특징 비중	Actor가 받는 8D 특징
초기	100%	0%	Teacher 특징; Student는 모방 손실로 먼저 학습
중간	50%	50%	두 특징의 원소별 가중합; Actor도 이에 맞춰 갱신
후기	0%	100%	Student 특징; 행동 보상으로 Student·Actor 갱신

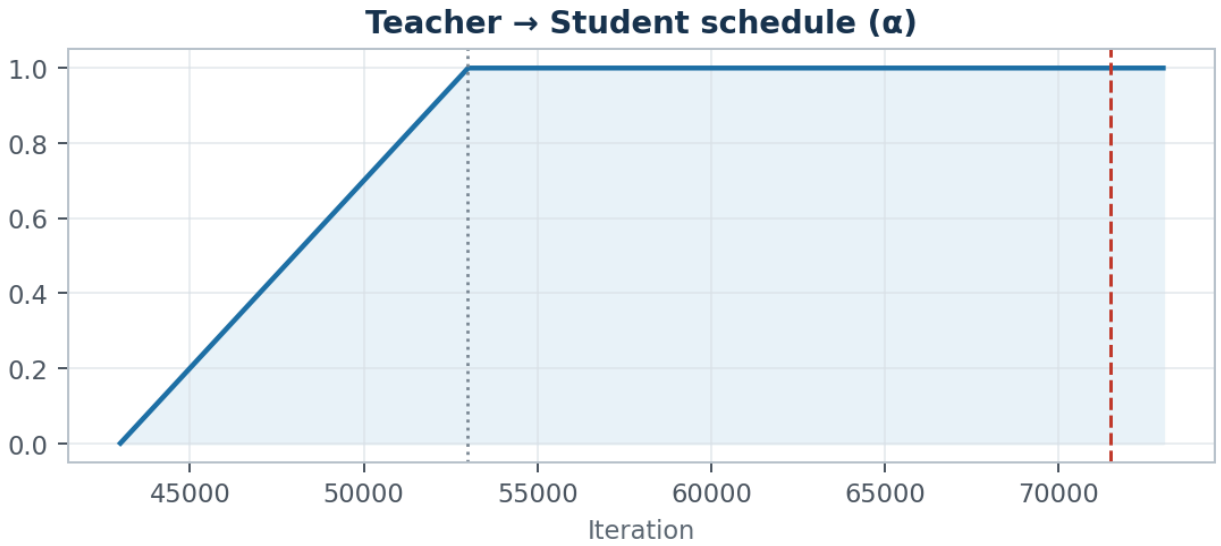
$$\alpha_k = clip((k - 43{,}000) / 10{,}000, 0, 1), \qquad \beta_k = 1 - \alpha_k$$

1) Liu et al., Saving the Limping, arXiv:2210.00474v3, 2023. 2) Local implementation: joint_teacher_student_actor_critic.py, fused_latent / set_training_iteration.

18 | 정책 입력과 관절 명령 [1) 2)]

02 학습 방법 · 목적 / 정보 / 구조 / 공동학습

- Actor 입력은 항상 현재 관측235D + 특징8D = 243D다. 관절 명령은 기준 자세에 각도 보정량을 더해 만든다.
- 0.25는 action scale이다. 도→라디안 변환 계수는 약0.01745이며, 두 값의 역할은 다르다.



현재 관측

235D

48D + terrain 187D

Student history

50×48

약 1초

$$q_t^{\text{des}} = q^{\text{default}} + 0.25\, a_t, \qquad a_t \in \mathrm{R}^{12}$$

정책 입력

현재 관측 235D + latent 8D = 243D

1) Project input: joint_schema.py; joint_teacher_student_actor_critic.py. 2) A1RoughCfg.control.action_scale=0.25; legged_robot.py:_compute_torques.

19 | 공동학습 목적함수와 갱신 대상 [1) 2)]

같은 rollout에서 PPO 보상 최적화와 특징 모방을 함께 수행한다. β는 모방 손실의 비중이며, α와 역할이 다르다.

$$L = L_{policy} + c_V L_{value} - c_H H(\pi) + \beta L_{adapt}$$

$$L_{adapt} = E_t[\|z_t^S - sg(z_t^T)\|_2], \qquad c_V = 1, \qquad c_H = 0.01$$

손실·경로	갱신되는 대상	의미
PPO policy / value	Actor · Critic · 혼합에 참여하는 encoder	행동의 누적 보상이 높아지도록 갱신
특징 모방	Student encoder; Teacher target은 detach	초기 Student 특징을 Teacher 특징에 가깝게 유도
Student-only 후기	Student encoder · Actor · Critic	Teacher 특징과 모방 손실의 기여가 모두 0

1) Liu et al., Saving the Limping, arXiv:2210.00474v3, 2023. 2) Local code: teacher_ppo.py:update; joint_teacher_student_actor_critic.py:adaptation_loss.

20 | 학습 절차와 정책 선택[1)]

02 학습 방법 · 정보 / 구조 / 공동학습 / 실행 절차

Teacher 기준 정책을 먼저 만든 뒤 Student 특징의 비중을 늘리며 공동학습한다. 최종 평가는 Student 경로만 사용한다.

단계	입력과 학습	산출물·확인 대상
1 · Teacher 준비	물리정보를 쓰는 encoder와 Actor·Critic을 PPO 학습	기준 정책 TF43000; 비교용 Teacher로 보존
2 · 공동학습 시작	TF43000에서 시작; Student 신규 초기화 43,000 → 53,000에서 Student 특징 비중 증가	모방 손실 + PPO로 encoder와 정책을 함께 갱신
3 · Student 중심 학습	53,000 이후 Student 특징으로 rollout·PPO 반복	Teacher 입력 없이 행동; JT71500 평가
4 · 같은 조건의 평가	Teacher / Student 경로를 분리해 추론	생존·회복·추종 비교; 학습 reward만으로 판정하지 않음

$$4{,}096 \times 24 = 98{,}304\ transitions\ /\ iteration$$

$$5\ epochs \times 4\ minibatches = 20\ updates$$

1) JT saved config / metrics.jsonl; teacher_runner.py; joint_teacher_student_actor_critic.py.

21 | 평가 지표와 선정 근거 [1) 2) 3)]

03 평가 설계 · 지표의 의미 / 출처 / 비교 조건

- 넘어지지 않는 것과 속도를 회복하는 것을 구분한다.

지표	계산 · 의미	선행연구와의 관계
20초 완주율	고장 후 20초를 끝까지 버틴 episode 비율	RMA: success rate의 평가 축 본 프로젝트: 고장 후 20초 완주로 정의
평균 생존 시간	고장 후 생존 시간의 평균; 20초로 나누어 정규화	Saving the Limping the Limping / RMA 와 같은 시간 기반 축
속도 · yaw RMSE	episode별 오차 RMSE를 구한 뒤 평균 얼마나 정확히 명령을 따라가는지 평가	Saving the Limping the Limping: 고장 전후 평균 전진 속도
안정 회복률	속도·yaw 허용 오차를 연속 1초 만족한 비율 이후 끝까지 안정했다는 뜻은 아님	프로젝트에서 추가한 지표

$$S_{complete} = \frac{1}{N}\sum_{i=1}^{N} 1[T_i = 20\ s]$$

$$S_{TTF} = \frac{E_i[T_i]}{20\ s}$$

$$RMSE_{vx} = \sqrt{\frac{1}{K}\sum_{t=1}^{K}(v_{x,t} - v_{x,t}^{cmd})^2}$$

$$|v_x - 0.5| \le 0.1\ m/s;\ |\omega_z| \le 0.2\ rad/s;\ 1\ s$$

N: episode 수 · T: 고장 후 생존 시간 · K: episode 내 유효 step 수. 보조: 전진 속도 적분, 접촉 중 발 미끄럼, 행동 한계 근처 비율.

1) Liu et al., Saving the Limping, §IV-D, Table I, Fig. 5 (arXiv:2210.00474v3). 2) Kumar et al., RMA, §V, Table II, Supplement S1 (RSS 2021). 3) 프로젝트 정의: P5 protocol / onset evaluator. 20초·1초 회복·RMSE 집계·보조 기준은 본 평가 설계.

22 | 평가 프로토콜 [1]

03 평가 설계 · 지표의 의미 / 출처 / 비교 조건

- Fixed는 시작부터 고장, onset은 보행 중 고장 발생을 뜻한다. 같은 명령·고장 조건에서 Teacher와 Student를 비교한다.
- 현재 onset 평가는 2 / 5 / 10초에 단일 관절의 출력을 저하시키고 이후20초를 관찰한다.

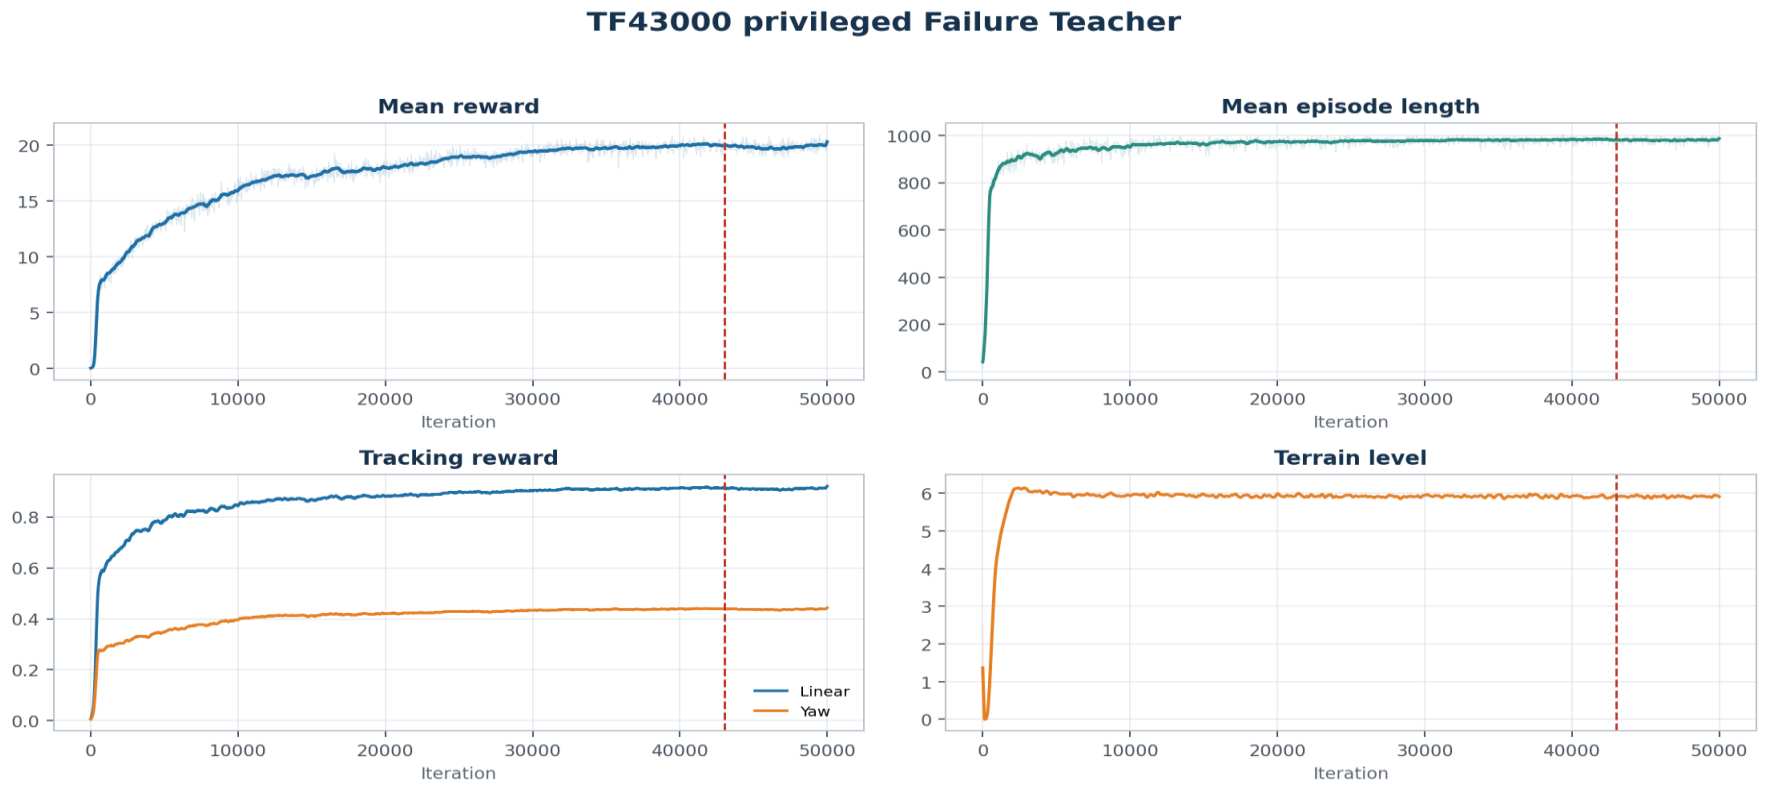
구분	Fixed failure	Random onset
고장 시점	episode 시작	2 / 5 / 10 s
열화율	0.0–1.0 · 6단계	0.2–1.0 · 5단계
관절	12	12
반복	3 seeds × 16	3 seeds × 16
episodes/model	3,456	8,640
horizon	20 s	고장 후 20 s

1) Local result: docs/results/p5-tf43000-vs-jt71500.md.

23 | TF43000 학습 결과 [1)]

TRAINING RESULT

- 고장 환경에서 학습한 Teacher의 reward·episode 길이·추종 보상·지형 난도 추이를 확인한다.



201-iteration moving average; red dashed line = selected checkpoint

Reward · 직전 201회 평균

19.94

Episode · 직전 201회 평균

980.6

max ≈ 1,000

Terrain level

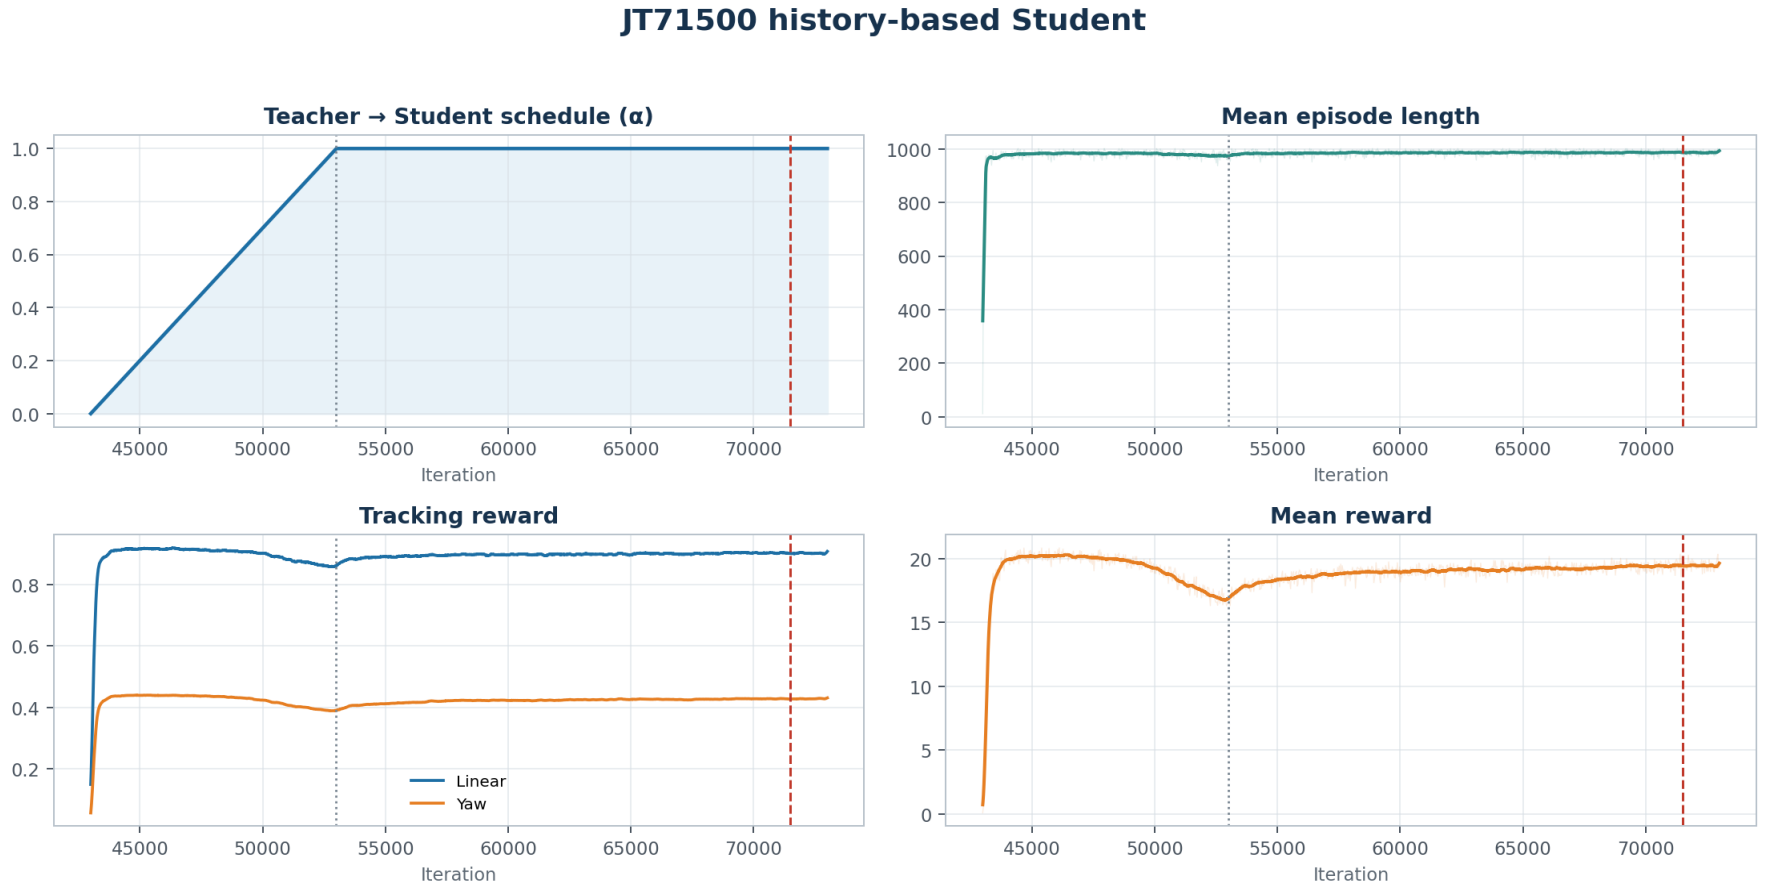
5.94

Selected checkpoint · 43,000

24 | JT71500 학습 결과 [1)]

TRAINING RESULT

- 43,000에서 Teacher로 초기화하고, 53,000부터 Student 특징만 사용한다. 71,500은 별도 평가로 선택.



Reward · 직전 201회 평균

19.46

Episode · 직전 201회 평균

988.6

Student-only

Fusion α

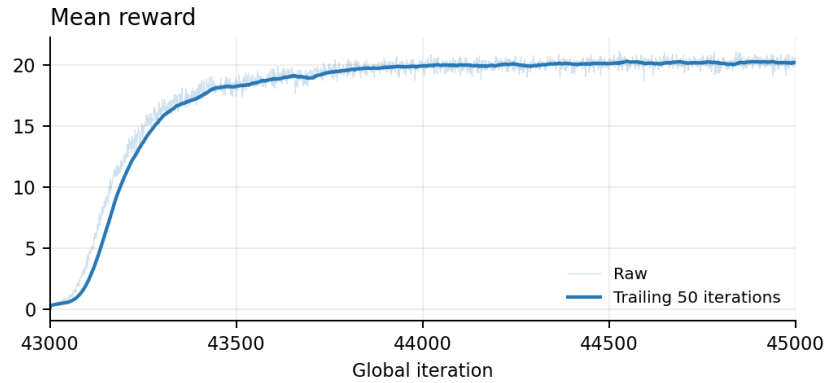
1.0

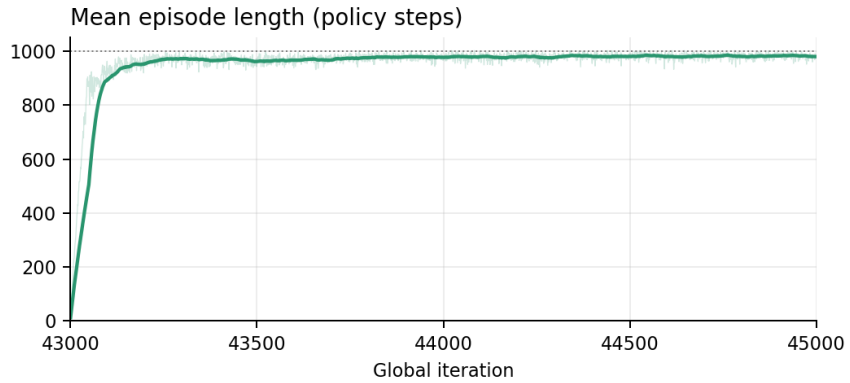
Selected checkpoint · 71,500

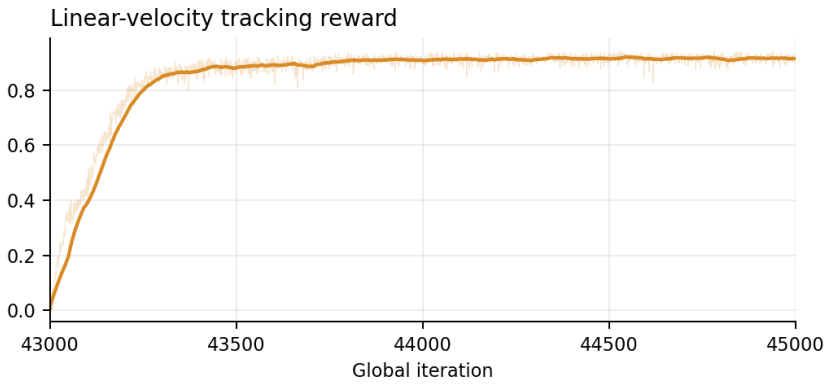
25 | 공동학습 초기 구간

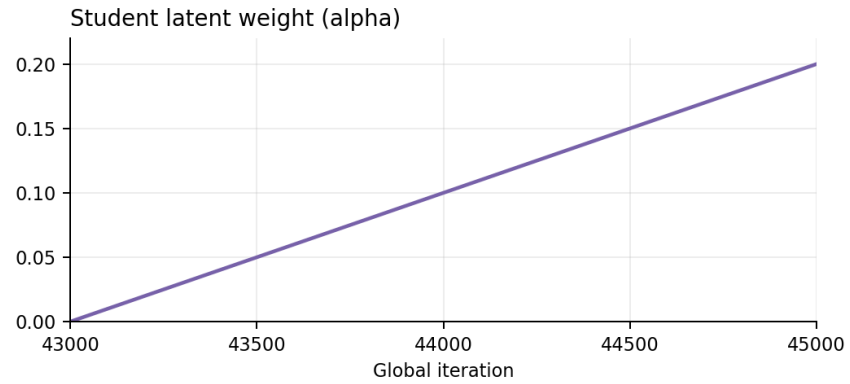
TRAINING RESULT

- 초기 reward 상승은 Teacher가 80–100% 혼합된 정책의 결과다. Student 단독 성능은 별도 평가로 확인한다.









초기 구간 해석

43,000 → 45,000
Student 비중 0 → 0.2
Teacher 비중 1 → 0.8

Student 단독 회복률

JT45000: 38.82%
JT71500: 81.66%
동일 onset 조건 별도 평가

26 | 최종 정량 결과 [1)]

EVALUATION RESULT

- 동일 평가 조건에서 Student의 생존율은 유사하지만, 회복률과 속도·yaw 추종 성능은 Teacher보다 낮다.
- On Set : 고장이 발생하기 시작하는 시점.

지표	TF43000	JT71500	차이
Fixed survival ↑	95.37%	**95.63%**	+0.26%p
Fixed 완전 상실 생존율 ↑	88.37%	**90.10%**	+1.74%p
Onset survival ↑	94.20%	**95.01%**	+0.81%p
Onset recovery ↑	**90.09%**	81.66%	−8.44%p
Onset 완전 상실 회복률 ↑	**65.28%**	45.89%	−19.39%p
Onset 전진 속도 RMSE ↓	**0.0770**	0.0961	+0.0191 m/s
Onset yaw RMSE ↓	**0.1044**	0.1346	+0.0302 rad/s
Onset foot slip ↓	0.0826	**0.0720**	−0.0106 m/s

해석

완전 출력 상실
회복률
Teacher 65.28%
Student 45.89%

작은 생존율 차이는
통계적 우월성으로 해석하지 않음

27 | 선행연구 결과와 비교 범위 [1) 2) 3) 4)]

RESULT · 선행연구 참고치와 동일 조건 비교의 구분

- 논문 수치는 평가의 참고 기준이다.
- 미세하게 다른 부분이 존재(지형, 고장 조건 등), 정량 평가 지표 완전 동일 X

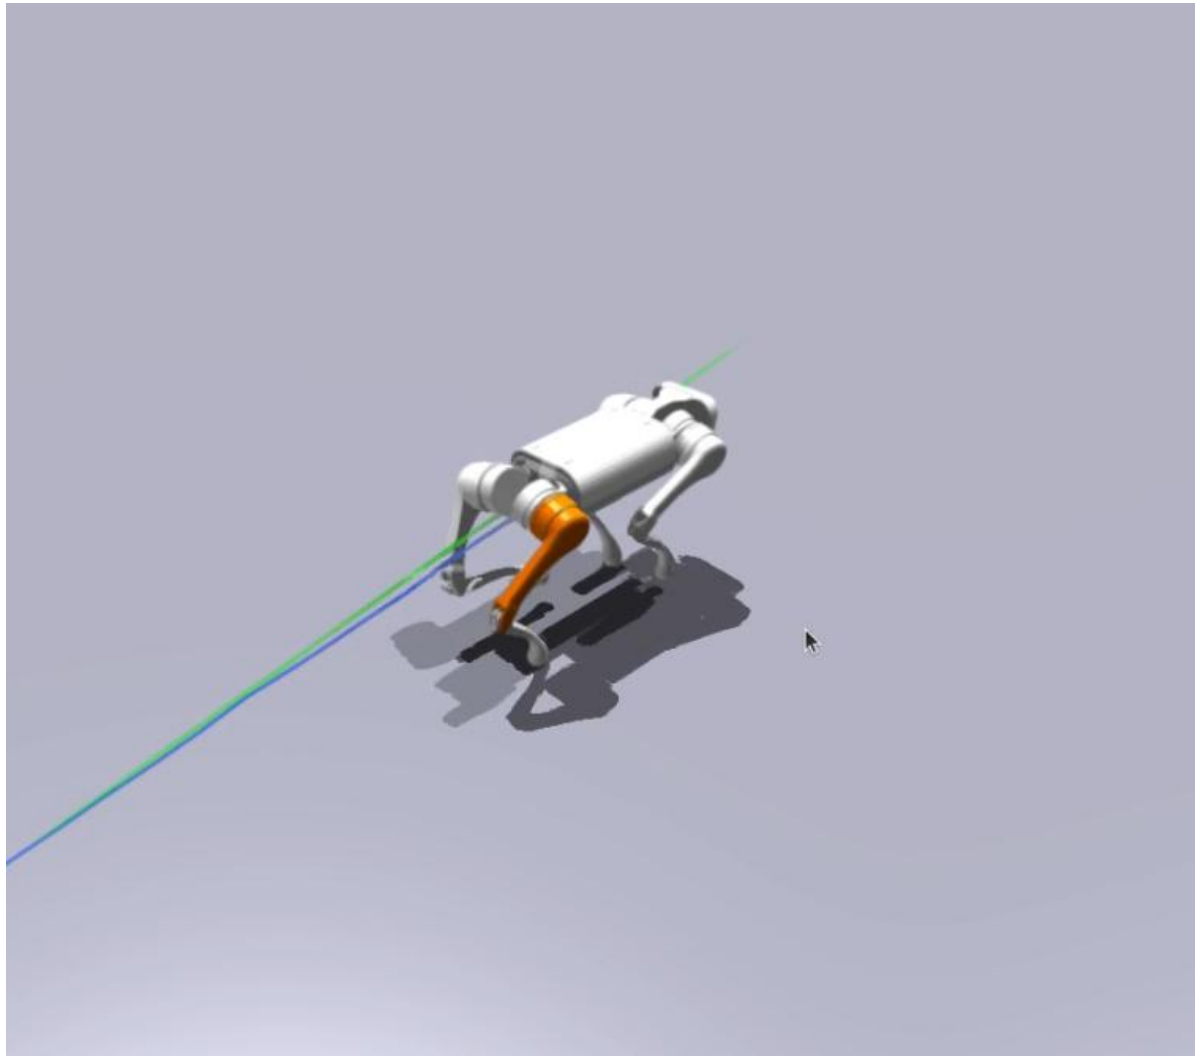
연구·조건	해당 논문 결과	Ours 와 비교
Saving the Limping · 단일 관절 잠금 전진 명령 0.5 m/s 고장 후 최대 20 s	고장 후 평균 전진 속도 0.47 m/s 정규화 평균 생존 시간 56.5% = 평균 11.30 s (All terrain)	출력 저하 평가: 평균 생존 19.44 s (97.19%) 20초 완주율 95.01%; 전진 RMSE 0.0961 m/s
RMA · 물리조건 변화 질량·마찰·모터 강도 등	성공률 73.5%; 정규화 TTF 0.85 Expert: 76.2%; TTF 0.86	Ours : 완주95.01%; 정규화 생존97.19% RMA 수치보다 높지만 과제·고장 조건이 다름
동일 조건의 방법 비교	확보: TF43000 ↔ JT71500 미확보: 분리학습 Student ↔ 공동학습 Student	공동학습 효과를 주장하려면 같은 출력 저하 환경의 분리학습 기준선 필요

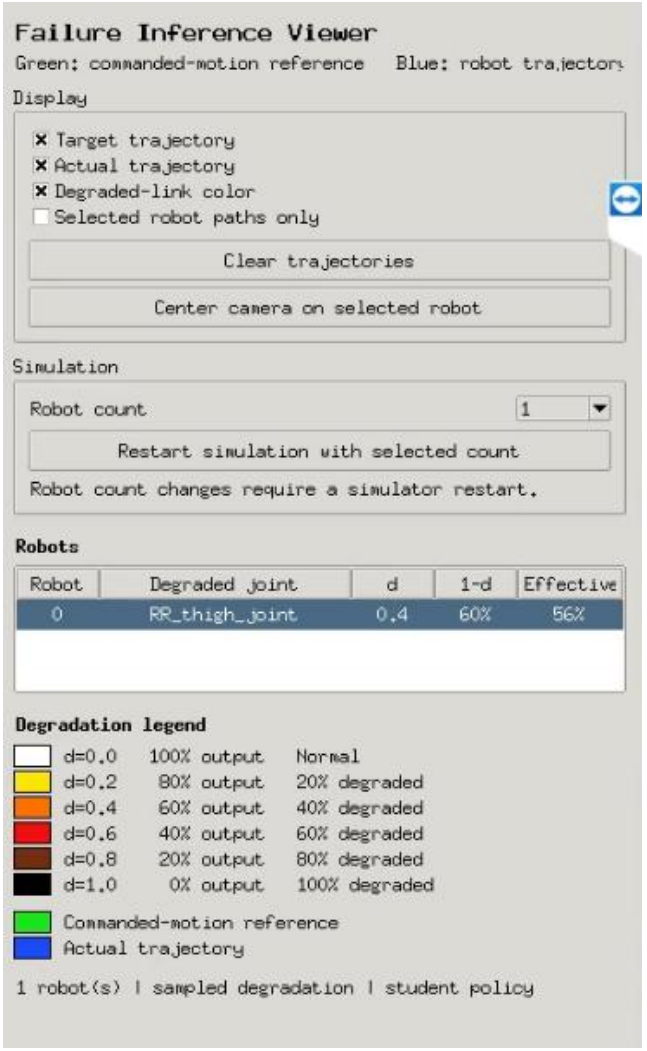
1) Liu et al., Saving the Limping, §IV-D, Table I, Fig. 5 (arXiv:2210.00474v3). 2) Kumar et al., RMA, §V, Table II, Supplement S1 (RSS 2021). 3) Wu et al., ADAPT, §5.1, Fig. 3, Appendix B (DAI 2023). 4) P5 canonical onset JSONL; docs/results/p5-tf43000-vs-jt71500.md.

28 | 결과 영상

EVALUATION RESULT

- TF43000
- JT43000
- JT43500
- JT71500





29 | 정량 결과의 의미 [1]

EVALUATION RESULT

- Onset : 고장 시점 랜덤 (0.0~ 10.0초 사이)
- 생존율 (survival) : 20초 에피소드 간 몸체 접촉 없음. 몸체 지면 접촉 시 에피소드 종료.
- 회복률(recovery) : 회복률은 고장 발생 후 전진 속도 오차가 ±0.1 m/s 이내, yaw 각속도가 ±0.2 rad/s 이내인 상태를 1초 연속 유지

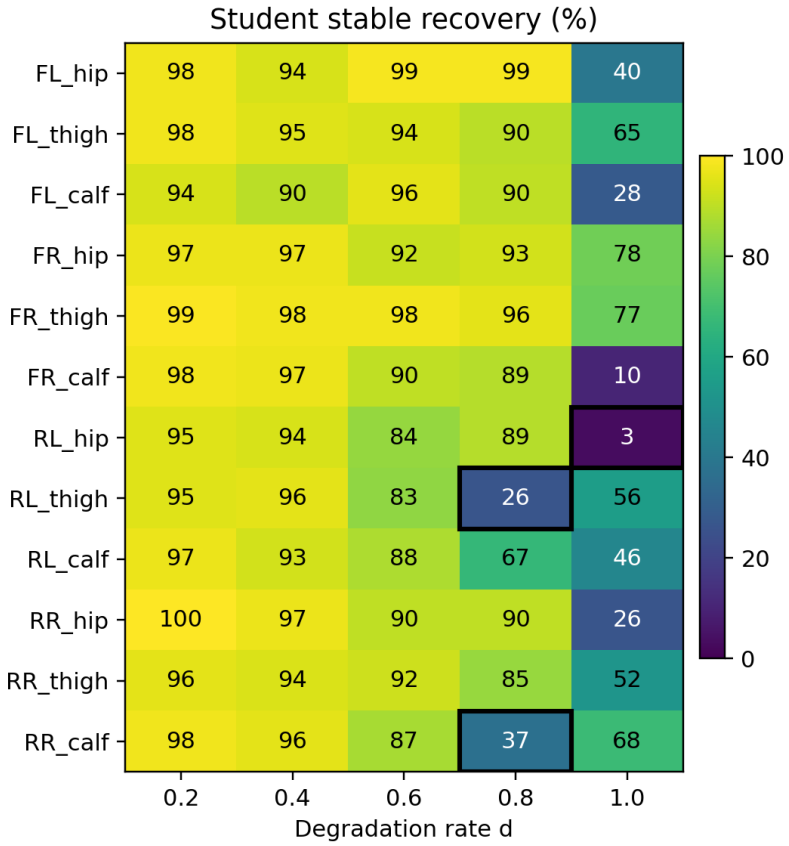
Onset survival	Stable recovery	Forward RMSE	Forward progress
95.01%	**81.66%**	**0.0961 m/s**	**9.12 / 10 m**
100회 중 약 95회가 고장 후 20초를 완주	약 82%가 1초 안정 구간 달성	에피소드별 RMSE의 평균 명령 속도 대비 19.2%	이상적 거리의 91.2%를 고장 후 20초 동안 전진

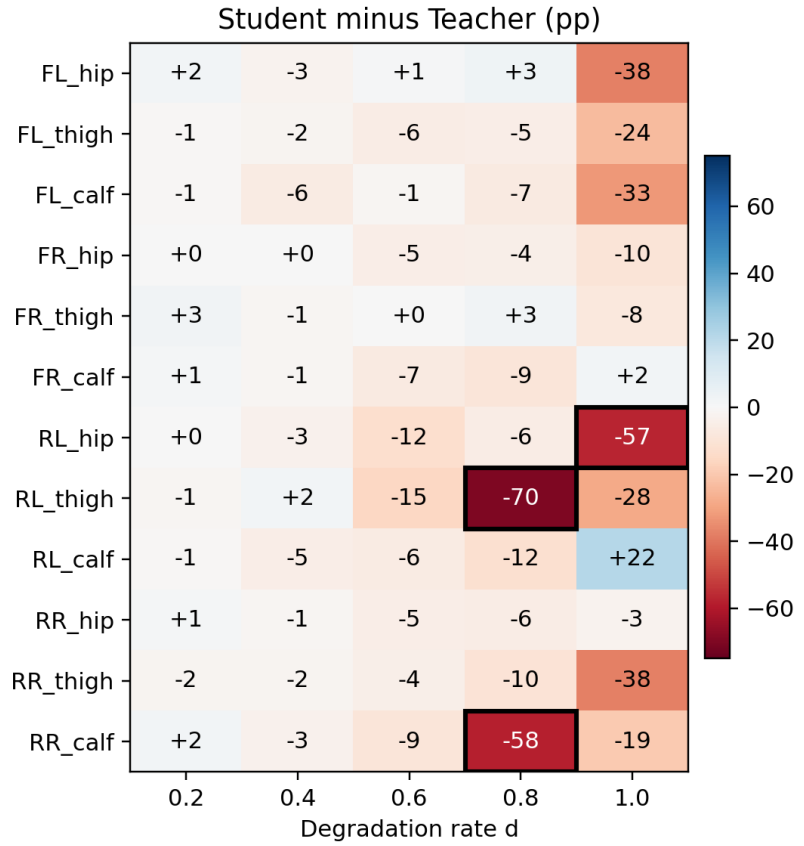
1) Local result: docs/results/p5-tf43000-vs-jt71500.md.

30 | 고장 조건별 안정 회복의 한계 [1) 2)]

RESULT · 평균 성능에서 드러나지 않는 조건별 회복 실패

- Student / Teacher 의 회복률 비교
- 완전 출력 상실(d=1.0) 에서는 여러 관절의 회복률이 낮다. 특정 관절 하나의 보편적 취약성보다, 생존과 회복의 차이를 확인한다.





조건	Teacher	Student
RL hip · 완전상실	60.42%	3.47%
RL thigh · 80% 저하	96.53%	26.39%
RR calf · 80% 저하	95.14%	36.81%

RL hip 완전상실: 생존 92.36%, 회복 3.47%. 넘어지지 않아도 속도·yaw 기준을 회복하지 못한다.

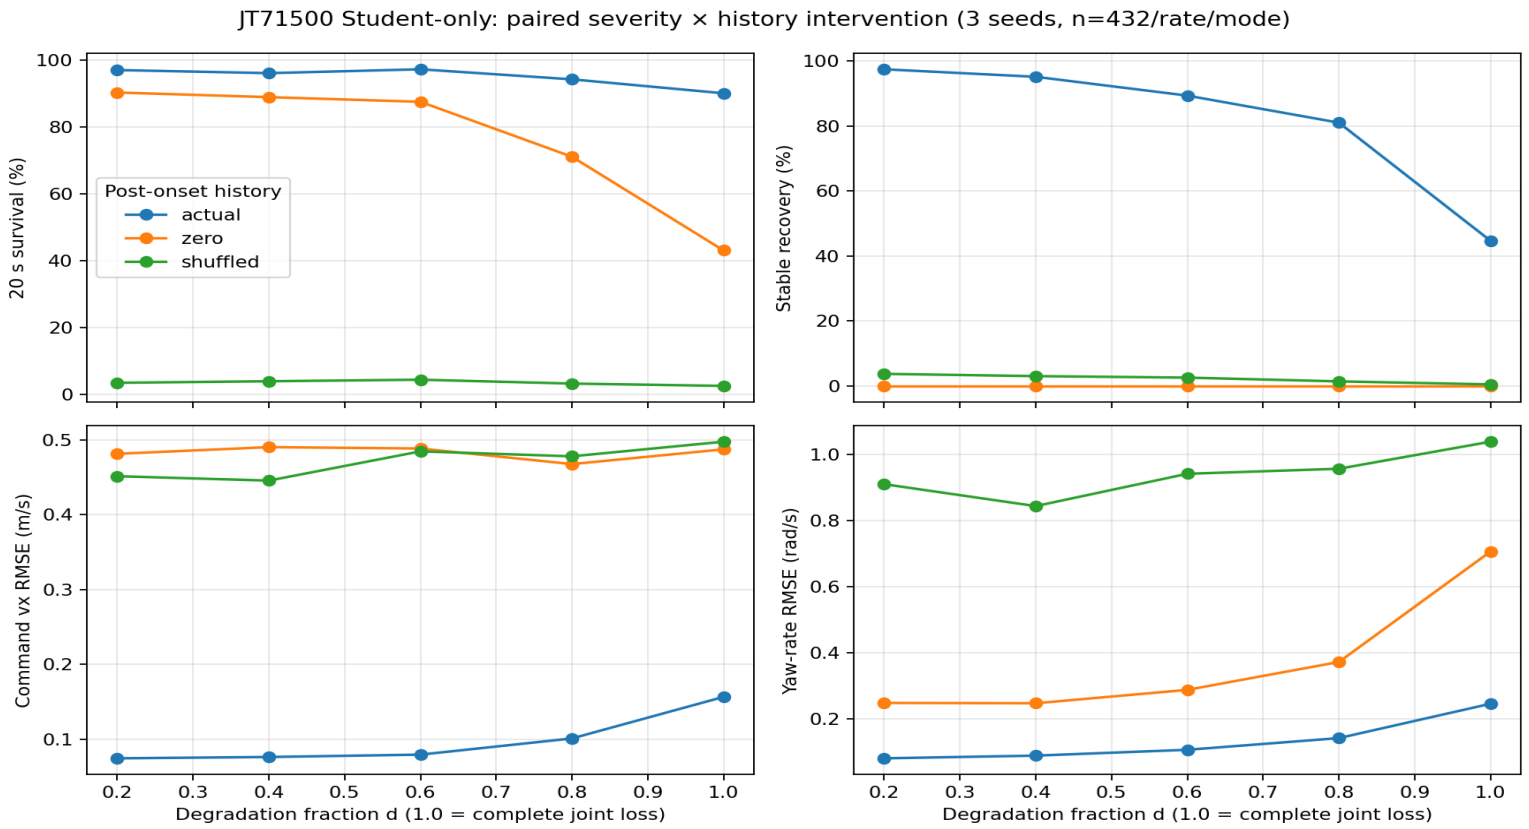
좌우·열화율별 차이가 있어, calf만의 문제로 일반화하지 않는다.

1) P5 canonical onset JSONL; docs/results/p5-tf43000-vs-jt71500.md. 2) 각 칸: 3 seeds × 3 onset times × 16 = 144 episodes. 검은 테두리는 상세 분석 대상이며 유의성 표시는 아님.

31 | History 의존성 [1)]

ABLATION

- 고장 후 관측 이력을 0으로 만들거나 로봇 간 섞어, Student 성능이 해당 입력에 의존하는지 확인한다.



History	생존	회복
Actual	94.91%	81.53%
Zero	76.16%	0%
Shuffled	3.52%	2.22%

해석

- 입력을 바꾸면 성능 저하
- Student 가 history 를 사용함을 알 수 있다

32 | 진행 현황과 한계 [1) 2)]

PROJECT STATUS

- 학습과 현재 조건의 비교 평가는 완료.
- 취약 조건의 원인과 새로운 조건에서의 성능 검증 필요.

완료	현재 한계	다음 단계
• 단일 관절 출력 저하 환경 • Teacher·Student 학습 완료 • 고정/주행 중 고장 비교 완료 • 관절별·이력 입력 분석 완료	• 고장 모델은 토크 비율 감소 • 새 명령 속도·지형 미검증 • 독립 재학습 반복 부족 • 완전 상실 회복률 45.89% • 8차원 특징의 물리 의미 미검증	• 취약 관절의 속도·yaw 시간 분석 • 미평가 명령 속도·지형 평가 • 다른 seed로 재학습 후 비교 • 고정 Teacher 방식과 비교 검토

33 | 결론 [1) 2)]

CONCLUSION

01	환경	Isaac Gym에 random-onset 단일 관절 출력 저하 환경을 구성
02	방법	Privileged Teacher와 history Student를 공동 학습
03	결과	0.5 m/s 명령에서 95.01% 생존, 9.12/10 m 전진
04	개선 사항	완전 출력 상실 onset 회복률은 45.89%로 추가 개선 필요

34 | Appendix A1 · PPO 설정

APPENDIX

매 iteration 새 rollout을 수집하고 PPO로 갱신한다. 아래는 해당 학습에서 사용한 설정이다.

파라미터	값	파라미터	값
γ	0.99	λ_{GAE}	0.95
PPO clip	0.2	Entropy coef.	0.01
Epochs / rollout	5	Minibatches / epoch	4
Steps/env	24	Desired KL	0.01
Learning rate	Adaptive	Max grad norm	1.0
Actor hidden	512–256–128	Latent	8D

$$L_{\text{PPO}}(\theta) = \mathbb{E}_t[\, min(r_t(\theta)\,\hat{A}_t, clip(r_t(\theta), 1-\varepsilon, 1+\varepsilon)\,\hat{A}_t)\,]$$

35 | Appendix A2 · PPO 학습 단위

APPENDIX

새 데이터를 수집하는 단계와 같은 데이터를 반복 사용하는 단계를 구분하면 학습량을 계산할 수 있다.

순서	단위	이 학습에서의 의미
1	Transition	환경 하나에서 행동 1회 → 다음 상태·보상·종료 신호를 얻은 기록
2	Rollout batch	4,096개 환경 × 24 policy steps = 새 transition 98,304개
3	Minibatch	rollout batch를 4묶음으로 분할 → 한 묶음 24,576개
4	Optimizer update	minibatch 하나로 손실·gradient를 계산하고 파라미터 1회 갱신
5	Epoch	현재 rollout batch의 4개 minibatch를 모두 학습 → update 4회
6	Iteration	새 rollout 수집 + 같은 batch를 5 epochs 학습 → update 20회

36 | Appendix A3 · 71500의 학습량 [1]

APPENDIX

71500은 checkpoint의 global iteration 번호다. Transition 수나 epoch 수를 뜻하지 않는다.

항목	계산 및 의미
초기화	TF43000의 네트워크로 시작 · Student 신규 초기화 · optimizer 재설정
번호 차이	71,500 − 43,000 = 28,500
실제 완료 횟수	43,000번 반복 직후에도 저장 → 43,000~71,500 포함 28,501회
새 transitions	28,501 × 98,304 = 2,801,762,304
PPO epochs 합계	28,501 × 5 = 142,505
Optimizer updates	28,501 × 5 × 4 = 570,020
선택 기준	fixed/onset 생존·회복·추종의 균형 · 최종 번호나 학습 reward만으로 선택하지 않음

1) JT metrics.jsonl: iterations 43000–71500 inclusive; teacher_runner.py checkpoint timing.

37 | Appendix A4 · 학습 시간과 반복 횟수 [1) 2)]

APPENDIX

5 epochs는 전체 학습이 5번이라는 뜻이 아니다. 매 iteration 새로 수집한 데이터 묶음을 5회 반복 학습한다.

구분	확인된 값	의미
현재 rollout 재사용	$5\ epochs \times 4\ minibatches = 20\ updates$	같은 데이터 98,304개를 5회 사용한 뒤 새로 수집
JT 구간 누적	28,501 iterations / 142,505 batch epochs	같은 고정 데이터셋의 142,505 epochs는 아님
파라미터 갱신	570,020 optimizer updates	로그의 completed_updates를 합산한 값
실제 경과 시간	49,999.59 s ≈ 13시간 53분	첫 iteration 완료 로그 → 71500 완료 로그
수집·학습 실행 시간	49,741.70 s ≈ 13시간 49분	iteration_time 합계; 경과 시간과 구분
5회 재사용의 이유	PPO는 현재 정책에서 얻은 데이터로 갱신	오래된 rollout을 과도하게 반복하면 정책 분포가 달라짐 5는 이번 학습 설정이며 최적 횟수라는 주장은 아님

1) JT metrics.jsonl: 43000–71500; 28,501 unique iterations. 2) Perf/iteration_time 합계와 wall_time_unix 차이. Teacher 사전학습·평가 시간 제외.

38 | Appendix A5 · 보상 구현과 해석 [1]

APPENDIX

계수뿐 아니라 각 항의 원시 함수, clipping 순서, 종료 처리를 확인해야 학습 목적을 재현할 수 있다.

항목	구현 기준과 해석
안정·제어 항	수직속도 제곱, roll·pitch 각속도 제곱합, 적용 토크 제곱합, 관절 가속도 제곱합
행동 변화	현재 행동과 직전 행동의 차이 제곱합; 이 항은 dt로 나눈 시간 미분이 아님
충돌	thigh·calf 접촉력 norm이 0.1 N을 넘는 body 개수; 몸체 접촉 종료와 별도
관절 위치 한계	허용 범위의 90%로 좁힌 soft limit 밖의 각도량 합; 제곱 벌점이 아님
체공 시간	필터링한 첫 착지에서 체공 시간 − 0.5 s; 평면 명령 크기 0.1 m/s 초과일 때만 적용
합산·종료	각 계수 × 0.02 s → 10개 항 합산 → 0 이상 clip; 종료 reward 계수는 0
평가와의 관계	20초 생존·1초 안정 회복·RMSE는 별도 평가 지표; latent 모방은 optimizer 손실

1) Local code: legged_robot.py:816–893; JT resolved_config.json.

39 | Appendix A6 · Saving the Limping 결과[1) 2)]

APPENDIX · 논문이 보고한 성능과 직관적 의미

목표 0.5 m/s에서 고장 대응 정책은 관절 잠금 후 속도를 더 잘 유지하고 더 오래 버텼다.
아래 생존 값은 평균 생존 시간이며, 20초를 완주한 비율과는 다르다.

결과	일반 정책 BaseEnv	고장 대응 정책 FailureEnv	숫자의 의미
고장 후 평균 전진 속도	0.42 m/s	0.47 m/s	0.05 m/s 개선 목표 속도 0.5 m/s에 더 가까움
목표 속도 대비 평균 속도	84%	94%	속도 평균으로 보면 목표의 약94%를 유지
고장 후 평균 생존 시간	8.94 s (최대20초의44.7%)	11.30 s (최대20초의56.5%)	평균 2.36초 더 생존 완주율이56.5%라는 뜻은 아님

1) Liu et al., Saving the Limping, Table I (All terrain), arXiv:2210.00474v3. 2) 속도/목표 비율과 생존 시간의 초 단위는 원문 값으로 환산.

40 | Appendix A7 · RMA 결과 [1) 2)]

APPENDIX · 논문이 보고한 성능과 직관적 의미

RMA는 일반 강건 정책보다 성공률이 높고, 실제 물리정보(GT)를 제공받는 Expert의 성능에 가까웠다.

결과	일반 강건 정책 Robust	RMA	물리정보 기준 Expert	숫자의 의미
과제 성공률	62.4%	73.5%	76.2%	Robust보다11.1%p 높음 Expert와는2.7%p 차이
평균 생존 시간 최대시간 대비	80%	85%	86%	허용시간의 평균 85%를 생존 Expert의 86%에 가까움
평균 이동거리	1.13 m	1.34 m	1.35 m	Robust보다 0.21m 더전진 Expert와는 0.01m 차이

1) Kumar et al., RMA, Table II: simulation testing results; §V / Supplement S1. 2) 성공률 차이는 percentage points. 정규화 생존은 원문의 TTF를 백분율로 표현.

41 | Appendix A8 · ADAPT 결과 [1) 2)]

APPENDIX · 논문이 보고한 성능과 직관적 의미

앞다리 calf의 완전 출력 상실 사례에서 ADAPT는 일반 정책보다 높은 점수를 얻고 Teacher에 가까웠다.
점수는 논문 고유의 누적 reward이며, 속도나 생존율을 뜻하지 않는다.

완전 출력 상실 조건	일반 정책 Single Policy	MLP	ADAPT	Teacher
왼쪽 앞 calf · LFC	24.22	25.92	26.44	26.54
오른쪽 앞 calf · RFC	25.82	25.99	26.42	26.50

1) Wu et al., ADAPT, Fig.3 printed values; DAI 2023. 2) LFC: 왼쪽 앞 calf / RFC: 오른쪽 앞 calf. 아래는 두 조건의 예시이며 전체 평균이 아님.

42 | Appendix A9 · 평가 지표의 집계 [1) 2)]

APPENDIX

본문은 생존·회복·추종을 중심으로 설명한다. 아래는 보조 지표와 episode 평균의 정확한 계산 기준이다.

$$e_i = \sqrt{\frac{\sum_{t=1}^{K_i}\left(v_{x,i,t} - v_{x,i,t}^{cmd}\right)^2}{max(1, K_i)}}, \qquad RMSE\ reported = \frac{1}{N}\sum_{i=1}^{N} e_i$$

보조 지표	계산	해석·출처
전진 진행량	$D_i = \sum_{t=1}^{K_i} v_{x,i,t}\,\Delta t$	몸체 전진 속도의 적분; 명령0.5m/s·20초면 이상적10m RMA 거리 평가 축과 관련되지만 세계좌표 이동거리/경로오차는 아님
접촉 중 발 미끄럼	발 수직 접촉력 > 1 N인 발들의 수평속도 norm을 평균; 이후 유효 step 평균	낮을수록 발 미끄럼이 적음 현재 평가 코드의 보조 진단 정의
행동 한계 근처 비율	$mean_{j,t}(1[\lvert a_{j,t}\rvert \geq 0.98])$	낮을수록 정규화 행동 한계 근처가 적음 0.98 임계값은 프로젝트 진단 기준

K: onset 후 유효 step 수. 고장 전 종료는 K=0이며 현재 코드의 연속 지표는0으로 기록된다.
따라서 RMSE를 생존·회복 실패와 함께 해석한다. episode별 평균은 모든 step을 합친 RMSE와 다르다.

1) P5 protocol; evaluate_teacher243_failure_onset.py: post mask / post_count / metric accumulation. 2) Saved result summary: episode별 지표 평균. 세계좌표 기준 경로의 오차를 측정한 것이 아님.

43 | Appendix A10 · Encoder 구조[1) 2) 3)]

APPENDIX

Teacher의 은닉층은 Saving the Limping, Student의 시간 CNN은 RMA를 따른다.
입력 차원과 프레임 임베딩은 프로젝트 구성이다. 가중치는 보행 보상과 특징 모방 손실로 학습한다.

$$z_t^T = \mu(\xi_t) \in R^8 \qquad z_t^S = \varphi(h_t) \in R^8$$

구성	현재 구현	논문 근거와 프로젝트 변경
Teacher encoder	45 → 512 → 256 → 128 → 8 은닉층 ELU	은닉층·8D 출력: Saving the Limping 명시 45D 입력: 프로젝트의 물리정보 구성
Student 이력	50프레임 × 48D 현재 주기에서 약1초	50프레임: Saving the Limping / RMA 48D 프레임: WIM 코드의 관측 구성
프레임 임베딩	Linear 48 → 32 + ELU	프로젝트 변형: 현재는 Linear 1층 RMA 원문은 프레임 임베딩에 2층 MLP
시간 방향 CNN	32채널 · 3층 (kernel,stride): (8,4), (5,1), (5,1)	RMA §IV-B와 같은 채널·커널·stride 시간 길이50 → 11 → 7 → 3
특징 출력	32 × 3 = 96 → Linear → 8	CNN 출력을 latent로 선형 투영하는 방식 계승 8개의 물리량을 직접 지정하는 방식은 아님

1) Saving the Limping §IV-A: Teacher MLP [512,256,128], ELU, latent8; history50 + 1D CNN. 2) RMA §IV-B: frame embedding MLP; Conv1d [32,32,8,4], [32,32,5,1], [32,32,5,1]. 3) Current implementation: joint_teacher_student_actor_critic.py:19–35,82–90; joint_schema.py.