4족 보행 로봇의 관절 토크 저하에 강건한 교사, 학생 기반 강화학습 보행 제어

Teacher–Student Reinforcement Learning for Robust Quadruped Locomotion under Joint Torque Degradation

요약 본 논문은 정상 상태와 단일 관절 토크 저하 상황에서 이동을 지속하는 관측 이력 기반 강화학습 보행 정책을 제안한다. 교사, 학생 공동학습으로 고장 정보를 직접 입력받지 않는 학생 정책을 학습한다. Isaac Gym의 Unitree A1 모델에서 정상학습 정책과 비교한 결과, 토크 저하율이 100%일 때 생존율은 37.2%p 높아지고 종료 전 경로 횡오차의 시행별 root mean square error (RMSE) 평균은 64.6% 감소하였다.

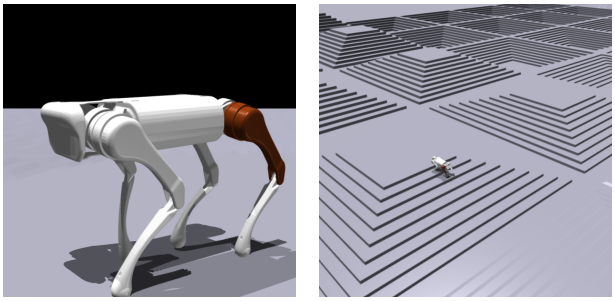
Abstract We propose a reinforcement learning locomotion policy that maintains balance, tracks commanded motion, and follows reference paths under nominal and single-joint torque degradation conditions. The policy combines current observations and history-based features through teacher–student joint training, without direct fault inputs. Policies trained with one seed each are compared in Isaac Gym using a Unitree A1 quadruped model on matched mixed-terrain tasks. Under full torque degradation, survival improved by 37.2 percentage points and mean pre-termination cross-track root mean square error decreased by 64.6% relative to the nominally trained policy.

Keywords: Quadrupedal locomotion, Joint torque degradation, Teacher–student learning, Joint learning

I. 서론

4족 보행 로봇은 발 디딤 위치와 다리의 움직임을 조절하여 계단을 오르내리고, 바퀴형 로봇의 이동이 제한되는 단차와 불규칙한 지형을 통과할 수 있다. 이러한 이동 능력을 구현하기 위해 강화학습을 활용한 보행 제어가 연구되고 있으며, 다양한 지면 조건에서 균형을 유지하고 이동 명령을 수행하는 정책이 개발되고 있다[1]. 그러나 안정적인 이동을 위해서는 지형 변화뿐 아니라 액추에이터의 노화나 손상에 따른 구동 성능의 변화도 고려해야 한다. 관절의 토크가 저하되면 몸체를 지지하고 추진하는 능력이 달라져, 정상 상태에서 학습한 정책으로는 보행을 유지하거나 요구된 속도와 방향을 따르기 어려울 수 있다. 따라서 관절의 토크가 저하되어도 균형을 유지하며 주어진 이동을 이어갈 수 있는 보행 정책이 필요하다.

본 논문에서는 정상 상태뿐 아니라 단일 관절의 토크가 저하된 상황에서도 이동을 지속할 수 있는 강화학습 기반 보행 정책을 제안한다. 단일 관절 토크 저하를 모델링하고, 교사, 학생 공동학습으로 고장 정보를 직접 입력받지 않는 관측 이력 기반 정책을 학습한다[2]. 정상학습 정책과 다양한 이동 명령 및 경로 추종 성능을 비교한다. 이를 통해 관절 토크 저하 상황에서 보행을 더 오래 유지하고 요구된 움직임을 더 정확하게 수행할 수 있음을 보인다.



(a) Unitree A1 (b) Isaac Gym 지형

그림 1. 로봇 모델과 시뮬레이션 환경

II. 시스템 모델

2.1 시뮬레이션 환경 및 제어 구조

Isaac Gym에서 4족 보행 로봇 Unitree A1을 모사한다[3]. 각 다리는 hip, thigh, calf로 구성되며, 전체 관절은 12개이다. 정책이 출력한 목표 관절 각도를 proportional-derivative (PD) 제어기가 토크로 변환한다. 다음 제어 시점에는 변화한 몸체와 관절 상태를 관측하여 새 목표 관절 각도를 출력한다[1]. 로봇과 지형은 그림 1, 제어 설정은 표 1과 같다. 12차원 행동 a_t는 기준 자세 q^0에 더할 관절 각도를 정하며, 0.25 rad는 행동 배율이다. 0.02 s마다 새 목표를 출력하고, 그 사이에는 목표를 유지한 채 0.005 s 간격으로 물리를 계산한다.

2.2 단일 관절 토크 저하 모델

관절 j의 목표 관절 각도로부터 PD 제어기가 생성하는 토크는 식 (1)과 같다. 관절 토크 저하는 토크 저하율 d_j에 따라

표 1. 로봇 및 제어 설정

Parameter	Value
Actuated joints	12 (3/leg)
Physics / policy interval	0.005 s / 0.02 s
Joint target	$q^{des} = q^0 + 0.25a_t$ (rad)
Nominal PD gains	$K_p = 20$ N·m/rad; $K_d = 0.5$ N·m·s/rad

출력을 $1 - d_j$배로 줄이는 방식으로 모델링한다[4]. 모터 강도 편차와 최대 허용 토크를 반영한 최종 출력은 식 (2)와 같다.

$$\tau_j^{PD} = K_p(q_j^{des} - q_j) - K_d\dot{q}_j, \tag{1}$$

$$\tau_j = \text{clip}\big(m_j(1 - d_j)\tau_j^{PD}, -\tau_j^{max}, \tau_j^{max}\big). \tag{2}$$

여기서 q_j^{des}, q_j, $\dot{q}_j$는 목표 관절 각도, 현재 관절 각도, 관절 각속도이며, K_p, K_d는 PD 이득이다. 식 (2)의 $m_j \in [0.9, 1.1]$은 명목 모터 강도의 $\pm 10\%$ 편차를, d_j는 관절별 토크 저하율을 나타낸다. τ_j^{max}는 최대 허용 토크이며, clip은 출력을 $\pm\tau_j^{max}$로 제한한다.

학습 시행마다 고장 관절 하나와 토크 저하율 $d_j \in \{0.0, 0.2, 0.4, 0.6, 0.8, 1.0\}$을 무작위로 선택한다. 시작 후 2~10 s 중 무작위 시점에 선택된 관절의 d_j를 0에서 선택한 값으로 바꾸고 종료까지 유지하며, 나머지 관절의 d_j는 0으로 유지한다. $d_j = 0.0$은 정상 상태이고, $d_j = 1.0$에서는 능동 토크가 0이 되지만 관절의 수동 운동은 가능하다.

III. 교사, 학생 공동학습 기반 보행 정책

3.1 관측 및 이력 표현

고장 정보를 직접 받지 않는 학생에게는 행동 이후의 운동 반응이 단서가 된다. 따라서 현재 관측과 최근 1 s의 관측 이력을 함께 사용한다. 현재 관측 o_t는 로봇, 명령 정보 $\tilde{o}_t$ 48차원과 지형 높이 187차원이다[1]. $\tilde{o}_t$에는 선속도, 각속도, 중력 방향, 속도 명령 각 3차원과 관절 각도 편차, 관절 각속도, 이전 행동 각 12차원이 포함된다. 각 관측의 기호, 단위, 차원은 표 2와 같다.

그림 2의 교사 인코더는 마찰계수 1차원, 추가 질량 1차원, 유효 모터 강도 12차원, PD 이득 24차원, 몸체 속도 6차원, 고장 표지 1차원으로 구성된 45차원 특권 물리 정보에서 8차원 교사 특징 z_t^T를 생성한다. 유효 모터 강도에는 관절별 토크 저하율이 반영된다. 교사 인코더는 은닉층 [512, 256, 128]과 exponential linear unit (ELU)를 갖는 multi-layer

표 2. 현재 관측의 구성

Component	Symbol	Unit	Dim.
Body linear velocity	v_t	m/s	3
Body angular velocity	ω_t	rad/s	3
Projected gravity	g_t	1	3
Linear velocity command	v_{xy}^{cmd}	m/s	2
Yaw rate command	ω_z^{cmd}	rad/s	1
Relative joint position	$q_t - q^0$	rad	12
Joint angular velocity	$\dot{q}_t$	rad/s	12
Previous action	a_{t-1}	1	12
Robot/command observation	$\tilde{o}_t$	mixed	48
Terrain heights	h_t	m	187
Current observation	o_t	mixed	235

perceptron (MLP)으로 구성한다[2]. 학생 인코더는 로봇 상태와 명령의 관측 이력 $H_t = [\tilde{o}_{t-49}, \ldots, \tilde{o}_t]$를 입력받는다. 이 50×48 이력의 각 프레임을 64차원으로 변환하고, 세 개의 1차원 합성곱 층을 갖는 convolutional neural network (CNN)로 8차원 학생 특징 z_t^S를 생성한다[2, 5]. 지형 높이는 이력에서 제외하며 부족한 과거 표본은 0으로 채운다. 평가 시 행동 정책(Actor)은 현재 관측과 학생 특징을 결합한 $235 + 8 = 243$차원을 입력받아 12차원 행동을 출력한다. 몸체 속도와 지형 높이는 시뮬레이터에서 얻으므로, 실제 로봇 적용에는 별도의 측정과 추정이 필요하다.

3.2 교사, 학생 공동학습

관측 이력에서 추정한 학생 특징으로도 보행을 유지하도록, 교사 특징과 학생 특징을 혼합하여 제어 정책을 함께 학습한다[2, 5]. 학습 초기에는 교사 특징을 주로 사용하고 학생 특징의 비중을 점차 높여, 정책의 입력을 학생 특징으로 전환한다. 이때 다음 혼합 특징을 현재 관측과 결합한 243차원을 Actor와 가치 함수(Critic)에 입력한다. Critic은 기대 할인 누적 보상을 추정하여 정책 학습을 돕고, 평가 시에는 사용하지 않는다.

$$z_t = (1 - \alpha)z_t^T + \alpha z_t^S. \tag{3}$$

식 (3)의 α는 학생 특징의 혼합 비중이다. 사전학습 교사로 초기화한 뒤 공동학습 반복 횟수 n에 따라 $\alpha(n) = \min(n/10000, 1)$로 학생 비중을 높인다. 10,000회 이후에는 학생 특징만 사용하여 평가와 입력 경로를 맞춘다. 전환 중에는 proximal policy optimization (PPO) 손실에 모방항을 추가한다[6].

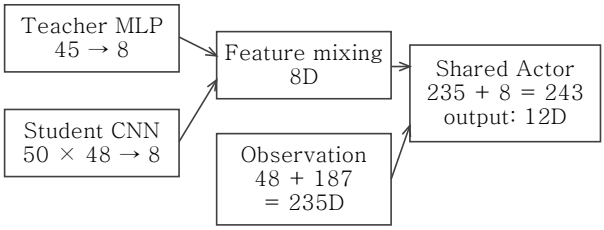


그림 2. 교사, 학생 공동학습 기반 보행 제어 구조

$$\mathcal{L} = \mathcal{L}_{PPO} + \frac{1-\alpha}{B}\sum_{i=1}^{B} \|z_i^S - \mathrm{sg}(z_i^T)\|_2. \qquad (4)$$

스케줄과 평균 L2 거리의 모방 손실은 선행 연구를 따른다[2]. 식 (4)에서 $\mathcal{L}_{PPO}$는 정책 손실과 가치 함수 손실, B는 미니배치 크기, i는 배치 내 표본 번호, sg는 모방 목표의 gradient 차단 연산이다. 교사는 전환 중에도 PPO로 갱신되며, $\alpha = 1$ 이후에는 학생, Actor, Critic만 학습한다. 두 경로에서 학생 경로로 전환하는 구조는 그림 2에 나타냈다.

3.3 속도 추종 보상

보상은 속도 추종과 안정적인 운동을 함께 유도한다[1]. 평면 선속도와 요 각속도(yaw rate)의 추종항은 오차가 작을수록 큰 값을 갖는다.

$$r_v = \exp\left(-\|v_{xy} - v_{xy}^{cmd}\|_2^2/0.25\right), \qquad (5)$$

$$r_\omega = \exp\left(-(\omega_z - \omega_z^{cmd})^2/0.25\right). \qquad (6)$$

식 (5), (6)에서 v_{xy}와 ω_z는 평면 선속도와 요 각속도이며, 요 각속도는 몸체좌표계의 z축 각속도로 계산한다. 위첨자 cmd는 명령값이다. 분모 0.25의 단위는 각각 $(\mathrm{m/s})^2$, $(\mathrm{rad/s})^2$이며 보상 감소 폭을 정한다. 표 3의 비용항은 수직 운동, roll/pitch 운동과 과도한 토크, 급격한 행동 변화 등을 억제한다. 원시 물리량으로 계산한 가중합에 제어 간격을 곱하고 음수 총보상은 0으로 제한한다. PPO로 할인 보상합을 최대화한다.

3.4 정책 학습 설정과 과정

마찰과 하중, 모터 강도가 달라져도 보행을 유지하도록 학습 중 마찰계수 0.5에서 1.25, 추가 질량 0에서 2 kg, 명목 모터 강도 ±10%를 무작위화하였다. PD 이득도 K_p ±5%, K_d ±10%로 변화시키고 혼합 지형과 주기적인 외란을 적용하였다.

4,096개의 병렬 환경에서 경험 수집과 PPO 갱신을 반복하며, 교사 사전학습, 교사와 학생의 공동학습, 학생 특징만 사용하는 후속 학습 순서로 진행하였다. 교사 사전학습은 43,000회 반복하였으며, 누적 53,000회까지 학생 특징의 혼합 비중을 높이고 이후 77,500회까지 학생 특징만 사용하여 정책을 학습하였다.

표 3. 제어 간격 적용 전 보상항별 가중치

Reward term	Weight
Planar velocity / yaw rate tracking	1 / 0.5
Squared vertical velocity	-2
Squared roll/pitch angular velocity	-0.05
Squared joint torque	-2×10^{-4}
Squared joint angular acceleration	-2.5×10^{-7}
Squared action change	-0.01
Disallowed contact count	-1
Joint-limit excess	-10
Foot air-time reward	1

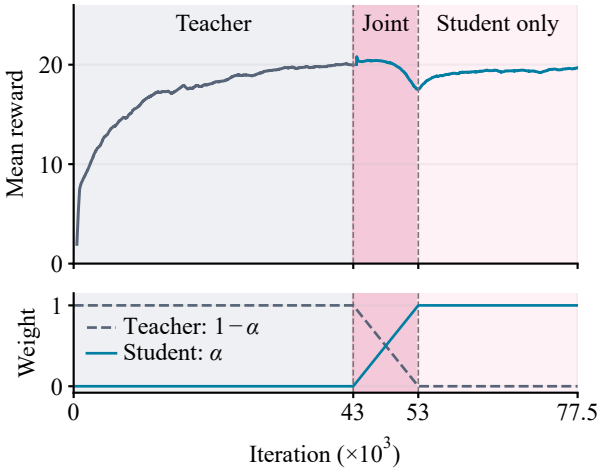


그림 3. 학습 보상과 교사, 학생 특징의 혼합 비중

그림 3의 상단은 시행별 누적 보상의 평균을 학습 반복 500회 구간으로 평활화한 결과이며, 하단은 교사 특징과 학생 특징의 혼합 비중이다. 공동학습 후반에는 특권 물리 정보로 만든 교사 특징의 비중을 줄이고 관측 이력으로 추정한 학생 특징을 더 많이 사용하며, 이 전환 구간에서 보상이 감소하였다. 학생 특징만 사용하는 후속 학습에서는 정책을 갱신하며 평균 누적 보상이 17.52에서 19.70으로 다시 높아졌다.

IV. 시뮬레이션 결과 및 성능 분석

4.1 비교 정책과 평가 조건

정상 상태만 학습한 정상학습 정책(Normal)과 정상 상태 및 관절 토크 저하 조건을 학습한 고장대응 정책(Student)을 비교한다. Normal은 실제 관절별 토크 저하율이 반영된 유효 모터 강도와 고장 표지를 포함한 특권 물리 정보의 교사 인

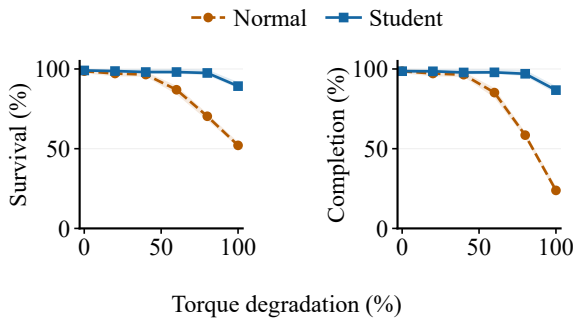


그림 4. 토크 저하율에 따른 생존율과 완주율(%)

코더를, Student는 관측 이력 기반 학생 인코더를 사용한다. 평가 정책의 누적 학습 반복 횟수는 각각 22,500회와 77,500회이며, 각 정책은 단일 학습 시드로 학습하였다. 고장 학습, 관측 표현, 학습량이 다른 두 정책 구성 전체를 비교 대상으로 한다.

혼합 지형은 경사, 거친 경사, 계단, 장애물로 구성된 8×8 m 구획을 5행 12열로 배치하며 세계좌표계의 $+x$ 방향으로 난이도가 증가한다. 전진, 좌우 대각 이동, 좌우 횡이동, 사인파 경로를 2:1:1:2 비율로 평가한다. 대각 이동과 횡이동은 몸체 방향을 각각 $\pm 45°$, $\pm 90°$로 유지하며 세계좌표계의 $+x$ 방향으로 진행하고, 사인파는 진폭 1.5 m와 2 m, 파장 16 m로 설정하며 몸체가 경로 접선을 따른다. 두 정책에 초기 상태, 물리 조건, 지형, 고장 일정을 동일하게 적용하고 관측 잡음과 외부 밀기는 해제하였다. 동일한 상위 제어기로 경로를 속도 명령으로 변환하며 목표 이동 속도의 크기는 0.5 m/s로 설정하였다. 정상 상태와 12개 관절의 토크 저하율 20~100%를 20% 간격으로 평가하며 고장은 2 s에 발생시켰다. 3개 평가 시드에서 정책별 각 고장 조건을 216회 반복하여 정상 상태를 포함한 총 26,352시행을 비교하였다.

평가 지표는 생존율, 이동 명령 추종 오차, 경로 횡오차이다. 몸체 접촉력의 노름이 1 N을 초과하면 낙상으로 판정하며, 생존율은 평가 종료까지 낙상하지 않은 시행의 비율로 정의한다. 완주율은 전체 시행 중 세계좌표계의 $x \geq 40.5$ m에 도달하고 경로 횡오차의 절댓값이 0.5 m 미만인 시행의 비율이다. 이동 명령 추종 오차는 몸체좌표계의 실제 선속도 v_x, v_y와 요 각속도 ω_z를 같은 시점에 전달된 명령과 비교한 차이로 정의한다. 경로 횡오차는 세계좌표계의 몸체 위치와 기준 경로의 근사 투영점 사이 변위를 경로의 단위 법선 방향으로 투영한 값이다. 각 오차는 고장 발생 시점인 2 s부터 시행 종료 전까지의 유효 구간에서 시행별 root mean square error (RMSE)로 계산한 뒤 동일 가중치로 평균한다. 명령이 0인 축도 포함하며 낙상 이후의 표본은 제외한다.

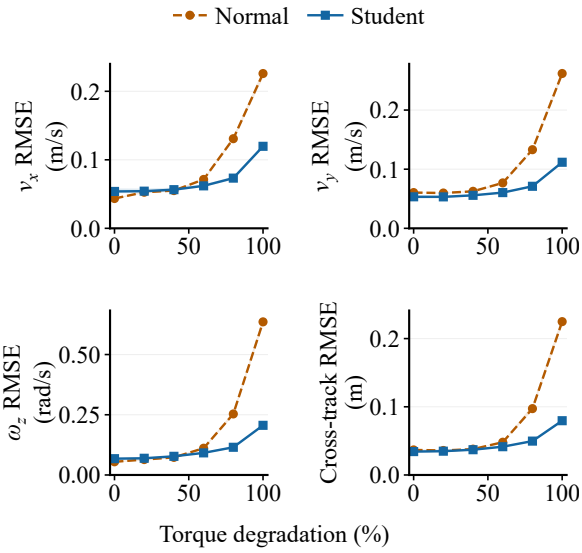


그림 5. 토크 저하율에 따른 이동 명령 추종 오차와 경로 횡오차

4.2 큰 토크 저하에서의 보행 및 추종 성능 유지

Student는 토크 저하율이 커져도 낙상을 줄이고 경로를 끝까지 수행하는 성능을 유지하였다. 그림 4은 고장 관절과 주행 과제에 대한 평균 결과이다. 토크 저하율이 100%일 때 생존율은 Normal 52.08%에서 Student 89.24%로, 완주율은 23.84%에서 86.73%로 높아졌다. 이는 균형 유지의 향상이 실제 이동 수행으로도 이어졌음을 보여준다.

추종 성능의 차이도 큰 토크 저하율에서 뚜렷해졌다. 그림 5에서 정상 상태와 낮은 토크 저하율의 추종 오차는 대체로 유사하며, 일부 축에서는 Normal이 근소하게 작았다. 반면 60~100%에서는 Student의 세 축 이동 명령 추종 오차와 경로 횡오차가 모두 작고, 100%에서 경로 횡오차 RMSE는 Normal 대비 64.6% 감소하였다. 제안 정책의 이점은 정상 상태의 추종 정밀도 향상보다, 관절의 구동 능력이 크게 줄었을 때의 성능 유지에 있다. 오차는 시행 종료 전 구간에서 계산하므로 생존율과 완주율을 함께 해석해야 한다.

생존율만으로는 이동 수행의 차이를 충분히 설명하기 어렵다. RL calf의 토크 저하율 100%에서 Normal과 Student의 생존율은 각각 87.04%, 91.67%지만, 완주율은 1.39%, 90.28%로 크게 달랐다. 일부 시행에서는 낙상하지 않은 채 30 s 동안 경로 진행 최고값의 증가가 0.5 m 미만인 정체도 관찰되었다. 따라서 생존, 완주와 추종 오차의 동반 개선이 고장 이후의 실질적인 이동 성능 향상을 뒷받침한다.

4.3 고장 관절별 보행 유지 성능

같은 토크 저하율에서도 Student의 성능은 고장 관절에 따라 달랐다. 그림 6는 셀당 216시행의 낙상률이며, 색에는

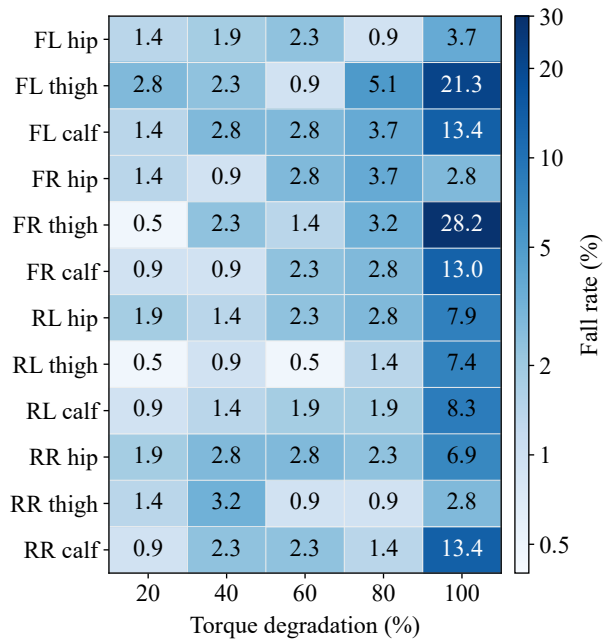


그림 6. Student의 고장 관절과 토크 저하율에 따른 낙상률(%)

0.4~30%의 로그 스케일을 적용하였다. FL/FR은 좌/우 앞다리, RL/RR은 좌/우 뒷다리이다. 토크 저하율이 100%일 때 FR hip의 낙상률은 2.78%지만 FR thigh와 FL thigh는 각각 28.24%, 21.30%였다. 본 평가에서 앞다리 thigh의 토크 저하율 100% 조건은 전체 평균의 개선에도 취약성이 남는 조건으로, 후속 학습에서 우선 보강할 대상을 보여준다.

V. 결론

본 논문에서는 정상 상태와 단일 관절 토크 저하 상황에서 주어진 이동을 지속하도록 교사, 학생 공동학습과 관측 이력 기반 특징을 결합한 강화학습 보행 정책을 제안하였다. 학습 시에는 특권 물리 정보를 활용하고, 평가 시에는 고장 관절과 토크 저하율을 직접 입력받지 않는 학생 정책으로 다양한 이동 명령과 경로를 수행하도록 구성하였다. 실험 결과, 제안 정책은 낮은 토크 저하율에서 정상학습 정책과 유사한 추종 성능을 유지하면서, 큰 토크 저하율에서는 낙상을 줄이고 경로 완주와 이동 명령 추종 성능을 함께 개선하였다. 또한 생존율이 유사한 조건에서도 완주 성능에는 큰 차이가 나타나, 낙상 여부만으로 설명되지 않는 이동 수행의 차이를 확인하였다. 특히 명령 속도와 경로 횡오차를 구분하여 평가함으로써, 이동 명령의 정확도와 기준 경로를 따라가는 정확도를 각각 확인하였다. 이러한 결과는 관측 이력을 활용하는 고장대응 정책이 관절 토크 저하 이후에도 요구된 방향과 경로로 이동을 이어가는 데 기여할 수 있음을 시사한다. 향후 연구에서는 관절별 취약 조건을 보완하고, 독립 학습 시드를 늘려 재현성을 검증하며 실제 로봇의 상태 추정과 제어 지연을 반영한 실험으로 적용 범위를 확장할 계획이다.

References

[1] N. Rudin, D. Hoeller, P. Reist, and M. Hutter, "Learning to walk in minutes using massively parallel deep reinforcement learning," in Proc. 5th Conf. Robot Learning (CoRL), London, UK, PMLR, vol. 164, pp. 91–100, 2022.

[2] D. Liu, T. Zhang, J. Yin, and S. See, "Saving the limping: Fault-tolerant quadruped locomotion via reinforcement learning," arXiv preprint arXiv:2210.00474v3, 2023.

[3] V. Makoviychuk et al., "Isaac Gym: High performance GPU based physics simulation for robot learning," in Proc. Neural Information Processing Systems Track on Datasets and Benchmarks (NeurIPS), Virtual, vol. 1, 2021.

[4] X. Wu, W. Dong, H. Lai, Y. Yu, and Y. Wen, "Adaptive control strategy for quadruped robots in actuator degradation scenarios," in Proc. 5th Int. Conf. Distributed Artificial Intelligence (DAI), Singapore, pp. 1–13, 2023.

[5] A. Kumar, Z. Fu, D. Pathak, and J. Malik, "RMA: Rapid motor adaptation for legged robots," in Proc. Robotics: Science and Systems (RSS), Virtual, 2021.

[6] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, "Proximal policy optimization algorithms," arXiv preprint arXiv:1707.06347, 2017.