4족 보행 로봇의 액추에이터 토크 저하에 강건한 교사·학생 기반 강화학습 보행 제어

Teacher–Student Reinforcement Learning for Robust Quadruped Locomotion under Actuator Torque Degradation

요약 본 논문은 정상 상태와 단일 관절 토크 저하에 대응하는 교사·학생 기반 강화학습 보행 제어 구성을 제시한다. 관측 이력 기반 학생은 고장 관절과 토크 저하율을 직접 입력받지 않는다. Unitree A1 시뮬레이션에서 정상학습 정책과 전진·대각·횡이동·사인파 경로를 비교하였다. 100% 저하에서 생존율은 52.08%에서 89.24%로 높아지고, 경로 횡오차 RMSE는 0.225 m에서 0.080 m로 낮아져 낙상 감소와 추종 성능 개선을 함께 확인하였다.

Abstract Quadrupedal robots should maintain balance and execute commanded motion after joint torque degradation. We present a teacher–student reinforcement learning control configuration whose history-based student handles nominal and single-joint degraded conditions without direct fault inputs. Unitree A1 simulations compare the fixed student with a nominally trained policy, each trained with one seed, on matched mixed-terrain courses using forward, diagonal, lateral, and sinusoidal-path tasks. At 100% torque degradation, survival (non-fall rate) increased from 52.08% to 89.24%, while mean pre-termination v_x, v_y, and cross-track root mean square errors (RMSEs) decreased from 0.226 to 0.120 m/s, 0.262 to 0.112 m/s, and 0.225 to 0.080 m, respectively, averaged over the fixed task mixture. The results show simultaneous improvements in fall avoidance and motion tracking under severe torque degradation.

Keywords: Quadrupedal locomotion, Actuator degradation, Teacher–student learning, Joint learning

I. 서론

4족 보행 로봇은 계단과 불규칙한 지형을 이동할 수 있으며, 강화학습을 이용한 보행 제어는 다양한 지면에서 균형 유지와 이동 명령 수행을 학습하는 데 활용된다[1]. 그러나 관절의 토크가 저하되면 몸체를 지지하고 추진하는 능력이 달라져 정상 조건에서 학습한 정책의 이동 성능이 저하될 수 있다. 특히 낙상을 피하더라도 요구된 속도와 방향을 따르지 못하거나 목표 경로에서 벗어날 수 있으므로, 고장 대응 보행은 생존 여부와 명령·경로 추종을 함께 평가해야 한다.

Rapid motor adaptation (RMA)은 관측 이력에서 환경 특성을 추정하여 보행에 활용하고, 교사·학생 공동학습은 관절 잠금에 대응하는 정책 학습에 적용되었다[2, 3]. ADAPT는 관절별 교사와 Transformer를 이용한 토크 저하 적응을 제안하였다[4]. 본 논문에서는 단일 관절 토크 저하를 고려한 교사·학생 기반 강화학습 보행 제어 구성을 제시한다. 학생은 고장 관절과 토크 저하율을 직접 입력받지 않고 현재 관측과 관측 이력을 사용하여 정상 상태와 토크 저하 상태에서 동작한다.

기여는 단일 관절 토크 저하 학습과 이력 표현을 결합한 제어 구성, 그리고 정상학습 정책과의 동일 조건 비교이다. 전진·좌우 대각·좌우 횡이동·사인파 경로에서 생존율과 세 축 명령 및 경로 횡오차의 root mean square error (RMSE)를 분석하여 낙상 감소와 추종 오차 개선이 함께 나타나는 범위 및 관절별 차이를 분석한다.

II. 시스템 모델

Isaac Gym의 graphics processing unit (GPU) PhysX에서 12개 관절을 갖는 Unitree A1을 모사한다[5]. 각 다리의 관절은 hip, thigh, calf이다. 정책은 0.02 s마다 12차원 행동 a_t를 출력하고, proportional-derivative (PD) 제어기가 목표 관절각을 토크로 변환한다. 물리 계산 간격은 0.005 s이다. 행동에서 실제 토크까지의 관계는 식 (1)과 같다.

$$
\begin{aligned}
q^{\text{des}} &= q^0 + 0.25a_t, \\
\tau_j &= \text{clip}\big(m_j\eta_j\left[K_{p,j}(q_j^{\text{des}} - q_j) - K_{d,j}\dot{q}_j\right], \pm\tau_j^{\max}\big).
\end{aligned} \tag{1}
$$

여기서 q^0, q_j, $\dot{q}_j$는 기준 관절각, 현재 관절각, 관절속도이고, 0.25 rad는 행동 배율이다. $K_{p,j}$, $K_{d,j}$는 PD 이득이며 명목값은 각각 20 N·m/rad, 0.5 N·m·s/rad이다. m_j는 명목 모터 강도 배율이고, $\tau_j^{\max}$는 로봇 모델에 지정된 관절 토크 한계이다. clip은 토크를 해당 한계 안으로 제한한다.

토크 저하율 $d \in [0, 1]$에 대해, 고장 발생 시점 t_f 이후 선택한 관절 j_f의 $\eta_{j_f} = 1 - d$로 하고 나머지는 1로 유지한다[4]. 배율은 포화 전 PD 명령에 적용되며 최대 토크 한계 자체를 축소하지 않는다. 한계는 hip 20 N·m, thigh·calf 55 N·m이다. $d = 1$에서는 해당 관절의 능동 토크가 0이지만, 관절 잠금과 달리 수동 운동과 접촉은 가능하다. 학습에서는

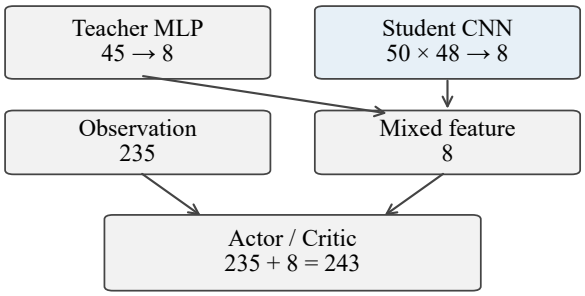


그림 1. 교사·학생 특징 혼합 학습. 평가에는 혼합 없이 학생 특징을 사용한다. MLP는 multi-layer perceptron이다.

에피소드마다 관절 하나와 $d \in \{0, 0.2, 0.4, 0.6, 0.8, 1\}$을 선택하고, 시작 후 2–10 s에 고장을 발생시킨다.

III. 교사·학생 기반 보행 제어

로봇 상태·물리 조건·지형을 상태, $a_t \in \mathbb{R}^{12}$를 행동으로 하는 Markov decision process (MDP)를 구성하되, 고장 상태를 직접 관측하지 못하는 학생은 관측 이력으로 행동을 정한다. 현재 관측 o_t는 몸체 속도·중력·명령·관절 상태·이전 행동의 $\tilde{o}_t \in \mathbb{R}^{48}$과 지형 높이 187차원이다[1]. 학생은 최근 1 s의 $H_t = [\tilde{o}_{t-49}, \ldots, \tilde{o}_t]$를 사용하며 부족한 이력은 0으로 채운다.

교사는 마찰·질량·유효 모터 강도·PD 이득·몸체 속도·고장 표지의 45차원 특권 정보를 8차원 특징 z_t^T로 압축한다. 학생은 convolutional neural network (CNN)로 H_t에서 8차원 특징 z_t^S를 얻는다. 현재 관측과 특징의 243차원을 행동 정책(Actor)과 가치 함수(Critic)에 입력한다. 평가에는 $[o_t, z_t^S]$를 사용한다. 몸체 속도·지형 높이와 상위 제어기의 세계 위치·자세는 시뮬레이터 값이다.

공동학습은 교사 특징을 학생이 모방하면서 정책 입력을 학생 특징으로 전환하는 기존 구성을 따른다[3]. 특징 혼합과 학습 손실은 식 (2)로 정의한다.

$$\begin{aligned} z_t &= (1-\alpha) z_t^T + \alpha z_t^S, \\ \mathcal{L} &= \mathcal{L}_{\text{PPO}} + \frac{1-\alpha}{B} \sum_{i=1}^{B} \| z_i^S - \text{sg}(z_i^T) \|_2 . \end{aligned} \tag{2}$$

여기서 $\alpha = \min(n/10000, 1)$은 공동학습 갱신 횟수 n에 따른 학생 비중, B는 미니배치 크기, i는 표본 번호, sg는 모방 목표의 gradient 차단 연산이다. $\mathcal{L}_{\text{PPO}}$는 proximal policy optimization (PPO)의 정책·가치 학습 손실이다[6]. 교사는 전환 중 PPO로 갱신되며, $\alpha = 1$ 이후에는 학생과 Actor·Critic만 갱신한다. 그림 1은 특징을 결합하는 학습 경로를 나타낸다.

보상은 평면 선속도·회전속도의 제곱 오차를 각각 0.25 (m/s)^2, 0.25 (rad/s)^{2}로 나눈 음의 지수를 취하고 1, 0.5로 가중한다. 수직·roll/pitch 운동, 토크, 관절가속도, 행동 변화, 비허용 접촉·관절 한계 초과를 억제하고 발 공중 시간 보상을 더한다. 제어 간격을 곱한 총보상은 0 이상으로 제한한다.

교사와 Actor·Critic은 은닉층 [512, 256, 128], 학생은 64차원 프레임 표현과 세 시간 합성곱 층을 사용한다. 4,096 환경의 24시점 경험으로 PPO를 갱신하고 초기 학습률은 10^{-5}로 한다. 마찰 0.5–1.25, 질량 0–2 kg, 모터 강도·PD 이득을 무작위화한다. 교사 사전학습 43,000회 이후 10,000회에 걸쳐 학생 특징으로 전환하였다. 전환 완료 시점의 500회 이동평균 보상 17.52는 77,500회에서 19.70으로 회복되었다. 이 최종 학생 정책을 평가한다.

IV. 시뮬레이션 결과 및 성능 분석

4.1 비교 정책과 평가 조건

Normal은 정상 조건만 학습하고, 평가 시 실제 고장 배율과 고장 표지를 반영한 특권 정보의 교사 인코더를 사용한다. Student는 정상·토크 저하 조건에서 학습하고 이력 기반 학생 인코더를 사용한다. 고장 학습·표현·학습 이력이 다른 두 구성 전체를 비교한다. 평가 체크포인트는 Normal 22,500회, Student 누적 77,500회이다. Student의 사전학습 교사는 Normal과 다른 고장학습 정책이다. 각 정책의 학습 시드는 1이며, 현재 수집 전에 선정한 고정 정책이다.

평가 저하율은 $d \in \{0.2, 0.4, 0.6, 0.8, 1\}$이며 정상 한 조건을 더한다(표 1). 8 m × 8 m 구획을 +x 방향 5행, 횡방향 12열로 배치한다. 각 열의 같은 지형 유형은 행마다 난이도 0–0.8로 증가한다. 열 구성은 음·양의 피라미드 경사 각 1, 거친 경사 1, 음·양의 계단 피라미드 4·3, 장애물 2이다. 같은 부호 계단 열은 동일 형상이며 요철·장애물은 시드에 따라 달라진다. 대응 쌍의 초기 상태·물리·지형·고장 일정을 맞추고, 관측 잡음·외부 밀기·종료 후 재시작은 해제하였다.

모든 과제는 세계 +x로 진행하고, 대각·횡이동은 몸체를 $\pm 45°$, $\pm 90°$로 유지하며 좌우를 조건·시드 사이에서 교대한다. 전진 두 슬롯은 초기·물리 난수가 다르다. 사인파는 열 중심 y_c에서 $y = y_c + A \sin(2\pi(x+1)/16)$이다. 완료된 전수 수집에서 성능값과 무관한 식별자로 고정 2:1:1:2를 추출하였다. 평균은 이 과제 구성과 지형 열 비중을 반영한다.

동일 상위 제어기가 접선 속도와 횡오차 피드백을 결합해 0.5 m/s의 세계 속도 명령을 정하고 실제 yaw로 몸체좌표로

표 1. 고정 혼합 과제의 평가 설정

Item	Setting
Task slots	Forward 2; diagonal 1; lateral 1; sine 2
Path / speed	World +x, $x = -1$ to 40.5 m; 0.5 m/s
Body yaw (line)	$0°$, $\pm 45°$, $\pm 90°$
Sine path	Amplitudes 2 / 1.5 m; wavelength 16 m
Conditions / onset	12 joints $\times$ 5 levels + 1 nominal; 2 s
Total trials	$6 \times 61 \times 2 \times 3 \times 12 = 26,352$
Evaluation seeds	1101, 1102, 1103
Post-onset cap	Line 445 s; $A = 1.5$: 479.88 s; $A = 2$: 504.62 s

변환한다. 목표 yaw는 사인파에서 접선, 직선에서 과제별 고정각이다. 회전 명령은 ± 0.8 rad/s로 제한하며, 상태에 따라 달라지는 실제 명령을 RMSE 기준으로 쓴다.

종료 조건은 base 링크 순접촉력 노름 > 1 N의 낙상, 출구 도달($x \geq 40.5$ m, 횡오차 절댓값 < 0.5 m), 경로 길이 L에 따른 시간 상한 $L/(0.1\,\mathrm{m/s}) + 30$ s 순으로 적용한다. 상한은 고장 후 기준이며 느린 이동을 기다리기 위한 예산이다. 저속·정체로 조기 종료하지 않는다.

생존율은 전체 N시행 중 낙상하지 않은 비율로 식 (3)과 같이 정의한다. 완주와 비낙상 상한 종료를 모두 포함하며, 고장 전 낙상도 실패로 센다.

$$S = \frac{100}{N} \sum_{i=1}^{N} I_i, \qquad I_i = \begin{cases} 0, & \text{낙상}, \\ 1, & \text{그 외 종료}. \end{cases} \tag{3}$$

여기서 I_i는 시행 i의 비낙상 지시값이다. S는 % 단위이며 완주율·평균 생존 시간이 아니다. 정책당 정상 216시행, 비영 저하율별 2,592시행, 관절·저하율별 216시행이다.

이동 명령 추종은 실제 몸체 v_x, v_y, ω_z와 같은 시점의 명령 간 오차로 평가한다. 경로 추종은 세계 위치 $\mathbf{p}(t)$를 기준 경로 $\mathbf{p}^{\mathrm{ref}}(s)$에 투영한 뒤, 그 차이의 단위 법선 방향 성분 $e_{\perp}(t)$를 사용한다. 이는 몸체 좌우 오차나 같은 시각 목표점까지의 거리가 아니다. 시행별 오차는 식 (4)로 계산한다.

$$R_{u,i} = \sqrt{\frac{1}{K_i} \sum_{k \in V_i} e_{u,i,k}^{\prime 2}}, \qquad \overline{R}_u = \frac{1}{M_u} \sum_{i:K_i>0} R_{u,i}. \tag{4}$$

여기서 $u \in \{v_x, v_y, \omega_z, \perp\}$이며, 속도 오차는 실제값에서 현재 명령을 뺀 값, 경로 오차는 $e_{\perp}$이다. V_i는 2 s 이후 첫 종료 전 유효 표본 집합, K_i는 표본 수, M_u는 오차 계산이 가능한 시행 수이다. 0 명령도 포함하며 낙상 이후를 0으로 채우지 않는다. 유효 표본이 없으면 계산 불가이며 이번 자료의 누락은 없다. 시행별 RMSE를 평균하므로 생존 표본 수로 가중하지 않는다. 정책별 종료 시점과 방문 지형이 달라 동일 시간·난이도의 오차 비교는 아니며 생존율과 함께 해석한다. 곡선 음영은 평가 시드 평균의 최소–최대이며 학습 시드 신뢰구간이 아니다.

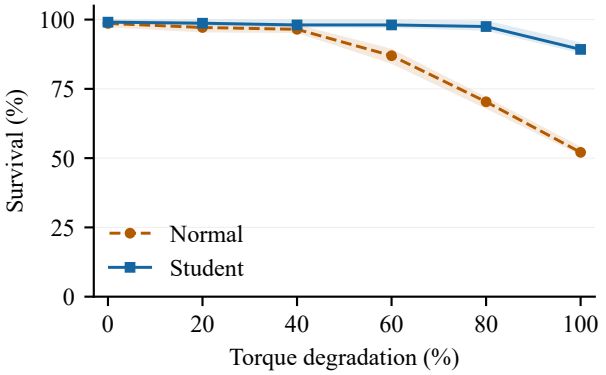


그림 2. 토크 저하율별 생존율. 점은 전체 평균, 음영은 3평가 시드 평균의 최소–최대이다.

표 2. 100% 토크 저하의 명령 추종 RMSE

Metric	Normal	Student
v_x (m/s)	0.226	0.120
v_y (m/s)	0.262	0.112
ω_z (rad/s)	0.636	0.206

4.2 토크 저하에 따른 낙상 및 명령 추종

그림 2는 토크 저하율에 따른 생존율을 나타낸다. 정상 상태에서 Normal과 Student는 각각 98.61%, 99.07%이지만 100% 저하에서 52.08%, 89.24%가 된다. Student의 생존율 우위는 60%에서 11.11%p, 80%에서 27.16%p, 100%에서 37.15%p로 커진다. 정상학습 정책의 생존 성능이 큰 저하에서 급감하는 데 비해 Student는 비낙상 비율을 상대적으로 높게 유지한다. 표 2는 100% 저하의 명령 추종 오차이다. v_x, v_y, ω_z RMSE가 각각 47.0%, 57.3%, 67.6% 감소하여 생존율과 실제 이동 정확도가 함께 개선되었다. 정상 상태의 v_x RMSE는 Normal 0.043 m/s, Student 0.054 m/s이고 회전속도 오차도 Student가 더 크므로, 이점은 큰 저하에서의 성능 유지에 있다.

4.3 경로 추종과 과제별 성능

그림 3은 경로 횡오차를 나타낸다. 100% 저하에서 Normal 0.225 m, Student 0.080 m로 64.6% 감소한다. 동일 상위 제어기에서 명령 추종과 실제 경로 이탈이 함께 개선되었다. 경로 위 정지에서도 횡오차는 작을 수 있으므로 앞의 생존

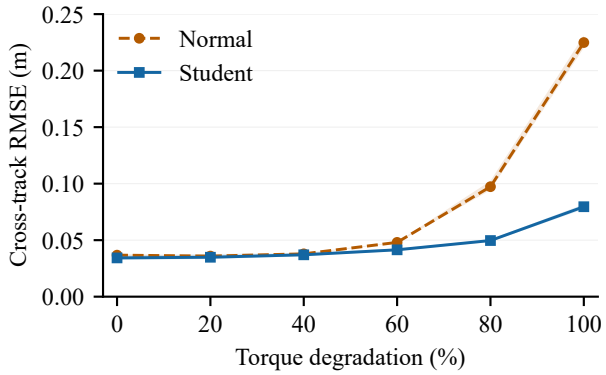


그림 3. 토크 저하율에 따른 기준 경로 횡오차 RMSE.

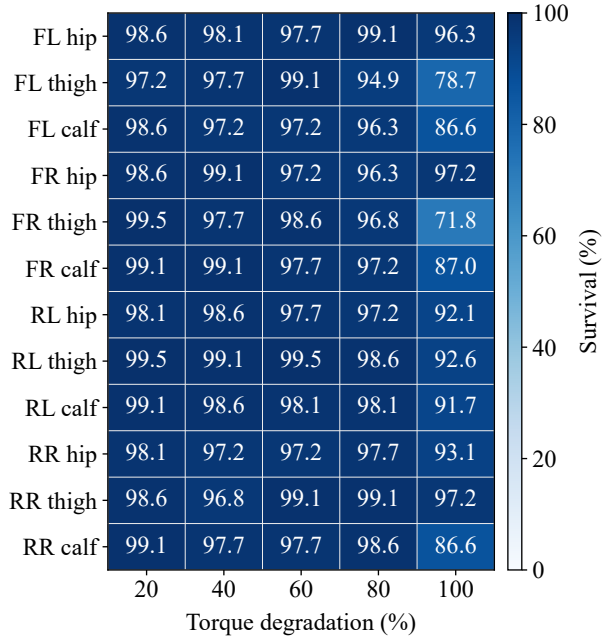


그림 4. Student의 관절·토크 저하율별 절대 생존율(%). 각 셀은 216시행이다.

율과 세 축 명령 오차를 같이 해석한다.

100% 저하에서 전체 시행의 출구 도달 비율도 Normal 618/2,592(23.84%)에서 Student 2,248/2,592(86.73%)로 높아졌다. 일부 비낙상 시행에서는 30 s 동안 경로 진행 최고값이 0.5 m 미만 증가하는 정체도 관찰되었다. RL calf 100%의 비낙상 시행 중 정체 경험은 Normal 185/188, Student 4/198이었다. 일시 정체 후 완주도 포함한 보조 사례이다. 100% 저하의 과제별 생존율도 전진 49.07%/88.89%, 대각 59.72%/90.74%, 횡이동 59.72%/95.14%, 사인파 47.45%/85.88%로 개선되었다(Normal/Student). 이 과제별 비낙상 결과와 혼합 과제의 명령·경로 오차를 함께 평가하였다.

4.4 Student의 관절별 성능

그림 4는 Student의 실제 생존 성능을 관절별로 나타낸다. FL/FR은 좌/우 앞다리, RL/RR은 좌/우 뒷다리이다. 100% 저하에서 FR hip와 RR thigh는 97.22%인 반면 FL thigh는 78.70%, FR thigh는 71.76%이다. 같은 저하율에서도 관절별 생존 성능은 다르다. 전체적으로 큰 저하에서 낙상 감소와 명령·경로 추종 개선이 함께 나타나며, 히트맵은 평균에 가려진 관절별 성능 범위를 보여준다.

V. 결론

본 논문에서는 단일 관절 토크 저하 학습과 관측 이력 표현을 결합한 교사·학생 기반 보행 제어 구성을 제시하였다. 단일 학습 시드의 두 고정 정책을 해당 과제·지형 혼합에서 비교한 결과, 60–100% 저하에서 Student의 생존율과 종료 전 명령·경로 추종 오차가 함께 개선되었다. 100% 저하에서는 생존율이 52.08%에서 89.24%로 높아지고 경로 횡오차 RMSE가 0.225 m에서 0.080 m로 낮아졌다. 향후 독립 학습 반복과 실제 로봇에서 재현성을 검증할 계획이다.

References

[1] N. Rudin, D. Hoeller, P. Reist, and M. Hutter, “Learning to walk in minutes using massively parallel deep reinforcement learning,” in Proc. 5th Conf. Robot Learning (CoRL), London, UK, PMLR, vol. 164, pp. 91–100, 2022.

[2] A. Kumar, Z. Fu, D. Pathak, and J. Malik, “RMA: Rapid motor adaptation for legged robots,” in Proc. Robotics: Science and Systems (RSS), Virtual, 2021.

[3] D. Liu, T. Zhang, J. Yin, and S. See, “Saving the limping: Fault-tolerant quadruped locomotion via reinforcement learning,” arXiv preprint arXiv:2210.00474v3, 2023.

[4] X. Wu, W. Dong, H. Lai, Y. Yu, and Y. Wen, “Adaptive control strategy for quadruped robots in actuator degradation scenarios,” in Proc. 5th Int. Conf. Distributed Artificial Intelligence (DAI), Singapore, pp. 1–13, 2023.

[5] V. Makoviychuk et al., “Isaac Gym: High performance GPU based physics simulation for robot learning,” in Proc. Neural Information Processing Systems Track on Datasets and Benchmarks (NeurIPS), Virtual, vol. 1, 2021.

[6] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, “Proximal policy optimization algorithms,” arXiv preprint arXiv:1707.06347, 2017.