4족 보행 로봇의 액추에이터 토크 저하에 강건한 교사·학생 기반 강화학습 보행 제어

Teacher–Student Reinforcement Learning for Robust Quadruped Locomotion under Actuator Torque Degradation

요약 본 논문은 정상 상태와 단일 관절 토크 저하에 대응하는 교사·학생 기반 강화학습 보행 제어 구성을 제시한다. 관측 이력 기반 학생은 고장 관절과 토크 저하율을 직접 입력받지 않는다. Unitree A1 시뮬레이션에서 정상학습 정책과 전진·대각·횡이동·사인파 경로를 비교하였다. 100% 저하에서 생존율은 52.08%에서 89.24%로 높아지고, 종료 전 경로 횡오차의 시행별 root mean square error (RMSE) 평균은 0.225 m에서 0.080 m로 낮아져 낙상 감소와 추종 성능 개선을 함께 확인하였다.

Abstract Quadrupedal robots should maintain balance and execute commanded motion after joint torque degradation. We present a teacher–student reinforcement learning control configuration whose history-based student handles nominal and single-joint degraded conditions without direct fault inputs. Unitree A1 simulations compare the fixed student with a nominally trained policy, each trained with one seed, on matched mixed-terrain courses using forward, diagonal, lateral, and sinusoidal-path tasks. At 100% torque degradation, survival increased from 52.08% to 89.24%, while mean pre-termination cross-track root mean square error (RMSE) decreased from 0.225 to 0.080 m, averaged over the fixed task mixture. The results show simultaneous improvements in fall avoidance and motion tracking under severe torque degradation for these fixed policies and evaluated tasks.

Keywords: Quadrupedal locomotion, Actuator degradation, Teacher–student learning, Joint learning

I. 서론

4족 보행 로봇은 발 디딤 위치와 다리의 움직임을 조절하여 계단을 오르내리고, 바퀴형 로봇의 이동이 제한되는 단차와 불규칙한 지형을 통과할 수 있다. 이러한 이동 능력을 구현하기 위해 강화학습을 활용한 보행 제어가 연구되고 있으며, 다양한 지면 조건에서 균형을 유지하고 이동 명령을 수행하는 정책이 개발되고 있다[1]. 그러나 안정적인 이동을 위해서는 지형 변화뿐 아니라 액추에이터의 노화나 손상에 따른 구동 성능의 변화도 고려해야 한다. 관절의 토크가 저하되면 몸체를 지지하고 추진하는 능력이 달라져, 정상 조건에서 학습한 정책으로는 보행을 유지하거나 요구된 속도와 방향을 따르기 어려울 수 있다. 따라서 관절의 토크가 저하되어도 균형을 유지하며 주어진 이동을 이어갈 수 있는 보행 정책이 필요하다.

본 논문에서는 정상 상태뿐 아니라 단일 관절의 토크가 저하된 상황에서도 이동을 지속할 수 있는 강화학습 기반 보행 정책을 제안한다. 이를 위해 시뮬레이션에서 단일 관절의 토크 저하를 모델링하고, 교사·학생 공동학습을 통해 학생이 현재 관측과 과거 관측 이력으로부터 제어에 필요한 로봇의 특성을 추정하도록 학습한다[2]. 학생은 추정한 특성을 보행 제어에 활용하며, 고장 관절이나 토크 저하 수준을 직접 입력받지 않고 하나의 정책으로 정상 상태와 토크 저하 상황에 대응한다. 제안 정책은 정상 조건에서만 학습한 정책과 다양한 이동 명령 및 목표 경로에 대한 수행 성능을 비교하여 검증한다. 이를 통해 토크 저하 상황에서 보행을 더 오래 유지하고 요구된 움직임을 더 정확하게 수행할 수 있음을 보인다.

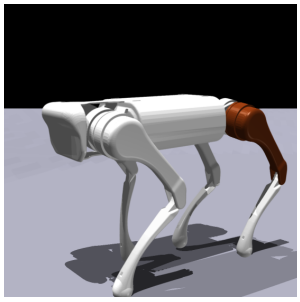
표 1. 로봇 및 제어 설정

Parameter	Value
Actuated joints	12 (hip, thigh, calf per leg)
Physics / policy interval	0.005 s / 0.02 s
Joint target	$q^{des} = q^0 + 0.25a_t$ (rad)
Nominal PD gains	$K_p = 20$ N·m/rad; $K_d = 0.5$ N·m·s/rad

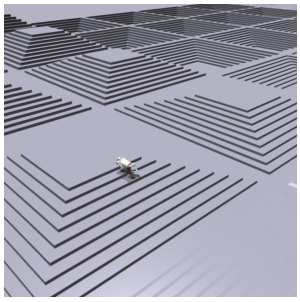
II. 시스템 모델

2.1 시뮬레이션 환경 및 제어 구조

Isaac Gym의 graphics processing unit (GPU) PhysX에서 Unitree A1을 모사한다[3]. 각 다리는 hip, thigh, calf로 구성되며, 전체 관절은 12개이다. 정책의 목표 관절각을 proportional-derivative (PD) 제어기가 토크로 변환하고, 몸체·관절 반응을 다음 관측에 반영하여 제어를 반복한다[1]. 로봇과 지형은 그림 1, 제어 설정은 표 1과 같다. 12차원 행동 a_t는 기준 자세 q^0에 더할 관절각을 정하며, 0.25 rad는 행동 배율이다. 0.02 s마다 새 목표를 출력하고, 그 사이에는 목표를 유지한 채 0.005 s 간격으로 물리를 계산한다.



(a) Unitree A1



(b) Isaac Gym 지형

그림 1. 로봇 모델과 시뮬레이션 환경

2.2 단일 관절 토크 저하 모델

토크 저하는 PD 토크에 곱하는 고장 배율의 감소로 모델링한다[4]. 토크 저하율 $d \in [0, 1]$에 대해 고장 배율은 $1 - d$이며, $d = 0.4$이면 고장 배율은 0.6이다. PD 토크에 모터 강도 m_j와 고장 배율 η_j를 곱한 뒤 관절 한계 토크로 제한한다.

$$\tau_j^{PD} = K_p(q_j^{des} - q_j) - K_d\dot{q}_j, \tag{1}$$

$$\tau_j = \text{clip}(m_j\eta_j\tau_j^{PD}, -\tau_j^{max}, \tau_j^{max}). \tag{2}$$

식 (1), (2)에서 q_j^{des}, q_j, $\dot{q}_j$는 목표 관절각, 현재 관절각, 관절속도이며, K_p, K_d는 PD 이득이다. τ_j^{max}는 관절 j의 최대 허용 토크이며, clip은 출력을 $\pm\tau_j^{max}$로 제한한다. m_j는 [0.9, 1.1]에서 무작위화하여 고장과 별개인 $\pm 10\%$ 편차를 반영한다. 100% 토크 저하($d = 1$)에서는 능동 토크가 0이지만, 관절 잠금과 달리 수동 운동은 유지된다.

고장은 선택된 관절 j_f에서 시점 t_f에 발생하며, 나머지 관절의 배율은 1로 유지한다.

$$\eta_j(t) = \begin{cases} 1 - d, & j = j_f,\ t \geq t_f, \\ 1, & \text{그 외}, \end{cases} \tag{3}$$

식 (3)의 j_f, t_f는 고장 관절과 발생 시점이다. 에피소드마다 관절 하나와 0, 20, 40, 60, 80, 100% 중 하나의 저하율을 무작위로 선택한다. 시작 후 2 s부터 10 s 사이에 고장을 발생시키고 배율을 유지한다. 고장 전후를 한 에피소드에 포함하여, 정상 보행 중 반응이 달라져도 제어를 이어가도록 학습한다.

III. 교사·학생 공동학습 기반 보행 정책

3.1 관측 및 이력 표현

고장 정보를 직접 받지 않는 학생에게는 행동 이후의 운동 반응이 단서가 된다. 따라서 현재 관측과 최근 1 s의 관측 이력을 함께 사용한다. 현재 관측 o_t는 로봇·명령 정보 $\tilde{o}_t$

표 2. 현재 관측의 구성

Component	Symbol	Unit	Dim.
Body linear velocity	v_t	m/s	3
Body angular velocity	ω_t	rad/s	3
Projected gravity	g_t	–	3
Linear velocity command	v_{xy}^{cmd}	m/s	2
Yaw-rate command	ω_z^{cmd}	rad/s	1
Relative joint position	$q_t - q^0$	rad	12
Joint velocity	$\dot{q}_t$	rad/s	12
Previous action	a_{t-1}	–	12
Robot/command observation	$\tilde{o}_t$	mixed	48
Terrain heights	h_t	m	187
Current observation	o_t	mixed	235

표 3. 교사·학생 인코더와 정책의 입출력

Path	Input → output
Teacher encoder	$45 \to z_t^T \in \mathbb{R}^8$
Student encoder	H_t: $50 \times 48 \to z_t^S \in \mathbb{R}^8$
Observation o_t	$48 + 187 = 235$
Training feature	$(1-\alpha)z_t^T + \alpha z_t^S$: 8
Actor/Critic (train)	$[o_t, z_t]$: $235 + 8 = 243$
Actor (inference)	$[o_t, z_t^S]$: $235 + 8 = 243 \to a_t \in \mathbb{R}^{12}$

48차원과 지형 높이 187차원이다[1]. $\tilde{o}_t$에는 선속도·각속도·중력 방향·속도 명령 각 3차원과 관절각 편차·관절속도·이전 행동 각 12차원이 포함된다. 각 관측의 기호·단위·차원은 표 2와 같다.

교사는 마찰계수 1, 추가 질량 1, 유효 모터 강도 12, PD 이득 24, 몸체 속도 6, 고장 표지 1의 총 45차원을 8차원 특징 z_t^T로 압축한다. 유효 모터 강도에는 손상 위치와 정도가 반영된다. 학생은 $H_t = [\tilde{o}_{t-49}, \ldots, \tilde{o}_t]$의 50×48 이력을 convolutional neural network (CNN) 인코더로 처리하여 특징 z_t^S를 만든다[2, 5]. 부족한 과거 표본은 0으로 채운다. 현재 관측 235차원과 학생 특징 8차원을 결합하여 12차원 행동을 출력한다. 교사·학생 인코더와 정책의 차원 관계는 표 3에 정리하였다. 지형 높이는 이력에서 제외한다. 몸체 속도와 지형 높이는 시뮬레이터에서 얻으므로, 실제 로봇 적용에는 별도의 측정·추정이 필요하다.

3.2 교사·학생 공동학습

교사의 45차원 특권 물리 정보는 학생에게 별도 입력하지 않는다. 이에 교사 특징을 관측 이력으로 추정하는 구조와

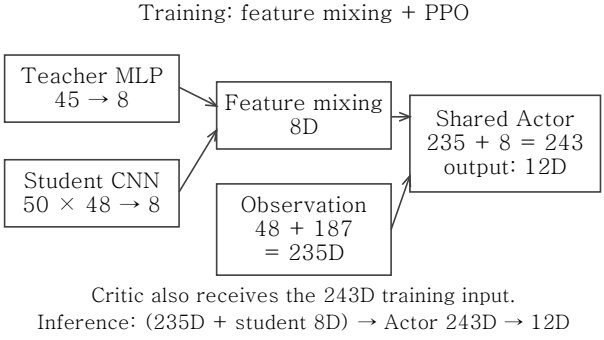


그림 2. 교사·학생 공동학습과 평가 시 학생 경로

특징 혼합 공동학습을 적용한다[2, 5]. 모방 오차가 남아 있어도 제어 정책이 학생 특징에 적응하도록, 다음 특징을 행동 정책(Actor)과 가치 함수(Critic)에 입력한다.

$$z_t = (1-\alpha) z_t^T + \alpha z_t^S. \tag{4}$$

식 (4)의 α는 학생 특징의 혼합 비중이다. 사전학습 교사로 초기화한 뒤 공동학습 갱신 횟수 n에 따라 $\alpha(n) = \min(n/10000, 1)$로 학생 비중을 높인다. 10,000회 이후에는 학생 특징만 사용하여 평가와 입력 경로를 맞춘다. 전환 중에는 proximal policy optimization (PPO) 손실에 모방항을 추가한다[6].

$$\mathcal{L} = \mathcal{L}_{PPO} + \frac{1-\alpha}{B} \sum_{i=1}^{B} \| z_i^S - \mathrm{sg}(z_i^T) \|_2. \tag{5}$$

스케줄과 평균 L2 거리의 모방 손실은 선행 연구를 따른다[2]. 식 (5)에서 $\mathcal{L}_{PPO}$는 정책·가치 학습 손실, B는 미니배치 크기, i는 배치 내 표본 번호, sg는 모방 목표의 gradient 차단 연산이다. 교사는 전환 중에도 PPO로 갱신되며, $\alpha = 1$ 이후에는 학생·Actor·Critic만 학습한다. 두 경로에서 학생 경로로 전환하는 구조는 그림 2에 나타냈다.

3.3 속도 추종 보상

보상은 속도 추종과 안정적인 운동을 함께 유도한다[1]. 평면 선속도와 yaw-rate(수직축 회전속도)의 추종항은 오차가 작을수록 큰 값을 갖는다.

$$r_v = \exp\left(-\|v_{xy} - v_{xy}^{cmd}\|_2^2 / 0.25\right), \tag{6}$$

$$r_\omega = \exp\left(-(\omega_z - \omega_z^{cmd})^2 / 0.25\right). \tag{7}$$

식 (6), (7)에서 v_{xy}와 ω_z는 평면 선속도와 수직축 각속도이며, 위첨자 cmd는 명령값이다. 분모 0.25의 단위는 각각 $(\mathrm{m/s})^2$, $(\mathrm{rad/s})^2$이며 보상 감소 폭을 정한다. 표 4의 비용항은 수직·roll/pitch 운동과 과도한 토크, 급격한 행동 변화 등을 억제한다. 원시 물리량으로 계산한 가중합에 제어 간격을 곱하고 음수 총보상은 0으로 제한한다. PPO로 할인 보상합을 최대화한다.

표 4. 제어 간격 적용 전 보상항별 가중치

Reward term	Weight
Planar velocity tracking / yaw-rate tracking	1 / 0.5
Squared vertical velocity	-2
Squared roll/pitch angular velocity	-0.05
Squared joint torque	-2×10^{-4}
Squared joint acceleration	-2.5×10^{-7}
Squared action change	-0.01
Disallowed contact count	-1
Joint-limit excess	-10
Foot air-time reward	1

3.4 정책 학습 환경 및 설정

물리 조건에 따라 달라지는 고장 후 반응을 학습하도록 마찰계수 0.5에서 1.25, 추가 질량 0에서 2 kg, 명목 모터 강도 $\pm 10\%$를 무작위화하였다. PD 이득도 K_p $\pm 5\%$, K_d $\pm 10\%$로 변화시키고 혼합 지형과 주기적인 외란을 적용하였다.

교사 인코더는 multi-layer perceptron (MLP)으로, 은닉층 [512, 256, 128]과 exponential linear unit (ELU)를 사용한다[2]. 본 구현의 Actor·Critic도 같은 은닉층 크기를 갖는다. 학생 인코더는 48차원 프레임을 64차원으로 변환한 뒤 세 개의 1차원 합성곱 층을 거쳐 8차원 특징을 출력한다[5]. Actor·Critic 입력은 현재 관측과 혼합 특징의 243차원이다.

병렬 환경 4,096개에서 환경당 24개 제어 시점의 경험으로 PPO를 갱신한다. 미래 보상의 가중치를 정하는 할인 계수 (discount factor) $\gamma = 0.99$, generalized advantage estimation (GAE) 계수 0.95, clip 계수 0.2, 갱신당 5회 학습과 4개 미니배치를 사용한다. 공동학습 초기 학습률(learning rate)은 10^{-5}이고 Kullback-Leibler (KL) divergence에 따라 조절한다. 학습 과정은 그림 3, 토크 저하율별 성능은 그림 4에 제시한다.

그림 3에서 학생 특징으로 전환할 때 감소한 보상은 후속 학습에서 회복된다. 교사를 43,000회까지 학습한 뒤 53,000회까지 학생 비중을 높였고, 77,500회의 학생 정책을 평가하였다. 전환 완료 시점의 평균 보상은 17.52에서 최종 19.70으로 증가하였다. 이는 바뀐 입력으로 정책이 보행을 학습한 과정이며, 고장 대응 성능은 다음 절의 조건별 평가로 확인한다.

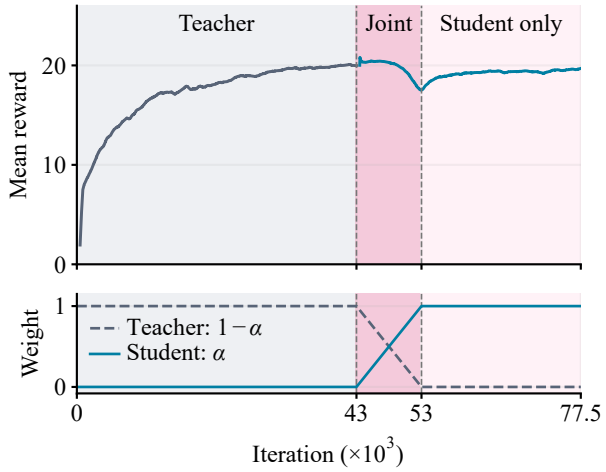


그림 3. 학습 단계별 평균 에피소드 보상(상단, 500회 이동평균)과 교사·학생 특징의 혼합 비중(하단).

표 5. 정책 비교를 위한 평가 조건

Item	Setting
Terrain	Mixed terrain; 5×12 cells of 8×8 m
Tasks	Forward : diagonal : lateral : sine = 2:1:1:2
Command / path	0.5 m/s; world +x; sine $A = 1.5, 2$ m, wavelength 16 m
Fault	12 joints $\times$ 5 levels (20–100%) + nominal; onset 2 s
Trials	3 evaluation seeds; 216 per joint/level/policy; 26,352 total

IV. 시뮬레이션 결과 및 성능 분석

4.1 비교 정책과 평가 조건

정상 조건만 학습한 Normal과 정상·토크 저하 조건을 학습한 Student를 비교한다. Normal은 실제 고장 배율과 표지를 포함한 특권 정보의 교사 인코더를, Student는 관측 이력 기반 학생 인코더를 사용한다. 평가 체크포인트는 각각 22,500회와 누적 77,500회이며, 각 정책은 단일 학습 시드로 학습하였다. 따라서 고장 학습·표현·학습량이 다른 두 정책 구성 전체의 성능을 비교한다.

표 5의 조건에서 초기 상태·물리 조건·지형·고장 일정을 두 정책에 동일하게 적용하고 관측 잡음과 외부 밀기는 해제하였다. 혼합 지형은 경사, 거친 경사, 계단과 장애물로 구성하며 +x 방향으로 난이도가 증가한다. 대각·횡이동은 몸체 yaw를 각각 $\pm 45°$, $\pm 90°$로 유지하며 세계 +x로 진행한다. 사인파에서는 몸체가 경로 접선을 따른다. 동일 상위 제어기가 경로를 속도 명령으로 변환하며, 실제 전달된 몸체좌표 명령을 추종 오차의 기준으로 사용한다.

base 링크의 접촉력 노름이 1 N을 초과하면 낙상, $x \geq 40.5$ m이고 횡오차 절댓값이 0.5 m 미만이면 완주로 종료한다. 고장 후 시간 상한은 경로 길이 L에 대해 $L/(0.1\,\mathrm{m/s}) + 30$ s로 정하여 445–504.62 s를 허용한다. 저속이나 정체로 조기 종료하지 않으며, 종료된 시행을 재시작하지 않는다.

생존율은 전체 N시행 중 낙상하지 않은 비율로 식 (8)과 같이 정의한다. 완주와 비낙상 상한 종료를 모두 포함하며, 고장 전 낙상도 실패로 센다.

$$S = \frac{100}{N} \sum_{i=1}^{N} I_i, \qquad I_i = \begin{cases} 0, & \text{낙상}, \\ 1, & \text{그 외 종료}. \end{cases} \tag{8}$$

여기서 I_i는 시행 i의 비낙상 지시값이다. S는 % 단위이며 완주율·평균 생존 시간이 아니다. 정책당 정상 216시행, 비영 저하율별 2,592시행, 관절·저하율별 216시행이다.

이동 명령 추종은 실제 몸체 v_x, v_y, ω_z와 같은 시점의 명령 간 오차로 평가한다. 경로 추종은 세계 위치 $\mathbf{p}(t)$를 기준 경로 $\mathbf{p}^{\mathrm{ref}}(s)$에 투영한 뒤, 그 차이의 단위 법선 방향 성분 $e_{\perp}(t)$를 사용한다. 이는 몸체 좌우 오차나 같은 시각 목표점까지의 거리가 아니다. 시행별 root mean square error (RMSE)는 식 (9)로 계산한다.

$$R_{u,i} = \sqrt{\frac{1}{K_i} \sum_{k \in V_i} e_{u,i,k}^2}, \qquad \overline{R}_u = \frac{1}{M_u} \sum_{i:K_i>0} R_{u,i}. \tag{9}$$

여기서 $u \in \{v_x, v_y, \omega_z, \perp\}$이며, 속도 오차는 실제값에서 현재 명령을 뺀 값, 경로 오차는 $e_{\perp}$이다. V_i는 2 s 이후 첫 종료 전 유효 표본 집합, K_i는 표본 수, M_u는 오차 계산이 가능한 시행 수이다. 0 명령도 포함하며 낙상 이후를 0으로 채우지 않는다. 유효 표본이 없으면 계산 불가이며 이번 자료의 누락은 없다. 시행별 RMSE를 평균하므로 시행의 유효 시간 표본 수로 가중하지 않는다. 정책별 종료 시점과 방문 지형이 달라 동일 시간·난이도의 오차 비교는 아니며 생존율과 함께 해석한다. 곡선 음영은 평가 시드 평균의 최소–최대이며 학습 시드 신뢰구간이 아니다.

4.2 토크 저하에 따른 보행 및 추종 성능

그림 4에서 정상 상태의 생존율은 Normal 98.61%, Student 99.07%로 유사하지만, 100% 토크 저하에서는 각각 52.08%, 89.24%이다. Student의 생존율 우위는 60%에서 11.11%p, 80%에서 27.16%p, 100%에서 37.15%p로 커진다. 큰 토크 저하에서 정상학습 정책의 낙상이 증가하는 데 비해 Student는 보행을 더 안정적으로 유지한다.

100% 저하에서 v_x, v_y, ω_z 명령 RMSE는 각각 0.226에서

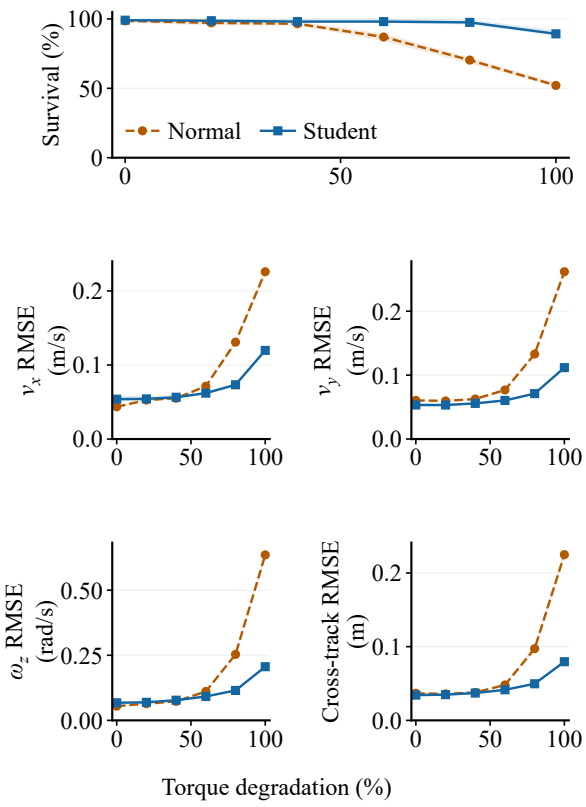


그림 4. 토크 저하율에 따른 생존율(상단)과 명령·경로 추종 RMSE(중단: v_x, v_y; 하단: ω_z, 경로 횡오차). 점은 전체 평균, 음영은 3평가 시드 평균의 최소–최대이다.

0.120 m/s, 0.262에서 0.112 m/s, 0.636에서 0.206 rad/s로 감소한다. 감소율은 각각 47.0%, 57.3%, 67.6%이다. 정상 상태의 v_x RMSE는 Normal 0.043 m/s, Student 0.054 m/s이고 낮은 저하의 회전속도 오차도 Normal이 작으므로, Student의 이점은 모든 조건의 정밀도 향상보다 큰 저하에서의 성능 유지에 있다.

경로 횡오차 RMSE도 100% 저하에서 0.225 m에서 0.080 m로 64.6% 감소한다. 생존율과 명령·경로 오차가 함께 개선되어, 낙상 회피와 요구된 움직임의 수행이 동시에 향상되었다. 다만 경로 위 정지에서도 횡오차는 작을 수 있으므로 생존율과 추종 오차를 실제 진행 여부와 함께 살펴본다.

4.3 과제별 주행 지속과 관절별 성능

표 6에서 네 과제 모두 Student의 생존율과 완주율이 높다. 전체 완주율도 Normal 23.84%에서 Student 86.73%로 증가하여, 생존율 향상과 실제 주행의 지속이 함께 나타났다. 생존율과 완주율의 차이는 낙상하지 않고 시간 상한에 도달한 시행이다. 일부 비낙상 시행에서는 30 s 동안 경로 진행 최고값의 증가가 0.5 m 미만인 정체도 관찰되었다. RL calf 100% 저하의 비낙상 시행 중 정체 경험은 Normal 185/188, Student 4/198이었다. 일시 정체 후 완주도 포함하는 보조 사례이다.

표 6. 100% 토크 저하의 과제별 생존율과 완주율(Normal / Student, %)

Task	Survival	Completion
Forward	49.07 / 88.89	21.99 / 86.11
Diagonal	59.72 / 90.74	29.86 / 88.43
Lateral	59.72 / 95.14	29.17 / 94.44
Sine	47.45 / 85.88	20.02 / 82.64

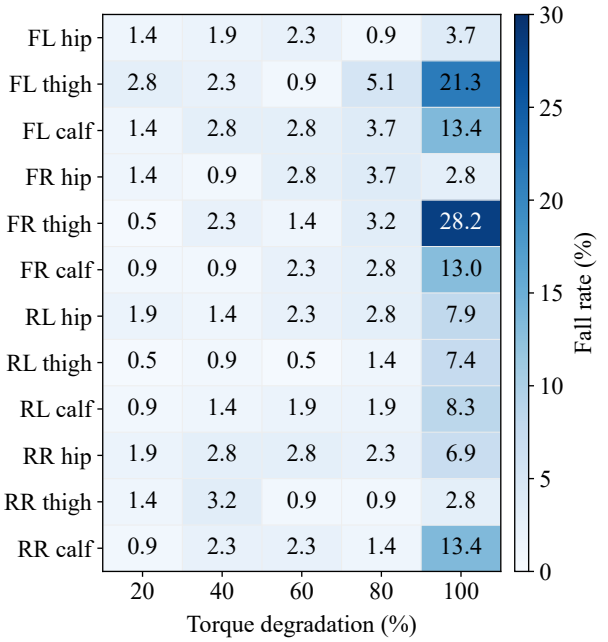


그림 5. Student의 관절·토크 저하율별 낙상률(%). 각 셀은 216시행이며, 색 범위는 0–30%이다.

그림 5는 전체 평균에 가려진 Student의 관절별 성능을 나타낸다. FL/FR은 좌/우 앞다리, RL/RR은 좌/우 뒷다리이다. 100% 저하에서 FR hip과 RR thigh의 낙상률은 각각 2.78%인 반면 FL thigh는 21.30%, FR thigh는 28.24%이다. 동일한 토크 저하율에서도 관절에 따라 보행 유지 성능이 달라진다.

V. 결론

본 논문에서는 단일 관절 토크 저하 학습과 관측 이력 표현을 결합한 교사·학생 기반 보행 제어 구성을 제시하였다. 단일 학습 시드의 두 고정 정책을 해당 과제·지형 혼합에서 비교한 결과, 60–100% 저하에서 Student의 생존율과 종료 전 명령·경로 추종 오차가 함께 개선되었다. 100% 저하에서는 생존율이 52.08%에서 89.24%로 높아지고 경로 횡오차

RMSE가 0.225 m에서 0.080 m로 낮아졌다. 향후 독립 학습 반복과 실제 로봇에서 재현성을 검증할 계획이다.

References

[1] N. Rudin, D. Hoeller, P. Reist, and M. Hutter, "Learning to walk in minutes using massively parallel deep reinforcement learning," in Proc. 5th Conf. Robot Learning (CoRL), London, UK, PMLR, vol. 164, pp. 91–100, 2022.

[2] D. Liu, T. Zhang, J. Yin, and S. See, "Saving the limping: Fault-tolerant quadruped locomotion via reinforcement learning," arXiv preprint arXiv:2210.00474v3, 2023.

[3] V. Makoviychuk et al., "Isaac Gym: High performance GPU based physics simulation for robot learning," in Proc. Neural Information Processing Systems Track on Datasets and Benchmarks (NeurIPS), Virtual, vol. 1, 2021.

[4] X. Wu, W. Dong, H. Lai, Y. Yu, and Y. Wen, "Adaptive control strategy for quadruped robots in actuator degradation scenarios," in Proc. 5th Int. Conf. Distributed Artificial Intelligence (DAI), Singapore, pp. 1–13, 2023.

[5] A. Kumar, Z. Fu, D. Pathak, and J. Malik, "RMA: Rapid motor adaptation for legged robots," in Proc. Robotics: Science and Systems (RSS), Virtual, 2021.

[6] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, "Proximal policy optimization algorithms," arXiv preprint arXiv:1707.06347, 2017.