4족 보행 로봇의 관절 토크 저하에 강건한 교사, 학생 기반 강화학습 보행 제어

Teacher–Student Reinforcement Learning for Robust Quadruped Locomotion under Joint Torque Degradation

요약 본 논문은 정상 상태와 단일 관절 토크 저하에 대응하는 교사, 학생 기반 강화학습 보행 제어 구성을 제시한다. 관측 이력 기반 학생은 고장 관절과 토크 저하율을 직접 입력받지 않는다. Unitree A1 시뮬레이션에서 정상학습 정책과 전진, 대각, 횡이동, 사인파 경로를 비교하였다. 토크 저하율이 100%일 때 생존율은 52.08%에서 89.24%로 높아지고, 종료 전 경로 횡오차의 시행별 root mean square error (RMSE) 평균은 0.225 m에서 0.080 m로 낮아져 낙상 감소와 추종 성능 개선을 함께 확인하였다.

Abstract Quadrupedal robots should maintain balance and execute commanded motion after joint torque degradation. We present a teacher–student reinforcement learning control configuration whose history-based student handles nominal and single-joint degraded conditions without direct fault inputs. Unitree A1 simulations compare the fixed student with a nominally trained policy, each trained with one seed, on matched mixed-terrain courses using forward, diagonal, lateral, and sinusoidal-path tasks. At 100% torque degradation, survival increased from 52.08% to 89.24%, while mean pre-termination cross-track root mean square error (RMSE) decreased from 0.225 to 0.080 m, averaged over the fixed task mixture. The results show simultaneous improvements in fall avoidance and motion tracking under severe torque degradation for these fixed policies and evaluated tasks.

Keywords: Quadrupedal locomotion, Joint torque degradation, Teacher–student learning, Joint learning

I. 서론

4족 보행 로봇은 발 디딤 위치와 다리의 움직임을 조절하여 계단을 오르내리고, 바퀴형 로봇의 이동이 제한되는 단차와 불규칙한 지형을 통과할 수 있다. 이러한 이동 능력을 구현하기 위해 강화학습을 활용한 보행 제어가 연구되고 있으며, 다양한 지면 조건에서 균형을 유지하고 이동 명령을 수행하는 정책이 개발되고 있다[1]. 그러나 안정적인 이동을 위해서는 지형 변화뿐 아니라 액추에이터의 노화나 손상에 따른 구동 성능의 변화도 고려해야 한다. 관절의 토크가 저하되면 몸체를 지지하고 추진하는 능력이 달라져, 정상 상태에서 학습한 정책으로는 보행을 유지하거나 요구된 속도와 방향을 따르기 어려울 수 있다. 따라서 관절의 토크가 저하되어도 균형을 유지하며 주어진 이동을 이어갈 수 있는 보행 정책이 필요하다.

본 논문에서는 정상 상태뿐 아니라 단일 관절의 토크가 저하된 상황에서도 이동을 지속할 수 있는 강화학습 기반 보행 정책을 제안한다. 이를 위해 시뮬레이션에서 단일 관절 토크 저하를 모델링하고, 교사, 학생 공동학습을 통해 학생이 현재 관측과 과거 관측 이력으로부터 제어에 필요한 로봇의 특성을 추정하도록 학습한다[2]. 학생은 추정한 특성을 보행 제어에 활용하며, 고장 관절이나 토크 저하율을 직접 입력받지 않고 하나의 정책으로 정상 상태와 관절 토크 저하 상황에 대응한다. 제안 정책은 정상 상태에서만 학습한 정책과 다양한 이동 명령 및 목표 경로에 대한 수행 성능을 비교하여 검증한다. 이를 통해 관절 토크 저하 상황에서 보행을 더 오래 유지하고 요구된 움직임을 더 정확하게 수행할 수 있음을 보인다.

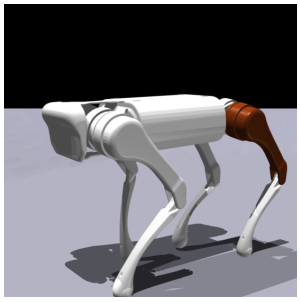
표 1. 로봇 및 제어 설정

Parameter	Value
Actuated joints	12 (hip, thigh, calf per leg)
Physics / policy interval	0.005 s / 0.02 s
Joint target	$q^{des} = q^0 + 0.25a_t$ (rad)
Nominal PD gains	$K_p = 20$ N·m/rad; $K_d = 0.5$ N·m·s/rad

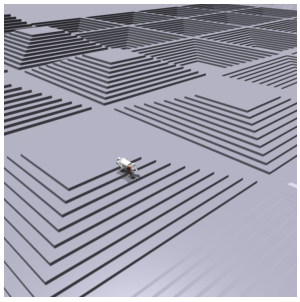
II. 시스템 모델

2.1 시뮬레이션 환경 및 제어 구조

Isaac Gym의 graphics processing unit (GPU) PhysX에서 Unitree A1을 모사한다[3]. 각 다리는 hip, thigh, calf로 구성되며, 전체 관절은 12개이다. 정책의 목표 관절각을 proportional-derivative (PD) 제어기가 토크로 변환하고, 몸체와 관절의 반응을 다음 관측에 반영하여 제어를 반복한다[1]. 로봇과 지형은 그림 1, 제어 설정은 표 1과 같다. 12차원 행동 a_t는 기준 자세 q^0에 더할 관절각을 정하며, 0.25 rad는 행동 배율이다. 0.02 s마다 새 목표를 출력하고, 그 사이에는 목표를 유지한 채 0.005 s 간격으로 물리를 계산한다.



(a) Unitree A1



(b) Isaac Gym 지형

그림 1. 로봇 모델과 시뮬레이션 환경

2.2 단일 관절 토크 저하 모델

관절 토크 저하는 PD 토크에 곱하는 고장 배율의 감소로 모델링한다[4]. 토크 저하율 $d \in [0, 1]$에 대해 고장 배율은 $1 - d$이며, $d = 0.4$이면 고장 배율은 0.6이다. PD 토크에 모터 강도 m_j와 고장 배율 η_j를 곱한 뒤 관절 한계 토크로 제한한다.

$$\tau_j^{PD} = K_p(q_j^{des} - q_j) - K_d\dot{q}_j, \tag{1}$$

$$\tau_j = \text{clip}(m_j\eta_j\tau_j^{PD}, -\tau_j^{max}, \tau_j^{max}). \tag{2}$$

식 (1), (2)에서 q_j^{des}, q_j, $\dot{q}_j$는 목표 관절각, 현재 관절각, 관절속도이며, K_p, K_d는 PD 이득이다. τ_j^{max}는 관절 j의 최대 허용 토크이며, clip은 출력을 $\pm\tau_j^{max}$로 제한한다. m_j는 [0.9, 1.1]에서 무작위화하여 고장과 별개인 $\pm 10\%$ 편차를 반영한다. 토크 저하율이 100%($d = 1$)이면 능동 토크가 0이지만, 관절 잠금과 달리 수동 운동은 유지된다.

고장은 선택된 관절 j_f에서 시점 t_f에 발생하며, 나머지 관절의 배율은 1로 유지한다.

$$\eta_j(t) = \begin{cases} 1 - d, & j = j_f,\ t \geq t_f, \\ 1, & \text{그 외}, \end{cases} \tag{3}$$

식 (3)의 j_f, t_f는 고장 관절과 발생 시점이다. 에피소드마다 관절 하나와 0, 20, 40, 60, 80, 100% 중 하나의 토크 저하율을 무작위로 선택한다. 시작 후 2 s부터 10 s 사이에 고장을 발생시키고 배율을 유지한다. 고장 전후를 한 에피소드에 포함하여, 정상 보행 중 반응이 달라져도 제어를 이어가도록 학습한다.

III. 교사, 학생 공동학습 기반 보행 정책

3.1 관측 및 이력 표현

고장 정보를 직접 받지 않는 학생에게는 행동 이후의 운동 반응이 단서가 된다. 따라서 현재 관측과 최근 1 s의 관측 이력을 함께 사용한다. 현재 관측 o_t는 로봇, 명령 정보 $\tilde{o}_t$ 48차원과 지형 높이 187차원이다[1]. $\tilde{o}_t$에는 선속도, 각속도, 중력 방향, 속도 명령 각 3차원과 관절각 편차, 관절속도, 이전 행동 각 12차원이 포함된다. 각 관측의 기호, 단위, 차원은 표 2와 같다.

표 2. 현재 관측의 구성

Component	Symbol	Unit	Dim.
Body linear velocity	v_t	m/s	3
Body angular velocity	ω_t	rad/s	3
Projected gravity	g_t	1	3
Linear velocity command	v_{xy}^{cmd}	m/s	2
Yaw rate command	ω_z^{cmd}	rad/s	1
Relative joint position	$q_t - q^0$	rad	12
Joint velocity	$\dot{q}_t$	rad/s	12
Previous action	a_{t-1}	1	12
Robot/command observation	$\tilde{o}_t$	mixed	48
Terrain heights	h_t	m	187
Current observation	o_t	mixed	235

표 3. 교사, 학생 인코더와 정책의 입출력

Path	Input → output
Teacher encoder	$45 \to z_t^T \in \mathbb{R}^8$
Student encoder	H_t: $50 \times 48 \to z_t^S \in \mathbb{R}^8$
Observation o_t	$48 + 187 = 235$
Training feature	$(1 - \alpha)z_t^T + \alpha z_t^S$: 8
Actor/Critic (train)	$[o_t, z_t]$: $235 + 8 = 243$
Actor (inference)	$[o_t, z_t^S]$: $235 + 8 = 243 \to a_t \in \mathbb{R}^{12}$

표 3의 교사 인코더는 마찰계수 1, 추가 질량 1, 유효 모터 강도 12, PD 이득 24, 몸체 속도 6, 고장 표지 1의 총 45차원 특권 물리 정보를 8차원 특징 z_t^T로 압축한다. 유효 모터 강도에는 고장 관절과 토크 저하율이 반영된다. 학생 인코더는 지형 높이를 제외한 로봇, 명령 정보 $\tilde{o}_t$를 50개 시점에 걸쳐 쌓은 $H_t = [\tilde{o}_{t-49}, \ldots, \tilde{o}_t]$의 50×48 이력을 convolutional neural network (CNN)로 처리하여 8차원 특징 z_t^S를 만든다[2, 5]. 부족한 과거 표본은 0으로 채운다. 평가 시 Actor는 현재 관측 235차원과 학생 특징 8차원을 결합한 243차원을 입력받아 12차원 행동을 출력한다. 몸체 속도와 지형 높이는 시뮬레이터에서 얻으므로, 실제 로봇 적용에는 별도의 측정과 추정이 필요하다.

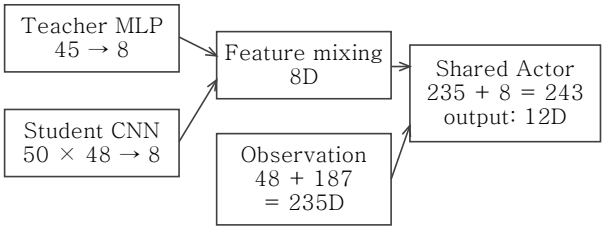


그림 2. 교사, 학생 공동학습 기반 보행 제어 구조

3.2 교사, 학생 공동학습

교사의 45차원 특권 물리 정보는 학생에게 별도 입력하지 않는다. 이에 교사 특징을 관측 이력으로 추정하는 구조와 특징 혼합 공동학습을 적용한다[2, 5]. 모방 오차가 남아 있어도 제어 정책이 학생 특징에 적응하도록, 다음 특징을 행동 정책(Actor)과 가치 함수(Critic)에 입력한다.

$$z_t = (1-\alpha) z_t^T + \alpha z_t^S. \tag{4}$$

식 (4)의 α는 학생 특징의 혼합 비중이다. 사전학습 교사로 초기화한 뒤 공동학습 갱신 횟수 n에 따라 $\alpha(n) = \min(n/10000, 1)$로 학생 비중을 높인다. 10,000회 이후에는 학생 특징만 사용하여 평가와 입력 경로를 맞춘다. 전환 중에는 proximal policy optimization (PPO) 손실에 모방항을 추가한다[6].

$$\mathcal{L} = \mathcal{L}_{PPO} + \frac{1-\alpha}{B} \sum_{i=1}^{B} \| z_i^S - \mathrm{sg}(z_i^T) \|_2. \tag{5}$$

스케줄과 평균 L2 거리의 모방 손실은 선행 연구를 따른다[2]. 식 (5)에서 $\mathcal{L}_{PPO}$는 정책 손실과 가치 함수 손실, B는 미니배치 크기, i는 배치 내 표본 번호, sg는 모방 목표의 gradient 차단 연산이다. 교사는 전환 중에도 PPO로 갱신되며, $\alpha = 1$ 이후에는 학생, Actor, Critic만 학습한다. 두 경로에서 학생 경로로 전환하는 구조는 그림 2에 나타냈다.

3.3 속도 추종 보상

보상은 속도 추종과 안정적인 운동을 함께 유도한다[1]. 평면 선속도와 몸체 z축 회전속도의 추종항은 오차가 작을수록 큰 값을 갖는다.

$$r_v = \exp\left(-\| v_{xy} - v_{xy}^{cmd} \|_2^2 / 0.25\right), \tag{6}$$

$$r_\omega = \exp\left(-(\omega_z - \omega_z^{cmd})^2 / 0.25\right). \tag{7}$$

식 (6), (7)에서 v_{xy}와 ω_z는 평면 선속도와 몸체 z축 회전속도이며, 위첨자 cmd는 명령값이다. 분모 0.25의 단위는 각각 $(\mathrm{m/s})^2$, $(\mathrm{rad/s})^2$이며 보상 감소 폭을 정한다. 표 4의 비용항은 수직 운동, roll/pitch 운동과 과도한 토크, 급격한 행동 변화 등을 억제한다. 원시 물리량으로 계산한 가중합에 제어 간격을 곱하고 음수 총보상은 0으로 제한한다. PPO로 할인 보상합을 최대화한다.

표 4. 제어 간격 적용 전 보상항별 가중치

Reward term	Weight
Planar velocity tracking / yaw rate tracking	1 / 0.5
Squared vertical velocity	-2
Squared roll/pitch angular velocity	-0.05
Squared joint torque	-2×10^{-4}
Squared joint acceleration	-2.5×10^{-7}
Squared action change	-0.01
Disallowed contact count	-1
Joint-limit excess	-10
Foot air-time reward	1

3.4 정책 학습 환경 및 설정

물리 조건에 따라 달라지는 고장 후 반응을 학습하도록 마찰계수 0.5에서 1.25, 추가 질량 0에서 2 kg, 명목 모터 강도 $\pm 10\%$를 무작위화하였다. PD 이득도 K_p $\pm 5\%$, K_d $\pm 10\%$로 변화시키고 혼합 지형과 주기적인 외란을 적용하였다.

교사 인코더는 multi-layer perceptron (MLP)으로, 은닉층 [512, 256, 128]과 exponential linear unit (ELU)를 사용한다[2]. 본 구현의 Actor, Critic도 같은 은닉층 크기를 갖는다. 학생 인코더는 48차원 프레임을 64차원으로 변환한 뒤 세 개의 1차원 합성곱 층을 거쳐 8차원 특징을 출력한다[5]. Actor, Critic 입력은 현재 관측과 혼합 특징의 243차원이다.

병렬 환경 4,096개에서 환경당 24개 제어 시점의 경험으로 PPO를 갱신한다. 미래 보상의 가중치를 정하는 할인 계수 (discount factor) $\gamma = 0.99$, generalized advantage estimation (GAE) 계수 0.95, clip 계수 0.2, 갱신당 5회 학습과 4개 미니배치를 사용한다. 공동학습 초기 학습률(learning rate)은 10^{-5}이고 Kullback-Leibler (KL) divergence에 따라 조절한다. 학습 과정은 그림 3, 토크 저하율별 생존율과 추종 오차는 그림 4, 5에 제시한다.

그림 3의 상단은 평균 에피소드 보상의 500회 이동평균, 하단은 교사, 학생 특징의 혼합 비중이다. 학생 특징으로 전환할 때 감소한 보상은 후속 학습에서 회복된다. 교사를 43,000회까지 학습한 뒤 53,000회까지 학생 비중을 높였고, 77,500회의 학생 정책을 평가하였다. 전환 완료 시점의 평균 보상은 17.52에서 최종 19.70으로 증가하였다. 이는 바뀐 입력으로 정책이 보행을 학습한 과정이며, 고장 대응 성능은 다음 절의 조건별 평가로 확인한다.

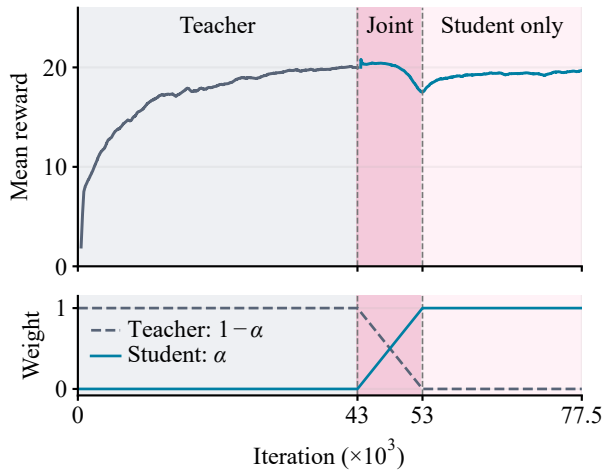


그림 3. 학습 보상과 교사, 학생 특징의 혼합 비중

IV. 시뮬레이션 결과 및 성능 분석

4.1 비교 정책과 평가 조건

정상 상태만 학습한 정상학습 정책(Normal)과 정상 상태 및 관절 토크 저하 조건을 학습한 고장대응 정책(Student)을 비교한다. Normal은 실제 고장 배율과 고장 표지를 포함한 특권 물리 정보의 교사 인코더를, Student는 관측 이력 기반 학생 인코더를 사용한다. 평가 체크포인트는 각각 22,500회와 누적 77,500회이며, 각 정책은 단일 학습 시드로 학습하였다. 고장 학습, 관측 표현, 학습량이 다른 두 정책 구성 전체를 비교 대상으로 한다.

표 5의 혼합 지형은 경사, 거친 경사, 계단, 장애물로 구성하며 세계 $+x$ 방향으로 난이도가 증가한다. 전진, 좌우 대각 이동, 좌우 횡이동, 사인파 경로를 2:1:1:2 비율로 평가한다. 대각 이동과 횡이동은 몸체 방향을 각각 $\pm 45°$, $\pm 90°$로 유지하며 세계 $+x$ 방향으로 진행하고, 사인파에서는 몸체가 경로 접선을 따른다. 두 정책에 초기 상태, 물리 조건, 지형, 고장 일정을 동일하게 적용하고 관측 잡음과 외부 밀기는 해제하였다. 동일한 상위 제어기로 경로를 속도 명령으로 변환하며 목표 이동 속도의 크기는 0.5 m/s로 설정하였다.

평가 지표는 생존율, 이동 명령 추종 오차, 경로 횡오차이다. 생존율 S는 전체 N시행 중 평가 종료까지 낙상하지 않은 시행의 비율로 식 (8)과 같이 계산한다. 몸체의 접촉력 노름이 1 N을 초과하면 낙상으로 판단한다.

$$S = \frac{100}{N}\sum_{i=1}^{N} I_i, \qquad I_i = \begin{cases} 0, & \text{낙상,} \\ 1, & \text{낙상 없이 종료.} \end{cases} \tag{8}$$

여기서 I_i는 시행 i의 비낙상 지시값이다. 이동 명령 추종

표 5. 정책 비교를 위한 평가 조건

Item	Setting
Terrain	Mixed terrain; 5×12 cells of 8×8 m
Tasks	Forward : diagonal : lateral : sine = 2:1:1:2
Command / path	0.5 m/s; world $+x$; sine $A = 1.5, 2$ m, wavelength 16 m
Fault	12 joints $\times$ 5 levels (20~100%) + nominal; onset 2 s
Trials	3 evaluation seeds; 216 per joint/level/policy; 26,352 total

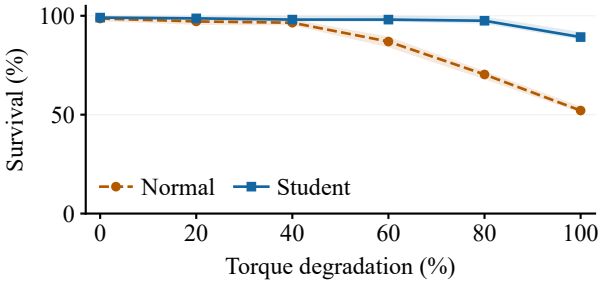


그림 4. 토크 저하율에 따른 생존율(%)

오차는 몸체좌표계의 실제 속도 v_x, v_y, ω_z와 같은 시점에 전달된 명령의 차이로 정의한다. 경로 횡오차 $e_\perp$는 세계좌표계의 몸체 위치와 기준 경로의 근사 투영점 사이 변위를 경로의 단위 법선 방향으로 투영한 값이다. 각 오차의 시행별 root mean square error (RMSE)와 시행 평균은 식 (9)로 계산한다.

$$R_{u,i} = \sqrt{\frac{1}{K_i}\sum_{k\in V_i} e_{u,i,k}^2}, \qquad \overline{R}_u = \frac{1}{M_u}\sum_{i:K_i>0} R_{u,i}. \tag{9}$$

여기서 $u \in \{v_x, v_y, \omega_z, \perp\}$는 오차의 종류, V_i는 고장 발생 시점인 2 s부터 시행 종료 전까지의 유효 표본 집합, K_i는 표본 수, M_u는 유효 표본이 있는 시행 수이다. 명령이 0인 축도 포함하며, 낙상 이후의 표본은 오차 계산에서 제외한다. 시행별 RMSE를 동일 가중치로 평균하고, 정책별 유효 구간이 다르므로 생존율과 함께 해석한다.

4.2 큰 관절 토크 저하에서의 보행 및 추종 성능 유지

Student는 관절 토크 저하가 큰 조건에서 보행 유지와 이동 명령 추종 성능을 함께 개선하였다. 그림 4에서 두 정책의 생존율은 정상 상태에서 유사하지만, 토크 저하율이 커질수록 Student의 우위가 뚜렷해진다. 토크 저하율이 100%일 때 생존율은 Normal 52.08%에서 Student 89.24%로 37.15%p 높아졌다. 그림 4, 5의 점은 전체 시행 평균이며, 음영은 세

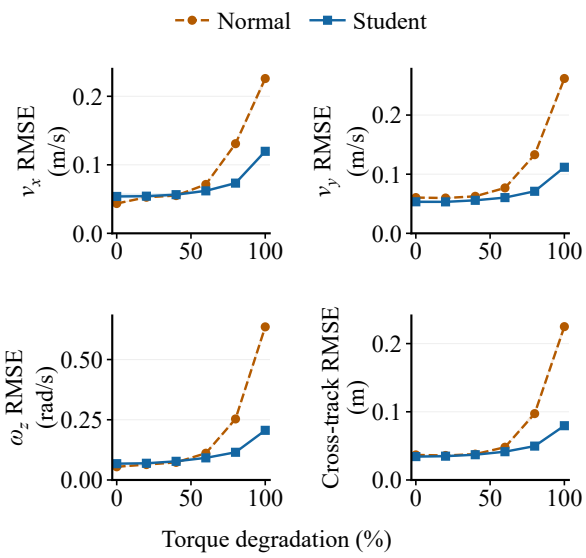


그림 5. 토크 저하율에 따른 이동 명령 추종 오차와 경로 횡오차

표 6. 토크 저하율 100%에서 과제별 생존율과 완주율(%)

Task	Survival Normal / Student	Completion Normal / Student
Forward	49.07 / 88.89	21.99 / 86.11
Diagonal	59.72 / 90.74	29.86 / 88.43
Lateral	59.72 / 95.14	29.17 / 94.44
Sine	47.45 / 85.88	20.02 / 82.64

평가 시드별 평균의 최솟값과 최댓값 사이를 나타낸다.

보행 유지의 개선은 요구된 움직임의 수행으로 이어졌다. 그림 5의 상단은 v_x, v_y 이동 명령 추종 오차, 하단은 ω_z 이동 명령 추종 오차와 경로 횡오차이다. 토크 저하율이 100%일 때 Student는 세 축의 이동 명령 추종 오차를 모두 낮추었으며, 경로 횡오차 RMSE도 0.225 m에서 0.080 m로 64.6% 감소하였다. 반면 정상 상태의 v_x 오차와 낮은 토크 저하율의 회전속도 오차는 Normal이 더 작았다. 따라서 Student의 주요 이점은 큰 관절 토크 저하에서도 보행을 유지하며 명령과 경로를 수행하는 데 있다.

4.3 주행 완주와 고장 관절별 보행 유지 성능

생존율 향상이 실제 주행으로 이어지는지 확인하기 위해 표 6에서 과제별 생존율과 완주율을 함께 비교한다. 완주율은 전체 시행 중 세계 $x \geq 40.5$ m에 도달하고 경로 횡오차의 절댓값이 0.5 m 미만인 시행의 비율이다. 토크 저하율이 100%일 때 Student는 네 과제 모두에서 생존율과 완주율이 높았으며, 전체 완주율은 Normal 23.84%에서 Student 86.73%로 증가하였다. Normal에서는 낙상하지 않았지만 완주하지 못한 시행이 많았고, 일부는 30 s 동안 경로 진행

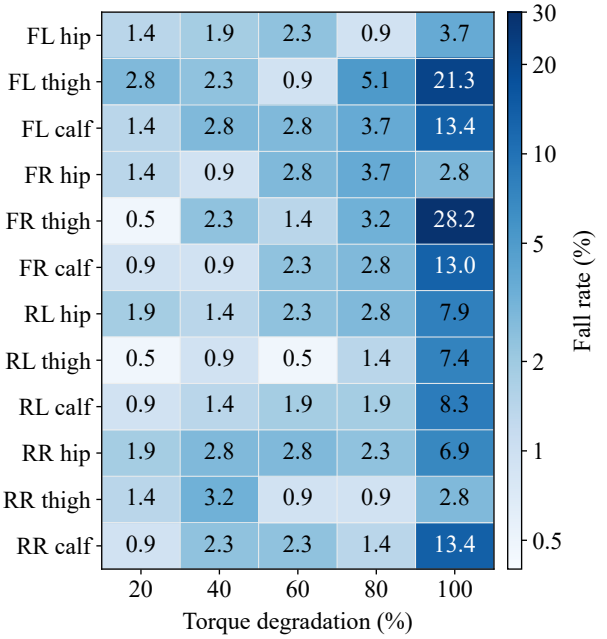


그림 6. Student의 고장 관절과 토크 저하율에 따른 낙상률(%)

최고값의 증가가 0.5 m 미만인 정체를 보였다. 왼쪽 뒷다리(RL)의 calf 토크 저하율이 100%인 비낙상 시행 중 정체를 경험한 시행은 Normal 185/188, Student 4/198이었다.

같은 토크 저하율에서도 고장 관절에 따라 Student의 보행 유지 성능이 달랐다. 그림 6의 각 셀은 216시행의 낙상률이며, 작은 낙상률의 차이를 구분하도록 색에 0.4~30% 범위의 로그 스케일을 적용하였다. FL/FR은 좌/우 앞다리, RL/RR은 좌/우 뒷다리이다. 토크 저하율이 100%일 때 FR hip의 낙상률은 2.78%인 반면 FR thigh는 28.24%로, 고장 관절에 따른 성능 차이가 남아 있다.

V. 결론

본 논문에서는 단일 관절 토크 저하 학습과 관측 이력 표현을 결합한 교사, 학생 기반 보행 제어 구성을 제시하였다. 단일 학습 시드의 두 고정 정책을 해당 주행 과제와 혼합 지형에서 비교한 결과, 토크 저하율 60~100%에서 Student는 생존율을 높이고 종료 전 이동 명령 추종 오차와 경로 횡오차를 낮추었다. 토크 저하율이 100%일 때 생존율이 52.08%에서 89.24%로 높아지고 경로 횡오차 RMSE가 0.225 m에서 0.080 m로 낮아졌다. 향후 독립 학습 반복과 실제 로봇에서 재현성을 검증할 계획이다.

References

[1] N. Rudin, D. Hoeller, P. Reist, and M. Hutter, "Learning to walk in minutes using massively parallel deep reinforcement learning," in Proc. 5th Conf. Robot Learning (CoRL), London, UK, PMLR, vol. 164, pp. 91–100, 2022.

[2] D. Liu, T. Zhang, J. Yin, and S. See, "Saving the limping: Fault-tolerant quadruped locomotion via reinforcement learning," arXiv preprint arXiv:2210.00474v3, 2023.

[3] V. Makoviychuk et al., "Isaac Gym: High performance GPU based physics simulation for robot learning," in Proc. Neural Information Processing Systems Track on Datasets and Benchmarks (NeurIPS), Virtual, vol. 1, 2021.

[4] X. Wu, W. Dong, H. Lai, Y. Yu, and Y. Wen, "Adaptive control strategy for quadruped robots in actuator degradation scenarios," in Proc. 5th Int. Conf. Distributed Artificial Intelligence (DAI), Singapore, pp. 1–13, 2023.

[5] A. Kumar, Z. Fu, D. Pathak, and J. Malik, "RMA: Rapid motor adaptation for legged robots," in Proc. Robotics: Science and Systems (RSS), Virtual, 2021.

[6] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, "Proximal policy optimization algorithms," arXiv preprint arXiv:1707.06347, 2017.