단일 관절 토크 저하에 강인한 4족 로봇의 강화학습 보행 제어

Reinforcement Learning for Robust Quadruped Locomotion under Single-Joint Torque Degradation

변지훈 · 유은빈 · 최서경 · 김준영 · 정소이*
Jihun Byun · Eunbin Yu · Seokyung Choi · Junyoung Kim · Soyi Jung*
아주대학교 전자공학과
Department of Electrical and Computer Engineering, Ajou University
*Corresponding author: sjung@ajou.ac.kr

요약 단일 관절의 토크 저하에 대응하는 기존 교사·학생 공동학습 방식을 적용한 4족 보행 정책을 구성한다. 특권 물리 정보를 사용하는 교사와 관측 이력을 사용하는 학생을 공동학습하고, 평가 시에는 고장 정보를 직접 받지 않는 학생만 사용한다. Isaac Gym의 Unitree A1에서 12개 관절과 6개 손실 수준을 시험하였다. 완전 손실에서 생존율은 정상 학습 정책의 41.49%에서 88.89%로 증가하였다. 전진속도 RMSE는 0.317 m/s에서 0.175 m/s로, yaw-rate RMSE는 0.753 rad/s에서 0.268 rad/s로 감소하였다. 관절별 분석으로 고장 후 명령 추종의 취약 조건을 구분하였다.

Abstract We construct a quadruped policy for single-joint torque loss by applying an existing joint-training framework with privileged Teacher and history-based Student representations. Inference uses only the Student without explicit fault information. We evaluate Unitree A1 in Isaac Gym across 12 joints and six loss settings. Under complete torque loss, survival increases from 41.49% for a fault-naive policy to 88.89%. Forward-velocity RMSE decreases from 0.317 to 0.175 m/s, and yaw-rate RMSE decreases from 0.753 to 0.268 rad/s. Joint-wise analysis identifies conditions with reduced command-tracking performance after fault onset.

Keywords: Quadrupedal locomotion, Actuator degradation, Teacher–student learning, Joint learning

I. 서론

4족 보행 로봇은 비정형 지형에서 이동할 수 있어 시설 점검과 탐사 등에 활용될 수 있다. 최근에는 강화학습과 병렬 시뮬레이션을 이용해 다양한 환경의 보행 정책을 학습하는 접근이 발전하고 있다[1]. 그러나 정상 구동 성능을 전제로 학습한 정책은 모터 출력이 저하되면 의도한 관절 운동을 만들지 못할 수 있다. 단일 관절의 변화도 지지와 추진에 영향을 주므로 고장 후 균형과 이동을 함께 유지해야 한다.

본 연구에서는 기존 교사·학생 공동학습 방식[2]을 단일 관절 토크 저하 조건에 적용하여 4족 로봇의 보행 정책을 학습한다. 시뮬레이션의 물리 정보를 사용하는 교사와 최근 몸체·관절 반응을 사용하는 학생을 함께 학습한다. 교사의 특징을 학생의 특징으로 점진적으로 전환하면서 보행 정책도 함께 갱신하고, 평가 시에는 고장 관절과 손실 정도를 직접 입력하지 않는 학생만 사용한다. Unitree A1 시뮬레이션에서 12개 관절과 6개 토크 손실 수준을 시험하여, 고장 후 생존율과 전진속도·yaw-rate 추종 성능을 평가하고 관절별 이동 특성을 분석한다.

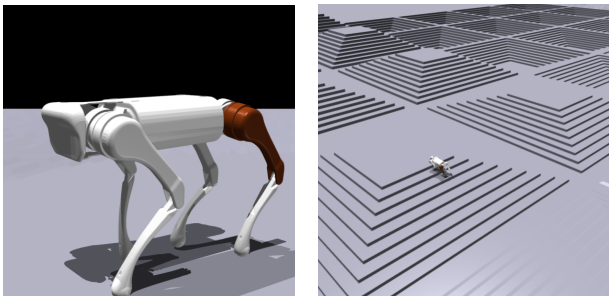
고장 대응 보행의 목표는 몸체가 넘어지지 않는 상태를 유지하면서 주어진 이동 명령을 수행하는 것이다. 따라서 정상 정책과의 비교에서 낙상 여부, 속도 추종 오차, 실제 전방 이동량을 함께 살펴본다. 특히 같은 토크 손실률에서도 손상된 관절에 따라 명령 수행이 달라지는지를 분석하여, 단일 평균 성능에 가려지는 취약 조건을 구분한다.

II. 시스템 모델

2.1 시뮬레이션 환경 및 제어 구조

Isaac Gym[3]의 GPU PhysX에서 12개 관절을 갖는 Unitree A1을 모사한다. 각 다리의 관절은 hip, thigh, calf이다. 정책이 출력한 목표 관절각을 PD 제어기가 토크로 변환하고, 다음 시점의 몸체·관절 반응을 정책에 되돌려 주는 폐루프를 구성한다[1]. 그림 1은 사용한 로봇 모델과 지형 환경이며, 주요 설정은 표 1에 정리하였다.

물리 계산은 0.005 s 간격으로 수행하고 정책은 네 번의 물리 계산마다 갱신한다. 따라서 정책의 제어 주기는 0.02 s이며, 한 시점의 목표 관절각은 다음 정책 출력까지 유지된다. 행동 a_t는 12개 관절의 기준 자세 q^0에 더할 각도 변화를 나타낸다. 이 구조에서 강화학습 정책은 관절별 토크를 직접 생성하는 대신 목표 자세를 조절하여 몸체 운동과 접촉 상태의 변화에 대응한다.



(a) Unitree A1 (b) Isaac Gym 지형

그림 1. 로봇 모델과 시뮬레이션 환경

표 1. 로봇 및 제어 설정

Parameter	Value
Actuated joints	12 (hip, thigh, calf per leg)
Physics / policy interval	0.005 s / 0.02 s
Joint target	$q^{des} = q^0 + 0.25a_t$ (rad)
Nominal PD gains	$K_p = 20$ N·m/rad; $K_d = 0.5$ N·m·s/rad

2.2 단일 관절 토크 저하 모델

토크 배율로 구동기 저하를 나타내는 모델[4]을 단일 관절에 적용한다. 고장 이후 선택된 관절의 배율은 $\eta_j = 1 - d$, 다른 관절은 1이다. $d \in [0, 1]$은 토크 손실률이며 $d = 0.4$는 명목 출력의 40% 손실을 뜻한다. PD 토크에 모터 강도 m_j와 고장

배율을 곱하고 관절 한계 토크로 포화한다.

$$\tau_j^{PD} = K_p(q_j^{des} - q_j) - K_d\dot{q}_j \tag{1}$$

$$\tau_j = \text{clip}(m_j\eta_j\tau_j^{PD}, -\tau_j^{max}, \tau_j^{max}) \tag{2}$$

m_j는 고장과 별도로 [0.9, 1.1]에서 무작위화하며, 이는 명목 모터 강도의 $\pm$10%에 해당한다. $d = 1$에서는 능동 토크가 상실되며 수동 관절 운동은 유지된다.

고장 시점 t_f를 포함한 관절 배율은 다음과 같이 정의한다.

$$\eta_j(t) = \begin{cases} 1-d, & j = j_f,\ t \geq t_f, \\ 1, & \text{그 외}, \end{cases} \tag{3}$$

여기서 j_f는 손상 관절이다. 학습 에피소드마다 손실률을 0, 20, 40, 60, 80, 100% 중 하나로 선택하고, 손상 관절은 전체 12개 중 무작위로 선택한다. 공동학습 환경에서는 시작 후 2–10 s 사이에 고장을 발생시키고 이후 해당 배율을 유지한다. 고장 전의 정상 보행과 고장 발생 후의 운동 변화를 한 에피소드에 포함하여, 학생 정책이 변화가 발생한 상태에서 보행을 이어가도록 학습한다.

고장 배율과 모터 강도 무작위화는 서로 다른 역할을 갖는다. m_j는 정상 구동 특성의 편차를, d는 특정 관절에 추가되는 출력 손실을 나타낸다. 토크 한계는 두 배율을 적용한 뒤 작용하므로, 출력 포화 상태를 포함한 폐루프 운동 반응이 정책의 다음 관측에 반영된다.

III. 교사·학생 공동학습 기반 보행 정책

3.1 관측 및 이력 표현

현재 관측 o_t는 기존 보행 연구[1]를 바탕으로 로봇·명령 관측 48차원과 지형 높이 187차원으로 구성된다(표 2). 관절각은 기준 자세와의 차이이다. 표의 단위는 관측 스케일 적용 전 물리량이며, 중력 방향과 행동은 무차원이다.

표 2. 현재 관측의 구성

Component	Symbol	Unit	Dim.
Body linear velocity	v_t	m/s	3
Body angular velocity	ω_t	rad/s	3
Projected gravity	g_t	–	3
Linear velocity command	v_{xy}^{cmd}	m/s	2
Yaw-rate command	ω_z^{cmd}	rad/s	1
Relative joint position	$q_t - q^0$	rad	12
Joint velocity	$\dot{q}_t$	rad/s	12
Previous action	a_{t-1}	–	12
Robot/command observation	$\tilde{o}_t$	mixed	48
Terrain heights	h_t	m	187
Current observation	o_t	mixed	235

표 3. 교사·학생 인코더와 공유 Actor의 입출력

Path	Input $\rightarrow$ output
Teacher encoder	Privileged information: $45 \rightarrow z_t^T \in \mathbb{R}^8$
Privileged components	Friction 1, mass 1, motor strength 12, PD gains 24, body velocities 6, fault flag 1
Student encoder	$H_t = [\tilde{o}_{t-49}, \ldots, \tilde{o}_t]$: $50 \times 48 \rightarrow z_t^S \in \mathbb{R}^8$
Training feature	$z_t = (1-\alpha)z_t^T + \alpha z_t^S$: 8
Actor/Critic (training)	$[o_t, z_t]$: $235 + 8 = 243$
Actor (inference)	$[o_t, z_t^S]$: $235 + 8 = 243 \rightarrow a_t \in \mathbb{R}^{12}$

학생의 시간 합성곱 인코더는 최근 50개 관측(약 1 s)에서 행동과 운동 반응의 관계를 추출한다[2, 5]. 없는 과거 표본은 0으로 채운다. 지형 높이는 이력에서 제외하고 현재 관측으로 Actor에 제공하며, 몸체 속도와 함께 시뮬레이터에서 획득한다.

교사는 마찰계수, 몸체 질량, 모터 강도와 PD 이득을 압축해 보행 정책에 전달한다. 이때 관절별 유효 모터 강도에는 손상 위치와 정도가 반영되며, 추가 고장 표지는 정상 상태와 손상 상태를 구분한다. 학생은 이러한 물리 정보를 직접 받는 대신 목표 행동 이후 관절과 몸체가 어떻게 반응했는지를 입력으로 사용한다. 이전 행동과 현재 관절 운동의 관계가 시간에 따라 누적되므로, 한 시점의 자세뿐 아니라 출력 저하 이후의 운동 변화도 표현에 포함할 수 있다.

현재 관측과 학생 특징은 서로 다른 정보를 제공한다. 235차원 현재 관측은 속도 명령과 즉시 측정된 운동 상태, 주변 지형을 전달하고, 8차원 학생 특징은 최근 반응을 압축한다. 두 정보를 결합한 Actor는 현재 목표와 누적된 운동 반응을 함께 이용하여 다음 목표 관절각을 생성한다. 고장 이후에도 동일한 입력 구조와 하나의 Actor를 사용한다.

3.2 속도 추종 보상

기존 병렬 보행 정책의 보상 구성[1]을 바탕으로 평면 선속도와 yaw-rate의 추종 보상은 각각 다음과 같다.

$$r_v = \exp\left(-\|v_{xy} - v_{xy}^{cmd}\|_2^2/0.25\right) \tag{4}$$

$$r_\omega = \exp\left(-(\omega_z - \omega_z^{cmd})^2/0.25\right) \tag{5}$$

추종항과 보행 안정성을 위한 비용·보상항의 가중치는 표 4와 같다. 각 항은 원시 물리량으로 계산하고, 가중합에 제어 간격을 곱한 뒤 음수 총보상을 0으로 제한한다. PPO[6]로 할인 보상합을 최대화한다.

전진속도만 보상하면 횡방향 움직임이나 몸체 회전을 동반한 이동에도 높은 보상이 주어질 수 있으므로, 평면 속도와 yaw-rate를 함께 추종하도록 구성하였다. 또한 수직 속도와 roll/pitch 각속도 비용은 몸체의 큰 진동을 억제하고, 관절 토크·가속도·행동 변화 비용은 급격한 제어 입력을 줄이는 역할을 한다. 고장 조건에서도 같은 보상 구성을 사용하여 명령 추종과 몸체 안정성을 함께 학습한다.

표 4. 제어 간격 적용 전 보상항별 가중치

Reward term	Weight
Planar velocity tracking / yaw-rate tracking	1 / 0.5
Squared vertical velocity	-2
Squared roll/pitch angular velocity	-0.05
Squared joint torque	-2×10^{-4}
Squared joint acceleration	-2.5×10^{-7}
Squared action change	-0.01
Disallowed contact count	-1
Joint-limit excess	-10
Foot air-time reward	1

3.3 교사·학생 공동학습

교사 특징을 이력 기반 학생 특징으로 대체하는 구조[5]와 특징 혼합 공동학습[2]을 적용한다. 모방 오차가 남아도 정책이 학생 특징으로 보행을 학습하도록, 두 특징을 혼합해 Actor 및 Critic에 입력한다.

$$z_t = (1-\alpha) z_t^T + \alpha z_t^S \tag{6}$$

사전학습 교사로 초기화하고 공동학습 10,000회 동안 α를 0에서 1까지 선형 증가시킨다. 전환 중에는 PPO 손실에 모방항을 추가한다.

공동학습 회차를 n이라 하면 혼합 비중은 $\alpha(n) = \min(n/10000, 1)$이다. $\alpha = 0$에서는 교사 특징으로 행동을 생성하면서 학생이 그 특징을 학습하고, 중간 구간에서는 학생 특징의 비중을 증가시킨다. $\alpha = 1$ 이후에는 학생 특징만으로 환경과 상호작용한다. 따라서 학습 후반부와 평가 시점의 Actor 입력 경로가 일치한다.

$$\mathcal{L} = \mathcal{L}_{PPO} + \frac{1-\alpha}{B} \sum_{i=1}^{B} \| z_i^S - \mathrm{sg}(z_i^T) \|_2 \tag{7}$$

혼합 스케줄과 손실은 선행 연구[2]를 따른다. B는 미니배치 크기, sg는 모방 목표의 gradient 차단 연산이다. 교사는 PPO 경로로 갱신하며 α=1 이후에는 학생·Actor·Critic를 학습한다. 병렬 환경 4,096개, 할인율 0.99, GAE 계수 0.95, PPO clip 계수 0.2를 사용하였다. 입력 경로와 특징 혼합은 그림 2에 나타내었다.

모방항에서 교사 특징을 고정 목표로 사용하는 것은 학생 인코더의 학습 방향을 정의하기 위한 것이다. 교사 인코더는 전환 구간의 PPO 경로에서 계속 갱신되며, 학생 인코더 역시 혼합 특징을 통해 정책 학습에 참여한다. 모방항의 비중을 학생 특징의 사용 비중과 반대로 감소시켜, 학습 초반에는 물리 정보를 반영한 표현을 익히고 후반에는 학생이 생성한 표현에서 직접 보행 성능을 개선한다.

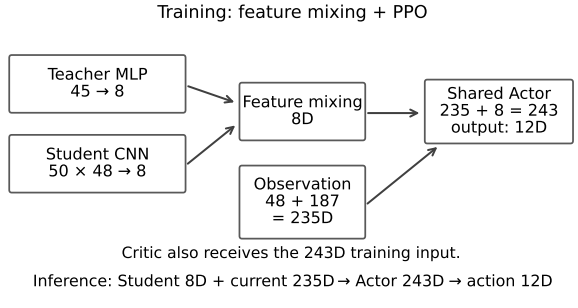


그림 2. 교사·학생 특징 인코딩과 공동학습 및 추론 구조

3.4 정책 학습 환경 및 설정

학습에는 마찰계수 0.5–1.25, 추가 질량 0–2 kg, 명목 모터 강도 ±10%의 무작위화를 적용하였다. PD 이득은 명목값에 대해 K_p ±5%, K_d ±10%로 변화시켰다. 혼합 지형과 주기적인 외란을 포함하여, 동일한 고장 수준에서도 지면 접촉과 몸체 반응이 달라지는 조건에서 정책을 학습하였다.

교사 인코더와 공유 Actor·Critic는 512–256–128 은닉층과 ELU 활성함수를 사용한다. 학생 인코더는 각 48차원 프레임을 64차원으로 변환한 뒤, 세 개의 시간 합성곱 층으로 50개 프레임의 관계를 처리하고 최종 8차원 특징을 출력한다. Actor와 Critic는 현재 관측과 혼합 특징을 결합한 243차원 입력을 공유한다.

4,096개 병렬 환경에서 환경당 24개 제어 시점의 경험을 수집한 뒤 PPO를 갱신하였다. 각 갱신에는 5회 학습과 4개 미니배치를 사용한다. 공동학습의 초기 학습률은 10^{-5}이며 KL divergence에 따라 조절한다. 고장 발생 후의 행동과 관측도 현재 정책으로 수집하여, 학생 특징에 따른 운동 반응이 다음 정책 갱신에 반영되도록 하였다.

IV. 시뮬레이션 결과 및 평가

4.1 평가 조건과 지표

정상 조건에서 학습한 정책(Normal)과 교사·학생 공동학습을 거친 학생 정책(Student)을 비교하였다. 두 정책은 각각 seed 1로 학습하였으며, 평가에서는 초기 물리 조건·지형·고장 일정을 동일하게 설정하였다.

각 관절·손실률 조합에 평가 seed 3개와 seed별 16개 시행을 배정하였다. 조건당 48회, 손실률당 576회, 정책당 전체 3,456회이다. 고장 시점부터 20 s 동안 관찰하며, 평가 중 종료된 로봇을 다시 초기화하여 같은 시행의 성능을 누적하지 않는다. 정상 조건도 동일한 관측 구간으로 집계하여 정책별 차이를 비교한다.

표 5. 정책 비교를 위한 평가 조건

Item	Setting
Command	v_x=0.5 m/s; v_y=ω_z=0
Conditions	12 joints × d∈{0,.2,.4,.6,.8,1}
Onset / observation	2–10 s / 20 s after onset
Trials	Evaluation seeds 301–303 × 16; 48 per joint/loss
Failure	Base contact force 〉1 N; pre-fault failure included

혼합 지형과 물리 무작위화는 유지하고 관측 잡음·외부 밀기·curriculum은 해제하였다. 생존율은 고장 전 실패를 포함한 전체 시행 중 종료 시 생존한 비율이다. 명령 추종 오차는 고장 후 생존 구간의 속도 표본 K개로 계산하였다.

$$\mathrm{RMSE}_u = \sqrt{\frac{1}{K} \sum_{k=1}^{K} (u_k - u^{cmd})^2} \tag{8}$$

여기서 $u \in \{v_x, v_y, \omega_z\}$이며 각 명령은 0.5 m/s, 0 m/s, 0 rad/s이다. 명령 추종 시간율 Q_{20}은 $|v_x - 0.5| \le 0.1$ m/s, $|v_y| \le 0.1$ m/s, $|\omega_z| \le 0.2$ rad/s를 동시에 만족한 생존 시간을 고장 후 전체 20 s로 나눈 값이다. 전진속도 허용오차는 명령의 20%이며, 낙상 이후 시간은 조건을 만족하지 않은 시간으로 포함한다. 엄격 추종률 Q_{10}은 각 허용오차를 절반으로 설정한다.

명령 추종 시간율은 다음의 세 조건을 동시에 평가한다.

$$Q_{20} = \frac{100}{NT} \sum_{i=1}^{N} \int_{0}^{T} A_i(t)\, C_i(t)\, dt, \tag{9}$$

$$C_i(t) = \mathbb{1}\left\{ \begin{array}{r} |v_{x,i}(t) - 0.5| \le 0.1, \\ |v_{y,i}(t)| \le 0.1, \\ |\omega_{z,i}(t)| \le 0.2 \end{array} \right\}. \tag{10}$$

여기서 t는 고장 발생 후의 시간, $T = 20$ s, N은 시행 수, $A_i(t)$는 생존 시 1인 지시함수이다. 선속도와 각속도의 허용오차 단위는 각각 m/s와 rad/s이다. 추종 시간율은 생존 여부와 명령 수행을 동시에 반영하고, RMSE는 생존한 동안 발생한 연속적인 속도 오차의 크기를 나타낸다. 두 지표를 함께 사용하여 보행 유지와 추종 정밀도를 구분한다.

고장 후 실제 이동량은 전방 순변위 $D_{\parallel}$로 평가하였다. 고장 순간과 마지막 생존 표본의 세계좌표 xy 변위를 고장 순간의 수평 전방 $\hat{u}^f$에 투영하였다.

$$D_{\parallel} = (x^{last} - x^{f})^{\top} \hat{u}^{f} \tag{11}$$

고장 전 종료된 시행의 $D_{\parallel}$는 0으로 처리하였다.

전방 순변위는 세계좌표에서 측정하므로, 몸체가 회전한 상태에서의 국소 전진속도 적분과 구별된다. 같은 전진속도를 유지하더라도 진행 방향이 달라지면 고장 순간의 전방으로 이동한 거리가 감소할 수 있다. 따라서 실제 이동량은 속도·yaw-rate 추종 결과와 함께 해석한다. 명령속도 0.5 m/s로 20 s 동안 직진했을 때의 기준 이동거리는 10 m이다.

4.2 학습 과정

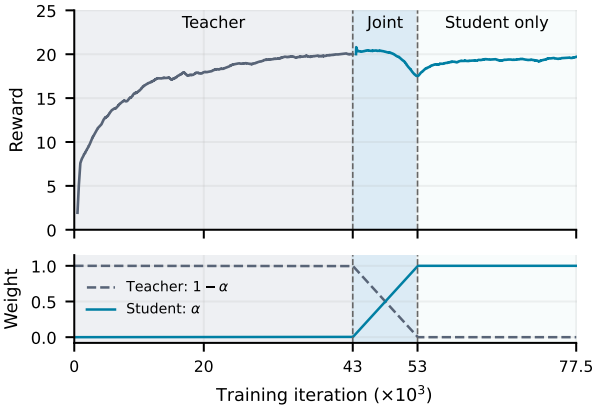


그림 3. 학습 단계별 평균 에피소드 보상(상단, 500회 이동평균)과 교사·학생 특징의 혼합 비중(하단)

그림 3은 평균 에피소드 보상과 특징 혼합 비중을 나타낸다. 교사를 43,000회까지 학습한 후 공동학습을 초기화하였다. 43,000–53,000회에는 학생 비중 α를 0에서 1로 증가시키고, 이후 학생 특징만 사용하였다.

학생 특징으로 전환되는 동안 감소한 보상은 학생 단독 학습에서 회복하였다. 전환 시점과 최종 평균 보상은 각각 17.52와 19.70으로 12.4% 증가하였다.

혼합 구간에서는 Actor 입력의 특징 분포와 학생 인코더가 함께 변화한다. 이후 학생 단독 구간에서는 학생이 만든 특징을 입력으로 행동을 생성하고, 그 행동에서 수집한 경험으로 정책을 갱신한다. 그림의 보상 회복은 이러한 학생 입력 경로에서의 학습 경향을 나타내며, 고장 대응 성능은 별도의 생존·추종 평가로 비교하였다.

4.3 토크 저하에 따른 생존 및 명령 추종 성능

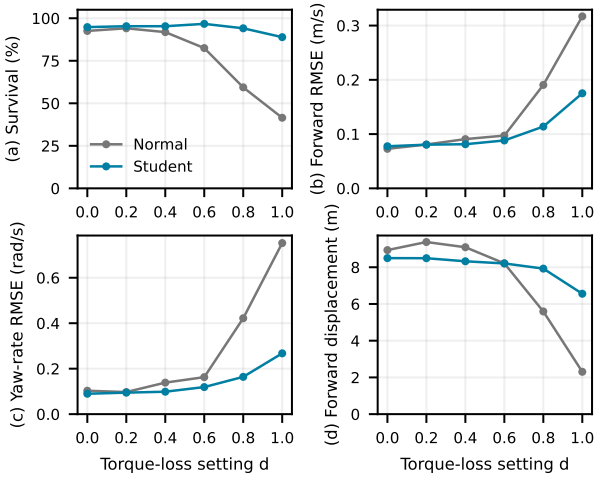


그림 4. 토크 손실에 따른 생존율, 전진속도·yaw-rate 추종 오차 및 전방 순변위

그림 4에서 강한 토크 저하에 따른 Student의 생존율 향상과 전진속도·yaw-rate 오차 감소가 함께 나타났다.

표 6. 정책별 성능 차이(Student−Normal)

손실 (%)	생존율 (%p)	v_x RMSE (m/s)	yaw RMSE (rad/s)	전방 변위 (m)
0	+2.26	+0.0047	-0.0133	-0.437
20	+1.22	-0.0003	-0.0027	-0.881
40	+3.47	-0.0094	-0.0399	-0.766
60	+14.24	-0.0090	-0.0437	-0.004
80	+34.72	-0.0767	-0.2578	+2.333
100	+47.40	-0.1418	-0.4850	+4.250

표 6의 생존율 차이는 양수일수록 생존율 증가를, 두 RMSE 차이는 음수일수록 추종 오차 감소를 나타낸다. 전방 변위 차이는 고장 이후 실제 이동량의 차이이며, 생존 및 명령 추종과 함께 해석한다.

손실이 커질 때 실제 전방 이동량을 유지하려면 낙상을 피하는 동시에 속도와 방향 명령을 수행해야 한다. 완전 손실에서 Student의 평균 전방 순변위는 6.56 m로, 명령을 그대로 수행한 기준 10 m의 약 65.6%에 해당한다. 같은 조건에서 Normal의 이동량은 2.31 m였다. Student는 고장 이후 더 긴 이동을 수행하면서 전진속도와 yaw-rate의 추종 오차도 줄였다.

정상 조건에서는 두 정책의 명령 추종 시간율이 Normal 80.01%, Student 80.71%였으며, 완전 손실에서는 16.57%와 41.07%였다. 완전 손실에서 Student가 세 축의 허용오차를 동시에 만족한 시간은 전체 관찰 시간의 평균 8.21 s이다. 이는 생존율 증가와 함께 명령을 수행한 시간의 증가를 보여준다. 엄격한 허용오차의 Q_{10}도 같은 조건에서 4.43%에서 12.30%로 증가하였다.

4.4 관절별 고장 대응 성능

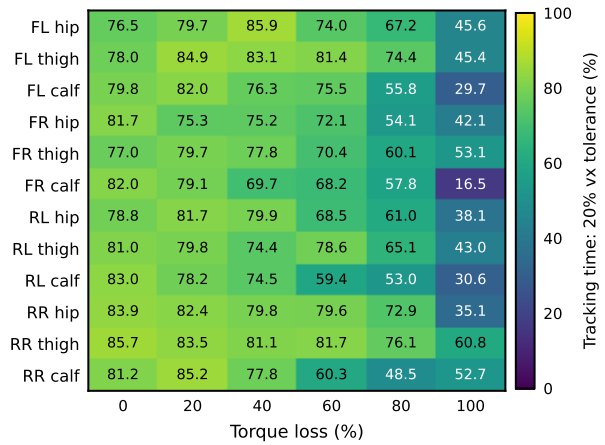


그림 5. 관절 및 토크 손실별 Student 명령 추종 시간율 Q_{20}(%)

FL/FR은 좌/우 앞다리, RL/RR은 좌/우 뒷다리이다. 그림 5은 3축 속도 허용오차를 동시에 만족한 시간을 비교한다. 완전 손실에서 RR thigh는 60.84%, FR calf는 16.49%로 관절별 차이가 나타났다. FR calf의 생존율은 83.33%였으나 전진속도와 yaw-rate RMSE는 각각 0.256 m/s와 0.382 rad/s였다. 생존을 유지한 이후에도 손상 관절에 따라 명령 수행의 취약성이 다르게 나타났다.

그림의 모든 셀은 같은 0–100% 색 범위와 같은 허용오차를 사용한다. 따라서 색의 차이는 손상 관절에 따른 실제 명령 수행 시간의 차이를 나타낸다. 관절별 평가는 생존율만으로 유사하게 보이는 조건 중에서도 전진·횡이동·회전 명령을 함께 유지하기 어려운 조건을 구분한다. 특히 FR calf는 생존한 시행이 많아도 추종 시간율이 낮았으므로, 해당 조건에서는 보행 유지 이후의 속도·방향 제어가 주요 개선 대상이다.

4.5 고장 대응 보행의 성능 해석

고장 후의 낙상과 속도 오차는 서로 다른 성능 요소이다. 낙상한 시행은 이후의 이동 명령을 수행할 수 없고, 생존한 시행에서도 속도나 진행 방향의 오차가 지속될 수 있다. 생존율은 전자의 발생 빈도를, 생존 구간 RMSE는 후자의 오차 크기를 나타낸다. 명령 추종 시간율은 두 요소를 결합하여 전체 관찰 시간 중 실제로 명령을 수행한 비중을 나타내므로, 고장 대응 보행의 목표와 직접 연결된다.

정상 조건에서 Student의 평균 전방 이동량은 Normal보다 작았지만, 세 축의 명령 추종 시간율은 유사하였다. 이동량의 변화에는 생존 시간뿐 아니라 전진속도, 횡방향 움직임과 진행 방향이 함께 작용한다. 따라서 이동량 감소만으로 고장 대응 성능을 판단하기보다, 명령을 어느 정도의 오차로 얼마나 오래 수행했는지를 함께 살펴야 한다.

강한 토크 손실에서는 Student의 생존율 증가와 속도·yaw-rate 오차 감소가 동시에 나타났다. 이에 따라 세계좌표에서 측정한 전방 이동량도 증가하였다. 반면 관절별 추종 시간율은 같은 손실률에서도 차이를 보였다. 평균 성능의 향상과 손상 위치에 따른 성능 편차를 함께 제시함으로써, 출력 손실에 대응하는 보행의 범위와 추가 개선이 필요한 관절 조건을 구분하였다.

향후 제어 성능을 높이기 위해서는 고장 후 균형 유지에 더해 추종 시간율이 낮은 관절 조건의 속도·방향 오차를 줄이는 학습이 필요하다. 특히 고장 수준과 손상 위치를 함께 평가하면, 특정 조건의 높은 생존율에 가려지는 명령 수행 오차를 학습 목표와 연결할 수 있다.

V. 결론 및 향후 연구

교사·학생 공동학습을 단일 관절 토크 저하에 적용한 4족 보행 정책을 구성하였다. 완전 손실에서 생존율은 Normal 41.49%에서 Student 88.89%로 증가하고, 전진속도·yaw-rate RMSE는 각각 0.317→0.175 m/s, 0.753→0.268 rad/s로 감소하였다. 관절별 추종 시간율은 생존 이후의 명령 수행 취약성을 구분하였다.

향후 여러 관절의 동시 토크 저하와 관절 잠금 고장으로 적용 범위를 확장하고, 고장 유형과 손상 조합에 따른 보행 안정성 및 속도 추종 성능을 평가할 예정이다.

References

[1] N. Rudin et al., “Learning to Walk in Minutes Using Massively Parallel Deep Reinforcement Learning,” PMLR 164, pp.91–100, 2022.

[2] D. Liu et al., “Saving the Limping: Fault-tolerant Quadruped Locomotion via Reinforcement Learning,” arXiv:2210.00474v3, 2023.

[3] V. Makoviychuk et al., “Isaac Gym: High Performance GPU-Based Physics Simulation for Robot Learning,” arXiv:2108.10470, 2021.

[4] X. Wu et al., “Adaptive Control Strategy for Quadruped Robots in Actuator Degradation Scenarios,” DAI 2023, doi:10.1145/3627676.3627686.

[5] A. Kumar et al., “RMA: Rapid Motor Adaptation for Legged Robots,” RSS XVII, 2021, doi:10.15607/RSS.2021.XVII.011.

[6] J. Schulman et al., “Proximal Policy Optimization Algorithms,” arXiv:1707.06347, 2017.