4족 보행 로봇의 액추에이터 토크 저하에 강건한 교사·학생 기반 강화학습 보행 제어

변지훈[1], 유은빈[1], 최서경[1], 김준영[1], 정소이[2],*
[1]아주대학교 전자공학과, [2]아주대학교 미래모빌리티공학과
{josephx03021, yooeunbin98, cskeong1022, kimjy3078, sjung}@ajou.ac.kr

Teacher–Student Reinforcement Learning for Robust Quadruped Locomotion under Actuator Torque Degradation

Jihun Byon[1], Eunbin Yoo[1], Seokyeong Choi[1], Junyoung Kim[1], Soyi Jung[2],*
[1]Department of Electrical and Computer Engineering, Ajou University
[2]Department of Mobility Engineering, Ajou University

Abstract

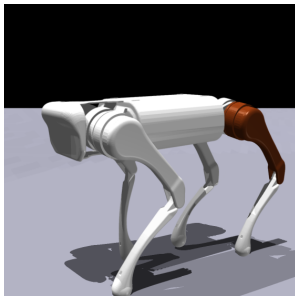
Quadrupedal robots should maintain balance and execute commanded motion after joint torque degradation. We present a teacher–student reinforcement learning control configuration whose history-based student handles nominal and single-joint degraded conditions without direct fault inputs. Unitree A1 simulations compare the fixed student with a nominally trained policy, each trained with one seed, on matched mixed-terrain courses using forward, diagonal, lateral, and sinusoidal-path tasks. At 100% torque degradation, survival increased from 52.08% to 89.24%, while mean pre-termination cross-track root mean square error (RMSE) decreased from 0.225 to 0.080 m, averaged over the fixed task mixture. The results show simultaneous improvements in fall avoidance and motion tracking under severe torque degradation for these fixed policies and evaluated tasks.

I. 서론

4족 보행 로봇은 계단과 불규칙한 지형을 이동할 수 있으며, 강화학습을 이용한 보행 제어는 다양한 지면에서 균형 유지와 이동 명령 수행을 학습하는 데 활용된다[1]. 그러나 관절의 구동 성능이 저하되면 몸체를 지지하고 추진하는 능력이 달라져, 정상 조건에서 학습한 정책의 이동 성능이 저하될 수 있다. 특히 낙상을 피하더라도 요구된 속도와 방향을 따르지 못하거나 목표 경로에서 벗어날 수 있다. 따라서 고장 대응 보행의 성능은 생존 여부와 명령 · 경로 추종을 함께 평가해야 한다.

본 논문은 단일 관절의 토크 저하를 대상으로, 기존 교사 · 학생 공동학습을 적용한 강화학습 기반 고장 대응 보행 제어 구성을 제시한다[2]. 학습 시에는 시뮬레이션의 특권 물리 정보를 활용하는 교사 표현과 관측 이력 기반 학생 표현을 사용하고, 평가 시에는 현재 관측과 학생 특징으로 행동을 출력한다. 학생은 고장 관절과 토크 저하 수준을 직접 입력받지 않으며, 동일한 정책으로 정상 조건과 토크 저하 조건에서 동작한다.

Unitree A1 시뮬레이션에서 정상 조건만 학습한 정책과 초기 상태 · 물리 조건 · 지형 · 고장 조건을 맞추어 비교한다. 전진, 좌우 대각 이동, 좌우 횡이동 및 두 사인파 경로를 대상으로 생존율과 세 축 이동 명령의 root mean square error (RMSE), 경로 횡오차 RMSE를 평가한다. 이를 통해 고장 관절 · 토크 저하율 · 이동 과제에 따른 성능 차이와 취약 조건을 분석한다.


(a) Unitree A1

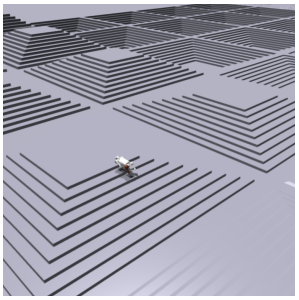

(b) Isaac Gym 지형

그림 1. 로봇 모델과 시뮬레이션 환경

표 1. 로봇 및 제어 설정

Parameter	Value
Actuated joints	12 (hip, thigh, calf per leg)
Physics / policy interval	0.005 s / 0.02 s
Joint target	$q^{des} = q^0 + 0.25a_t$ (rad)
Nominal PD gains	$K_p = 20$ N·m/rad; $K_d = 0.5$ N·m·s/rad

II. 시스템 모델

2.1 시뮬레이션 환경 및 제어 구조

Isaac Gym의 graphics processing unit (GPU) PhysX에서 Unitree A1을 모사한다[3]. 각 다리는 hip, thigh, calf로 구성되며, 전체 관절은 12개이다. 정책의 목표 관절각을 proportional–derivative (PD) 제어기가 토크로 변환하고, 몸체 · 관절 반응을 다음 관측에 반영하여 제어를 반복한다[1]. 로봇과 지형은 그림 1, 제어 설정은 표 1과 같다. 12차원 행동 a_t는 기준 자세 q^0에 더할 관절각을 정하며, 0.25 rad는 행동 배율이다. 0.02 s마다 새 목표를 출력하고, 그 사이에는 목표를 유지한 채 0.005 s 간격으로 물리를 계산한다.

2.2 단일 관절 토크 저하 모델

토크 저하는 PD 토크에 곱하는 고장 배율의 감소로 모델링한다[4]. 토크 저하율 $d \in [0,1]$에 대해 고장 배율은 $1-d$이며, $d = 0.4$이면 고장 배율은 0.6이다. PD 토크에 모터 강도 m_j와 고장 배율 η_j를 곱한 뒤 관절 한계 토크로 제한한다.

$$\tau_j^{PD} = K_p(q_j^{des} - q_j) - K_d\dot{q}_j, \quad (1)$$

$$\tau_j = \mathrm{clip}(m_j\eta_j\tau_j^{PD}, -\tau_j^{max}, \tau_j^{max}). \quad (2)$$

식 (1), (2)에서 q_j^{des}, q_j, $\dot{q}_j$는 목표 관절각, 현재 관절각, 관절속도이며, K_p, K_d는 PD 이득이다. τ_j^{max}는 관절 j의 최대 허용 토크이며, clip은 출력을 $\pm\tau_j^{max}$로 제한한다. m_j는 [0.9, 1.1]에서 무작위화하여 고장과 별개인 ±10% 편차를 반영한다. 100% 토크 저하($d = 1$)에서는 능동 토크가 0이지만, 관절 잠금과 달리 수동 운동은 유지된다.

표 2. 현재 관측의 구성

Component	Symbol	Unit	Dim.
Body linear velocity	v_t	m/s	3
Body angular velocity	ω_t	rad/s	3
Projected gravity	g_t	−−	3
Linear velocity command	v_{xy}^{cmd}	m/s	2
Yaw−rate command	ω_z^{cmd}	rad/s	1
Relative joint position	$q_t - q^0$	rad	12
Joint velocity	$\dot{q}_t$	rad/s	12
Previous action	a_{t-1}	−−	12
Robot/command observation	$\tilde{o}_t$	mixed	48
Terrain heights	h_t	m	187
Current observation	o_t	mixed	235

고장은 선택된 관절 j_f에서 시점 t_f에 발생하며, 나머지 관절의 배율은 1로 유지한다.

$$\eta_j(t) = \begin{cases} 1-d, & j = j_f,\ t \geq t_f, \\ 1, & \text{그 외}, \end{cases} \quad (3)$$

식 (3)의 j_f, t_f는 고장 관절과 발생 시점이다. 에피소드마다 관절 하나와 0, 20, 40, 60, 80, 100% 중 하나의 저하율을 무작위로 선택한다. 시작 후 2 s부터 10 s 사이에 고장을 발생시키고 배율을 유지한다. 고장 전후를 한 에피소드에 포함하여, 정상 보행 중 반응이 달라져도 제어를 이어가도록 학습한다.

III. 교사 · 학생 공동학습 기반 보행 정책

3.1 관측 및 이력 표현

고장 정보를 직접 받지 않는 학생에게는 행동 이후의 운동 반응이 단서가 된다. 따라서 현재 관측과 최근 1 s의 관측 이력을 함께 사용한다. 현재 관측 o_t는 로봇 · 명령 정보 $\tilde{o}_t$ 48차원과 지형 높이 187차원이다[1]. $\tilde{o}_t$에는 선속도 · 각속도 · 중력 방향 · 속도 명령 각 3차원과 관절각 편차 · 관절속도 · 이전 행동 각 12차원이 포함된다. 각 관측의 기호 · 단위 · 차원은 표 2와 같다.

교사는 마찰계수 1, 추가 질량 1, 유효 모터 강도 12, PD 이득 24, 몸체 속도 6, 고장 표지 1의 총 45차원을 8차원 특징 z_t^T로 압축한다. 유효 모터 강도에는 손상 위치와 정도가 반영된다. 학생은 $H_t = [\tilde{o}_{t-49}, \ldots, \tilde{o}_t]$의 50×48 이력을 convolutional neural network (CNN) 인코더로

표 3. 교사 · 학생 인코더와 정책의 입출력

Path	Input → output
Teacher encoder	$45 \rightarrow z_t^T \in R^8$
Student encoder	H_t: $50 \times 48 \rightarrow z_t^S \in R^8$
Observation o_t	$48 + 187 = 235$
Training feature	$(1-\alpha)z_t^T + \alpha z_t^S$: 8
Actor/Critic (train)	$[o_t, z_t]$: $235 + 8 = 243$
Actor (inference)	$[o_t, z_t^S]$: $235 + 8 = 243 \rightarrow a_t \in R^{12}$

처리하여 특징 z_t^S를 만든다[2, 5]. 부족한 과거 표본은 0으로 채운다. 현재 관측 235차원과 학생 특징 8차원을 결합하여 12차원 행동을 출력한다. 교사 · 학생 인코더와 정책의 차원 관계는 표 3에 정리하였다. 지형 높이는 이력에서 제외한다. 몸체 속도와 지형 높이는 시뮬레이터에서 얻으므로, 실제 로봇 적용에는 별도의 측정 · 추정이 필요하다.

3.2 교사 · 학생 공동학습

교사의 45차원 특권 물리 정보는 학생에게 별도 입력하지 않는다. 이에 교사 특징을 관측 이력으로 추정하는 구조와 특징 혼합 공동학습을 적용한다[2, 5]. 모방 오차가 남아 있어도 제어 정책이 학생 특징에 적응하도록, 다음 특징을 행동 정책(Actor)과 가치 함수(Critic)에 입력한다.

$$z_t = (1-\alpha)z_t^T + \alpha z_t^S. \tag{4}$$

식 (4)의 α는 학생 특징의 혼합 비중이다. 사전학습 교사로 초기화한 뒤 공동학습 갱신 횟수 n에 따라 $\alpha(n) = \min(n/10000, 1)$로 학생 비중을 높인다. 10,000회 이후에는 학생 특징만 사용하여 평가와 입력 경로를 맞춘다. 전환 중에는 proximal policy optimization (PPO) 손실에 모방항을 추가한다[6].

$$\mathcal{L} = \mathcal{L}_{PPO} + \frac{1-\alpha}{B}\sum_{i=1}^{B} \|z_i^S - \mathrm{sg}(z_i^T)\|_2. \tag{5}$$

스케줄과 평균 L2 거리의 모방 손실은 선행 연구를 따른다[2]. 식 (5)에서 $\mathcal{L}_{PPO}$는 정책 · 가치 학습 손실, B는 미니배치 크기, i는 배치 내 표본 번호, sg는 모방 목표의 gradient 차단 연산이다. 교사는 전환 중에도 PPO로 갱신되며, $\alpha = 1$ 이후에는 학생 · Actor · Critic만 학습한다. 두 경로에서 학생 경로로 전환하는 구조는 그림 2에 나타냈다.

3.3 속도 추종 보상

보상은 속도 추종과 안정적인 운동을 함께 유도한다[1]. 평면 선속도와 yaw−rate(수직축 회전속도)의 추종항은

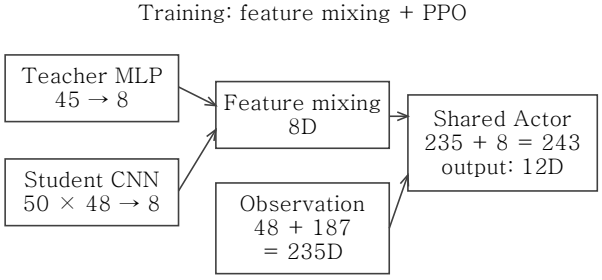


그림 2. 교사 · 학생 공동학습과 평가 시 학생 경로

표 4. 제어 간격 적용 전 보상항별 가중치

Reward term	Weight
Planar velocity tracking / yaw−rate tracking	1 / 0.5
Squared vertical velocity	-2
Squared roll/pitch angular velocity	-0.05
Squared joint torque	-2×10^{-4}
Squared joint acceleration	-2.5×10^{-7}
Squared action change	-0.01
Disallowed contact count	-1
Joint−limit excess	-10
Foot air−time reward	1

오차가 작을수록 큰 값을 갖는다.

$$r_v = \exp\left(-\|v_{xy} - v_{xy}^{cmd}\|_2^2/0.25\right), \tag{6}$$
$$r_\omega = \exp\left(-(\omega_z - \omega_z^{cmd})^2/0.25\right). \tag{7}$$

식 (6), (7)에서 v_{xy}와 ω_z는 평면 선속도와 수직축 각속도이며, 위첨자 cmd는 명령값이다. 분모 0.25의 단위는 각각 $(\mathrm{m/s})^2$, $(\mathrm{rad/s})^2$이며 보상 감소 폭을 정한다. 표 4의 비용항은 수직 · roll/pitch 운동과 과도한 토크, 급격한 행동 변화 등을 억제한다. 원시 물리량으로 계산한 가중합에 제어 간격을 곱하고 음수 총보상은 0으로 제한한다. PPO로 할인 보상합을 최대화한다.

3.4 정책 학습 환경 및 설정

물리 조건에 따라 달라지는 고장 후 반응을 학습하도록 마찰계수 0.5에서 1.25, 추가 질량 0에서 2 kg, 명목 모터 강도 $\pm 10\%$를 무작위화하였다. PD 이득도 K_p $\pm 5\%$, K_d $\pm 10\%$로 변화시키고 혼합 지형과 주기적인 외란을 적용하였다.

교사 인코더는 multi−layer perceptron (MLP)으로, 은닉층 [512, 256, 128]과 exponential linear unit (ELU)를 사용한다[2]. 본 구현의 Actor · Critic도 같은 은닉층 크기를 갖는다. 학생 인코더는 rapid motor

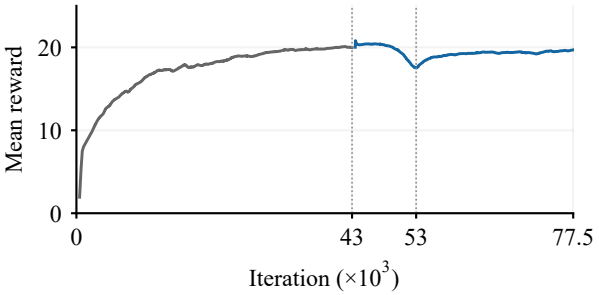


그림 3. 학습 단계별 평균 에피소드 보상(500회 이동평균). 43,000–53,000회가 교사에서 학생 특징으로 전환하는 구간이다.

adaptation (RMA) 계열로, 48차원 프레임을 64차원으로 변환한 뒤 세 개의 1차원 합성곱 층을 거쳐 8차원 특징을 출력한다[5]. Actor · Critic 입력은 현재 관측과 혼합 특징의 243차원이다.

병렬 환경 4,096개에서 환경당 24개 제어 시점의 경험으로 PPO를 갱신한다. 미래 보상의 가중치를 정하는 할인 계수(discount factor) $\gamma = 0.99$, generalized advantage estimation (GAE) 계수 0.95, clip 계수 0.2, 갱신당 5회 학습과 4개 미니배치를 사용한다. 공동학습 초기 학습률(learning rate)은 10^{-5}이고 Kullback–Leibler (KL) divergence에 따라 조절한다. 학습 과정은 그림 3, 토크 저하율별 성능은 그림 4에 제시한다.

그림 3에서 학생 특징으로 전환할 때 감소한 보상은 후속 학습에서 회복된다. 교사를 43,000회까지 학습한 뒤 53,000회까지 학생 비중을 높였고, 77,500회의 학생 정책을 평가하였다. 전환 완료 시점의 평균 보상은 17.52에서 최종 19.70으로 증가하였다. 이는 바뀐 입력으로 정책이 보행을 학습한 과정이며, 고장 대응 성능은 다음 절의 조건별 평가로 확인한다.

IV. 시뮬레이션 결과 및 성능 분석

4.1 비교 정책과 평가 조건

Normal은 정상 조건만 학습하고, 평가 시 실제 고장 배율과 고장 표지를 반영한 특권 정보의 교사 인코더를 사용한다. Student는 정상 · 토크 저하 조건에서 학습하고 이력 기반 학생 인코더를 사용한다. 고장 학습 · 표현 · 학습 이력이 다른 두 구성 전체를 비교한다. 평가 체크포인트는 Normal 22,500회, Student 누적 77,500회이다. 사전학습 교사는 Normal과 별도의 고장학습 정책이며 43,000회까지 학습하였다. 각 정책은 단일 학습 시드로 학습하였으며, 현재 수집 전에 선정한 고정 정책이다.

평가 저하율은 $d \in \{0.2, 0.4, 0.6, 0.8, 1\}$이며 정상 한 조건을 더한다(표 5). 8 m × 8 m 구획을 +x 방향 5행, 횡방향 12열로 배치한다. 각 열의 같은 지형 유형은 행마다 난이도 0–0.8로 증가한다. 열 구성은 음 · 양의 피라미드 경사각 1, 거친 경사 1, 음 · 양의 계단 피라미드 4 · 3, 장애물 2이다. 같은 부호 계단 열은 동일 형상이며 요철 · 장애물은 시드에 따라 달라진다. 대응 쌍의 초기 상태 · 물리 · 지형 · 고장 일정을 맞추고, 관측 잡음 · 외부 밀기 · 종료 후 재시작은 해제하였다.

표 5. 고정 혼합 과제의 평가 설정

Item	Setting
Task slots	Forward 2; diagonal 1; lateral 1; sine 2
Path / speed	World +x, $x = -1$ to 40.5 m; 0.5 m/s
Body yaw (line)	$0°$, $\pm 45°$, $\pm 90°$
Sine path	Amplitudes 2 / 1.5 m; wavelength 16 m
Conditions / onset	12 joints × 5 levels + 1 nominal; 2 s
Total trials (both policies)	$6 \times 61 \times 2 \times 3 \times 12 = 26,352$
Evaluation seeds	1101, 1102, 1103
Post-onset cap	Line 445 s; $A = 1.5$: 479.88 s; $A = 2$: 504.62 s

모든 과제는 세계 +x로 진행하고, 대각 · 횡이동은 몸체를 $\pm 45°$, $\pm 90°$로 유지하며 좌우를 조건 · 시드 사이에서 교대한다. 전진 두 슬롯은 초기 · 물리 난수가 다르다. 사인파는 열 중심 y_c에서 $y = y_c + A\sin(2\pi(x+1)/16)$이다. 완료된 전수 수집에서 성능값과 무관한 식별자로 고정 2:1:1:2를 추출하였다. 평균은 이 과제 구성과 지형 열 비중을 반영한다.

동일 상위 제어기가 선행 거리 0.4 m, 횡오차 이득 0.7, 방향 오차 이득 1.5로 접선 속도와 횡오차 피드백을 결합해 0.5 m/s의 세계 속도 명령을 정하고 실제 yaw로 몸체 좌표로 변환한다. 목표 yaw는 사인파에서 접선, 직선에서 과제별 고정각이다. 회전 명령은 ± 0.8 rad/s로 제한하며, 상태에 따라 달라지는 실제 명령을 RMSE 기준으로 쓴다.

종료 조건은 base 링크 순접촉력 노름 > 1 N의 낙상, 출구 도달($x \geq 40.5$ m, 횡오차 절댓값 < 0.5 m), 경로 길이 L에 따른 시간 상한 $L/(0.1\ \text{m/s}) + 30$ s 순으로 적용한다. 상한은 고장 후 기준이며 느린 이동을 기다리기 위한 예산이다. 저속 · 정체로 조기 종료하지 않는다.

생존율은 식 (8)의 전체 N시행 중 비낙상 비율이다. 완주 · 비낙상 상한 종료를 포함하고 고장 전 낙상은 실패로 센다.

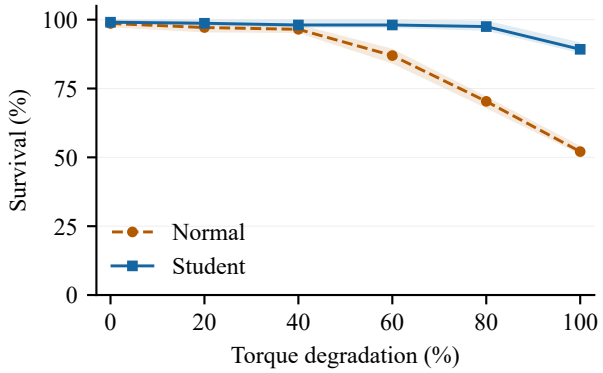


그림 4. 토크 저하율별 생존율. 점은 전체 평균, 음영은 3평가 시드 평균의 최소–최대이다.

$$S = \frac{100}{N}\sum_{i=1}^{N} I_i, \qquad I_i = \begin{cases} 0, & \text{낙상}, \\ 1, & \text{그 외 종료}. \end{cases} \tag{8}$$

여기서 I_i는 시행 i의 비낙상 지시값이다. S는 % 단위이며 완주율 · 평균 생존 시간이 아니다. 정책당 정상 216시행, 비영 저하율별 2,592시행, 관절 · 저하율별 216시행이다.

이동 명령 추종은 실제 몸체 v_x, v_y, ω_z와 같은 시점의 명령 간 오차로 평가한다. 경로 추종은 세계 위치와 기준 경로 근사 투영점의 차이를 단위 법선으로 투영한 횡오차 $e_\perp(t)$로 평가한다. 시행별 오차는 식 (9)로 계산한다.

$$R_{u,i} = \sqrt{\frac{1}{K_i}\sum_{k\in V_i} e_{u,i,k}^2}, \qquad \overline{R}_u = \frac{1}{M_u}\sum_{i:K_i>0} R_{u,i}. \tag{9}$$

여기서 $u \in \{v_x, v_y, \omega_z, \perp\}$이며, 속도 오차는 실제값에서 현재 명령을 뺀 값, 경로 오차는 $e_\perp$이다. V_i는 2 s 이후 첫 종료 전 유효 표본 집합, K_i는 표본 수, M_u는 오차 계산이 가능한 시행 수이다. 0 명령도 포함하며 낙상 이후를 0으로 채우지 않는다. 유효 표본이 없으면 계산 불가이며 이번 자료의 누락은 없다. 정책별 종료 시점과 방문 지형이 달라 동일 시간 · 난이도의 오차 비교는 아니며 생존율과 함께 해석한다. 곡선 음영은 평가 시드 평균의 최소–최대이며 학습 시드 신뢰구간이 아니다.

4.2 토크 저하에 따른 낙상 및 명령 추종

그림 4는 토크 저하율에 따른 생존율을 나타낸다. 정상 상태에서 Normal과 Student는 각각 98.61%, 99.07%이지만 100% 저하에서 52.08%, 89.24%가 된다. Student의 생존율 우위는 60%에서 11.11%p, 80%에서 27.16%p, 100%에서 37.15%p로 커진다. 정상학습 정책의 생존 성능이 큰 저하에서 급감하는 데 비해 Student는 비낙상 비율을 상대적으로 높게 유지한다. 그림 5는 v_x 명령 추종 오차를 나타낸다. 정상 상태에서는 Normal 0.043 m/s, Student 0.054 m/s로 Student의 오차가 더

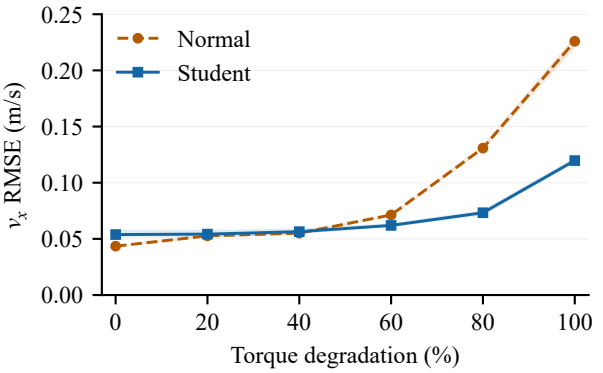


그림 5. 토크 저하율에 따른 몸체 x축 이동 명령 RMSE.

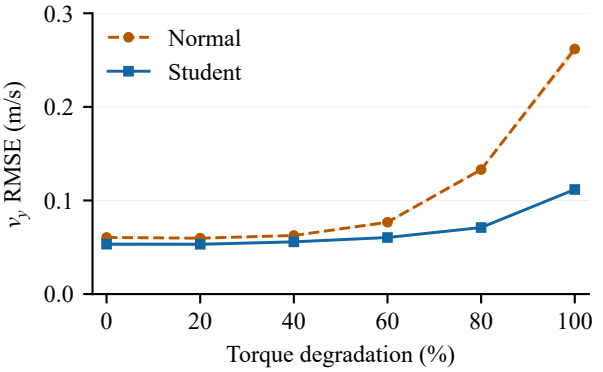


그림 6. 토크 저하율에 따른 몸체 y축 이동 명령 RMSE.

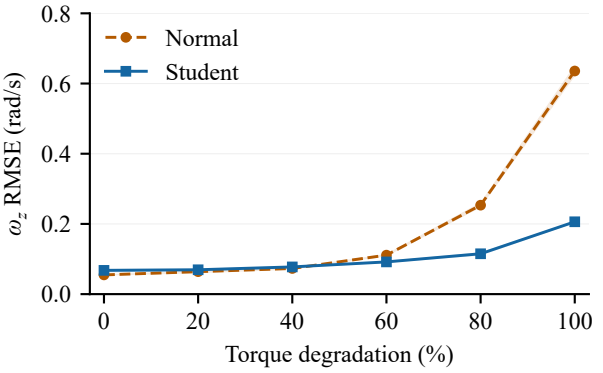


그림 7. 토크 저하율에 따른 몸체 수직축 회전속도 명령 RMSE.

크지만, 100% 저하에서는 0.226 m/s에서 0.120 m/s로 47.0% 감소한다. Student의 이점은 정상 상태의 정밀도를 일률적으로 높이는 데 있지 않고, 큰 토크 저하에 따른 성능 악화를 줄이는 데 나타난다. 그림 6은 v_y 명령 RMSE를 나타낸다. 100% 저하에서 Normal 0.262 m/s, Student 0.112 m/s로 57.3% 감소한다. 몸체 y축 이동을 포함한 혼합 과제에서 생존율과 속도 오차가 함께 개선되었다. 그림 7은 회전속도 명령 추종 오차를 나타낸다. 100% 저하에서 0.636 rad/s에서 0.206 rad/s로 67.6% 감소한다. 몸체 방향 유지와 곡선 주행에 사용하는 회전

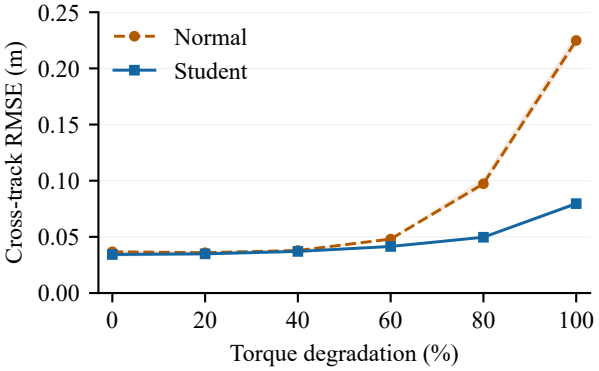


그림 8. 토크 저하율에 따른 기준 경로 횡오차 RMSE.

표 6. 100% 저하의 과제별 성능(Normal / Student). 정책당 전진 · 사인파 각 864회, 대각 · 횡 각 432회.

Task	Survival (%)	Cross-track RMSE (m)
Forward	49.07 / 88.89	0.245 / 0.079
Diagonal	59.72 / 90.74	0.174 / 0.061
Lateral	59.72 / 95.14	0.144 / 0.049
Sine	47.45 / 85.88	0.271 / 0.105

속도 명령도 더 정확하게 따랐다. 다만 정상 · 낮은 저하에서는 Normal의 오차가 더 작다.

4.3 경로 추종과 과제별 성능

그림 8은 경로 횡오차를 나타낸다. 100% 저하에서 Normal 0.225 m, Student 0.080 m로 64.6% 감소한다. 동일 상위 제어기에서 명령 추종 오차와 종료 전 경로 횡오차가 함께 감소하였다. 경로 위 정지에서도 횡오차는 작을 수 있으므로 앞의 생존율과 세 축 명령 오차를 같이 해석한다.

100% 저하에서 전체 시행의 출구 도달 비율도 Normal 618/2,592(23.84%)에서 Student 2,248/2,592(86.73%)로 높아졌다. 일부 비낙상 시행에서는 30 s 동안 경로 진행 최고값이 0.5 m 미만 증가하는 정체도 관찰되었다. RL calf 100%의 비낙상 시행 중 정체 경험은 Normal 185/188, Student 4/198이었다. 일시 정체 후 완주도 포함한 보조 사례이다. 표 6은 100% 저하의 과제별 생존율과 경로 오차를 나타낸다. 네 과제 모두 생존율이 높아지고 횡오차가 작아졌으며, 각 과제의 세 축 명령 RMSE 평균도 모두 감소하였다(재현 자료의 `task_metrics.csv`). 개선은 전진에만 국한되지 않는다. 사인파의 Student 횡오차는 0.105 m로 다른 과제보다 커, 곡선 주행에서 상대적으로 오차가 남는다.

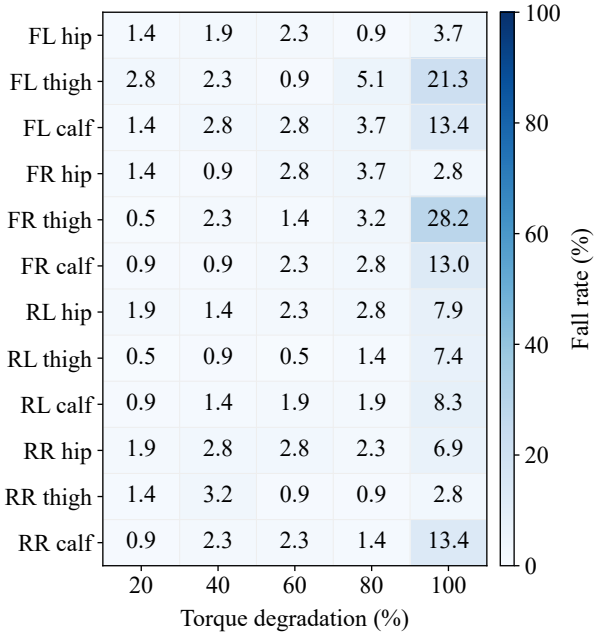


그림 9. Student의 관절 · 토크 저하율별 낙상률(%). 각 셀은 216시행이며 낙상률은 100%에서 생존율을 뺀 값이다.

4.4 Student의 관절별 성능

그림 9는 Student의 관절별 낙상률을 나타낸다. FL/FR은 좌/우 앞다리, RL/RR은 좌/우 뒷다리이다. 100% 저하에서 FR hip과 RR thigh의 낙상률은 각각 2.78%인 반면 FL thigh는 21.30%, FR thigh는 28.24%이다. 같은 저하율에서도 관절별 성능은 다르며, 히트맵은 평균에 가려진 취약 조건을 보여준다.

V. 결론

본 논문에서는 단일 관절 토크 저하 학습과 관측 이력 표현을 결합한 교사 · 학생 기반 보행 제어 구성을 제시하였다. 단일 학습 시드의 두 고정 정책을 해당 과제 · 지형 혼합에서 비교한 결과, 60–100% 저하에서 Student의 생존율과 종료 전 명령 · 경로 추종 오차가 함께 개선되었다. 100% 저하에서는 생존율이 52.08%에서 89.24%로 높아지고 경로 횡오차 RMSE가 0.225 m에서 0.080 m로 낮아졌다. 향후 독립 학습 반복과 실제 로봇에서 재현성을 검증할 계획이다.

설정 · 추출 규칙 · 과제별 수치는 공개 재현 자료에 제공한다. 저장소는 https://github.com/JIhunByonAJOU/fault_tolerant_legged_RL이며, `dev` 브랜치의 `docs/submission/ieie2026/paper_assets/`에서 `MANUSCRIPT_EVIDENCE.md`와 `task_metrics.csv`를 확인할 수 있다.

참고문헌

[1] N. Rudin, D. Hoeller, P. Reist, and M. Hutter, "Learning to walk in minutes using massively parallel deep reinforcement learning," in Proc. 5th Conf. Robot Learning (CoRL), London, UK, PMLR, vol. 164, pp. 91–100, 2022.

[2] D. Liu, T. Zhang, J. Yin, and S. See, "Saving the limping: Fault-tolerant quadruped locomotion via reinforcement learning," arXiv preprint arXiv:2210.00474v3, 2023.

[3] V. Makoviychuk et al., "Isaac Gym: High performance GPU based physics simulation for robot learning," in Proc. Neural Information Processing Systems Track on Datasets and Benchmarks (NeurIPS), Virtual, vol. 1, 2021.

[4] X. Wu, W. Dong, H. Lai, Y. Yu, and Y. Wen, "Adaptive control strategy for quadruped robots in actuator degradation scenarios," in Proc. 5th Int. Conf. Distributed Artificial Intelligence (DAI), Singapore, pp. 1–13, 2023.

[5] A. Kumar, Z. Fu, D. Pathak, and J. Malik, "RMA: Rapid motor adaptation for legged robots," in Proc. Robotics: Science and Systems (RSS), Virtual, 2021.

[6] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, "Proximal policy optimization algorithms," arXiv preprint arXiv:1707.06347, 2017.